

DORA

人工智能辅助软件开发 现状调查报告

Google Cloud 2025

QECOn 翻译出品

译者:朱少民、李威、王永雷、揭光发、顾黄亮、单虢晗、熊志男、吴骏龙

审校:张乐、茹炳晟

项目组:白萍萍、张丽媛、李婕

添加小助手, 关注10月31日Dora报告解读



铂金赞助商

swarmia /thoughtworks

首要研究合作伙伴

REVOLUTION

金牌赞助商

Buildkite CodeRabbit DATADOG Deloitte.
harness JELLYFISH Octopus Deploy OPSERA

研究合作伙伴

GitHub GitLab
skillbench Workhelix

目录

03	65	99
摘要	平台工程	作者
08	73	103
前言	价值流管理	个人与企业统计概况
11	79	113
理解您的软件交付效能： 7 种团队类型概览	AI 之镜：AI 如何反映和放大 组织的真正能力	方法论
23	89	131
人工智能的采纳与使用	度量框架	我们的研究模型及理论基础
33	95	137
探索 AI 与关键成果 之间的关系	结语：从洞察到行动	下一步
49	97	138
DORA 人工智能能力模型	致谢	附录

摘要

核心要点：AI 是一种放大器

2025 年，技术领导者面临的核心问题不再是是否应该采纳 AI，而是如何实现其价值。DORA 的研究包括超过 100 小时的定性数据以及来自全球近 5,000 名技术专业人士的调研回复。¹ 研究揭示了一个关键真相：AI 在软件开发中的主要角色是放大器。它放大了高效能组织的优势，也放大了困境组织的功能障碍。


AI 投资的最大回报并非来自工具本身，而是来自对底层组织系统的战略性关注：内部平台的质量、工作流程的清晰度，以及团队的协调一致性。如果没有这个基础，AI 只会创造局部的生产力提升，而这些提升往往会在下游的混乱中消失殆尽。



主要发现

基于 2025 年 6 月 13 日至 7 月 21 日期间进行的定性数据收集和全球调研，本报告揭示了 AI 辅助软件开发现状的几个关键发现，包括：

AI 采纳已变得几乎普及。大多数调研受访者（90%）在工作中使用 AI，并相信（超过 80%）AI 提高了他们的生产力。然而，有相当一部分人（30%）目前报告对 AI 生成的代码几乎没有或完全没有信任，这表明人们需要关键的验证技能。 更多内容请参见《人工智能的采纳与使用》章节。	成功采纳 AI 需要的不仅仅是工具。我们新的 DORA 人工智能能力模型识别出七个基础实践——包括明确且已共识的 AI 立场、健康的数据生态系统和以用户为中心的关注点——这些实践被证明能够放大 AI 对组织效能的积极影响。 在《DORA 人工智能能力模型》章节阅读更多内容。	AI 采纳现在改善了软件交付吞吐量，这是与去年相比的关键转变。然而，它仍然增加了交付不稳定性。这表明虽然团队正在为提高速度而调整，但他们的底层系统尚未演进到能够安全管理 AI 加速开发的程度。 在《探索 AI 与关键结果关系》章节阅读更多内容。
今年的研究识别出七种不同的团队类型，从“和谐的高成就者”到陷入“遗留系统瓶颈”的团队，为有针对性地改进提供了新的框架。 在了解您的《软件交付效能章节》章节阅读更多内容。	价值流管理（Value Stream Management, VSM）是一种可视化、分析并优化从创意到交付客户全过程工作流的实践方法，它能为人工智能（AI）发挥倍增效应，确保局部生产力的提升可转化为团队与产品绩效的可量化改进。 在《价值流管理》章节阅读更多内容。	90% 的企业已采用平台工程，这使得高质量的内部平台成为人工智能（AI）成功应用的关键基础。 在《平台工程》章节阅读更多内容。



给技术领导者的分析和建议

成功的 AI 采纳是一个系统问题，而非工具问题

我们新的 DORA 人工智能能力模型揭示，AI 的价值并非由工具本身释放，而是由周围的技术和文化环境所决定的。我们已经识别出七个基础能力——包括明确且已共识的 AI 人工智能立场、健康的数据生态系统、高质量的内部平台和以用户为中心的关注点——这些能力被证明能够放大 AI 对效能的积极影响。

将您的 AI 采纳视为组织转型。最大的回报将来自对放大 AI 效益的基础系统的投资：您的内部平台、您的数据生态系统，以及团队的核心工程能力。这些要素是将 AI 潜力转化为可衡量的组织效能的基本前提。

普遍的 AI 采纳与合理的怀疑态度

虽然大多数开发者使用 AI 来提高生产力，但对其输出质量存在合理的怀疑态度。这种“信任但要验证”的方法是成熟采纳的标志。

关于人工智能的讨论，必须从“采纳”转向“有效应用”。企业的培训项目应聚焦于教会团队如何批判性地引导、评估并验证人工智能生成的成果，而非单纯鼓励使用人工智能。

七种团队效能类型

仅依靠简单指标远远不够。我们已识别出七种截然不同的团队类型，每种类型在绩效、稳定性与员工幸福感方面均呈现出独特的组合特征。该模型为理解团队面临的具体挑战提供了细致入微的视角，进而助力制定量身定制的改进路径。

借助这些团队类型，可在软件交付绩效指标之外，对团队健康状况进行诊断。要准确判断团队属于“高效能但正面临倦怠”还是“状态稳定却受困于遗留系统”情况，并据此实施恰当的干预措施，需以严谨、客观的视角开展分析与行动。

高质量平台释放 AI 的价值

平台工程现在几乎普及（94% 的采纳率）。我们的数据显示，高质量内部平台与组织释放 AI 价值的能力之间存在直接关联。将平台工程视作旨在优化开发者体验的内部产品来打造的企业，能获得显著更高的回报。

应将平台工程相关举措列为优先事项并为其提供资金支持。开发者体验不佳与工具碎片化问题，可能会削弱人工智能战略的实际成效。

系统视角引导 AI 的潜力

今年的研究证实，价值流管理 VSM 能够实现针对性改进，进而推动更高的团队和产品效能。

VSM 可作为人工智能投资的效能倍增器。通过提供系统层面的视角，它能确保人工智能被应用于正确的问题上，从而将局部生产力提升转化为显著的组织层面优势，而非单纯在下游制造更多混乱。

使用本报告

本报告详述了这些发现背后的数据，包括我们新的 DORA AI 能力模型，该模型识别了放大 AI 效益的关键实践。

虽然每个组织都是独特的，但我们的发现提供了一个框架来指导您的战略并引导您的团队。使用这项研究来形成假设、进行实验并测量结果，以发现在您的特定环境中驱动最高效能的因素。



1 关于今年研究参与者的更多详细信息可在[人口统计学和企业统计学](#)章节中找到。



DORA 社区¹ 为专业人士提供了一个参与这项研究并将其应用于改善自身组织效能的平台。



为什么加入DORA社区？

您应该成为 DORA 社区一员的几个原因：

向专家和同行学习：社区通过演示和讨论提供向嘉宾演讲者和其他成员学习的机会。

跟上研究进展：第一时间了解 DORA 的新信息和出版物。

协作和讨论：DORA 社区 Google 群组² 为异步对话、公告和活动邀请提供论坛。这使成员能够讨论话题并与该领域的其他人分享经验。

参与社区活动：虚拟和面对面活动的日程表可在 DORA.community 上找到。

为讨论做出贡献：通过倾听、交和参与聊天为对话做出贡献。社区重视成员的意见，并为领导力、团队赋权和技术实践演进等话题的持续讨论提供空间。

1. DORA 社区: <https://dora.community>

2. DORA 社区 Google 组: <https://groups.google.com/g/dora-community/about>

前言

许多人相信，科学的目标是用最少的原理解释最多的可观察现象，确认深层次的直觉，并揭示令人惊讶的洞察。十多年来，这正是 DORA 研究项目所做的。

我对今年的研究如何帮助我们更好地理解如何使用 AI 来改进软件感到非常兴奋。

Gene Kim

研究员、Vibe 程序员、《Vibe Coding》、《凤凰项目》《DevOps 实践指南》、《加速》联合作者

2013 年，我有幸与 Nicole Forsgren 博士和 Jez Humble 一起进行 DevOps 现状研究。这项工作成为了 DevOps 研究与评估小组——DORA——的基础，该小组于 2018 年成为 Google Cloud 的一部分。

对如今许多人而言，很难相信就在十多年前，软件部署曾是既危险又复杂的事情。当时的部署需要详尽的规划与审批流程，且往往涉及数百个高风险、易出错的手动操作步骤。即便经过了周密规划与谨慎执行，部署操作仍会引发严重混乱与业务中断，这也是过去我们每年只敢进行一次部署的原因。

2013 年，DevOps 现状研究表明，每天进行多次部署并不是一个疯狂的想法，可靠性似乎需要更频繁地进行更小规模的部署。

更令人兴奋的是：实现这一点，并不局限于初创企业或硅谷地区的公司。您只需要优秀的技术实践（例如，自动化构建、自动化测试、自动化部署、主动的生产遥测），一个能够实现行动独立性的架构（能够独立开发、测试和部署的价值，几乎没有或没有协调成本），以及学习的文化。

现在，12 年后，作为一个技术社区，我们再次面临着一项卓越的新技术——人工智能。正如我们十年前所做的那样，我们正在询问：这项新技术是否真的能够实现更好的软件交付和组织效能？

2024 年，DORA 发布了一份具有里程碑意义的报告，该报告旨在衡量人工智能对软件交付性能的影响，是此类研究中最先开展的系统性研究之一。部分人对报告结果感到惊讶。数据显示，人工智能的使用程度越高，软件交付的稳定性与吞吐量反而越差——而这两项指标正是软件开发从业者过去十年间一直致力于改善的核心属性。

是的，我亲眼见过也亲身经历过使用人工智能可能引发的问题，从静默删除测试、明显损坏的功能，甚至删除生产数据等各种问题。但与此同时，我也见证过人工智能被用于大幅改善工作成果的案例。我开始称去年的报告及其发现为“DORA 2024 异常现象”——也就是说，一个令人兴奋的待解之谜。

这种信念来自于过去一年与 Steve Yegge 的合作，他因在亚马逊和谷歌工作 20 年而闻名。他记录了亚马逊创始人 Jeff Bezos 的一份备忘录如何推动亚马逊从软件单体架构转变为数千个微服务。这种转变帮助实现了 2015 年每天 136,000 次部署，这一成就多年来一直激励着 DORA 研究。

Steve 和我一起撰写了即将出版的书籍《Vibe Coding》，我们在其中将“vibe coding”定义为不需要手工键入代码的编程形式。相反，代码通过与 AI 的迭代对话而产生。我们描述了 vibe coding 如何改变了我们的生活——它使我们能够更快地构建想要的东西，追求更雄心勃勃的项目，更自主地工作，获得更多乐趣，并探索一个更广阔的选择空间（放手去试！）。

我和 Steve 都见证过“氛围编码”（vibe coding）如何走向失控——最终导致测试用例被删除、系统中断，甚至代码仓库被误删。但我们得出的结论是：出现这些问题，根源在于过去数十年里对我们大有裨益的工程直觉，如今已被证明远远不足以应对当前的情况。

假设你曾有过的最快移动速度，不过是每小时 4 英里的步行速度，此时若有人让你以每小时 50 英里的速度驾驶汽车——在缺乏练习与培训的情况下，你毫无疑问会把车开得一团糟。

我们得出结论，当人工智能显著加速软件开发时，我们的控制系统——也就是我们自己——也必须加速。¹ 换句话说，十年的 DORA 研究可能已经向整个软件开发行业展示了实践必须演进。

- 我们需要快速反馈循环——比以往任何时候都更快——以匹配 AI 加速的代码生成。
- 我们需要在能够赋予我们行动自主性的软件架构内开展工作——如今，我们比以往任何时候都更需要具备独立开发、测试和部署软件的能力。
- 我们需要营造一种学习氛围，尤其是考虑到人工智能所具有的独特属性及其迅猛的发展速度。

在《Vibe Coding》中，Steve 和我收录了以下案例研究，这些案例隐晦地揭示了相关原则与实践——以及为何它们在人工智能时代具有如此重要的意义。

快速反馈循环和软件架构

Fernando Cornago, 阿迪达斯全球副总裁、数字和电子商务技术负责人, 他管理着近一千名开发人员。在他们的生成式人工智能（生成式 AI）试点项目中, 研究发现, 在松耦合架构下开展工作且拥有快速反馈循环的团队, “其生产力提升了 20% 至 30%—— 这是通过代码提交量、拉取请求数及整体功能交付速度的增长来衡量的”, 并且 “‘快乐时间’增加了 50%”—— 即实际编码时间更多, 而行政事务性工作更少。

相比之下, 由于与企业资源规划（ERP）系统的紧密耦合而导致反馈循环较慢的团队几乎没有看到任何 AI 收益。

2

学习文化

我们也很欣赏来自 Booking.com 开发者体验团队产品经理 Bruno Passos 的案例研究, 该公司拥有超过 3,000 名开发者的团队。在他们的 gen AI 创新实践中, 他们发现“开发者对 vibe 编程和编程助手工具的采纳是不均匀的……Bruno 的团队很快意识到缺少的要素是培训。当开发者学会如何给他们的编程助手提供更明确的指令和更有效的上下文时, 他们发现合并请求增加了多达 30%, 工作满意度也更高。”³

这两个案例研究均指向一个令人振奋的可能性: 人工智能会放大我们工程实践中的优势与劣势。无论是个人、团队还是团队集群, 只要具备出色的工程实践能力, 就有望从人工智能中获得显著收益。

我们认为, 那些不具备此类实践能力的组织或个人, 很可能会陷入困境—— 这一点在 “2024 年 DORA 异常现象” 中已有所暗示。


我很感激并荣幸能够与谷歌的 DORA 团队以及我们扩展的专家和研究团队合作, 他们的工作和成就令我钦佩, 帮助为今年的研究提供信息。

最让我兴奋的是 2025 年研究的规模: 有近 5,000 名参与者, 我们将能够进行一项实践调研, 希望能产生像十年前那样的“灵光一闪!”时刻。我确信我们将在未来几个月看到类似的突破。

一些发现已经进入了报告, 但还有更多诱人的洞察正在出现, 我很兴奋在未来的几个月和几年里分享这些发现。

我对整个 DORA 团队和使这项突破性研究成为可能的扩展贡献者表示感谢。

1. 控制理论中的奈奎斯特稳定性判据告诉我们, 任何控制系统都必须以至少是它所控制系统速度两倍的速度运行。
2. Kim, Gene, and Steve Yegge. Vibe Coding: Building Production-Grade Software With GenAI, Chat, Agents, and Beyond. Foreword by Dario Amodei (IT Revolution, 2025), 57.
3. 同上, 58。





理解您的软件交付效能： 七种团队类型概览

Nathen Harvey

DORA 负责人, Google Cloud

OECON 翻译出品
保留所有权利, 禁止商用

软件交付效能

新软件发布的时刻值得庆祝，因为只有当世界能够使用它时，其主要价值才能被确定。这些用户可能是客户、合作伙伴、同事、陌生人，甚至是其他技术系统。



同时，新软件发布的时刻，也是我们开始了解其在生产环境中表现如何、以及满足用户需求程度的起点。在这一时刻到来之前，我们可以采取诸多措施来提升信心，确保软件能按照预期运行。但发布的这一刻，才是检验软件能否从理论走向实践的关键——若无法实现，便意味着理论未转化为实际价值。

发布新软件远不止是推出新的应用程序与服务。一旦应用程序发布，用户的反馈要么会推动你进行改进，要么会迫使你不得不改进。

当然，需要对应用程序进行变更的原因有很多，例如修复安全漏洞、提升性能、降低运营成本，或是减少碳排放量。从本质上讲，这些考量不仅能为用户带来益处，也有助于保障应用程序的长期成功。

我们还需考虑负责应用程序构建、部署、运维及持续支持的团队的长期健康与工作状态。我们需要配备恰当的能力与条件，确保这些团队能够以可持续的方式推动项目取得成功成果。

这些考虑，加上更快发展和取得更大成功的业务需求，促使 DORA 将软件交付效能作为我们研究的焦点。

软件交付效能因素

DORA 的软件交付效能指标从宏观视角审视整个交付流程，并聚焦于两个关键要素：吞吐量与不稳定性。

吞吐量

吞吐量是衡量在一段时间内有多少变更可以通过系统的指标。吞吐量越高，意味着系统能够将更多变更推送至生产环境。

DORA 使用三个因素来衡量软件交付吞吐量：

变更前置时间

变更从提交到版本控制到在生产环境中部署所需的时间。

部署频率

在给定时间段内的部署次数或部署之间的时间间隔。

失败部署恢复时间

从失败且需要立即干预的部署中恢复所需的时间。

不稳定性

不稳定性是衡量软件部署情况好坏的指标。当部署顺利时，团队能够自信地将更多变更推送至生产环境，而用户在部署完成后立即遇到应用程序问题的可能性也会降低。

DORA 使用两个因素来衡量软件交付不稳定性：

变更失败率

需要在部署后立即干预的部署比例。可能导致变更回滚或“热修复”以快速修复任何问题。

返工率


由于生产环境中的事故而导致的计划外部署的比例。

综合来看，这两个软件交付效能要素能让团队从宏观层面理解自身的软件交付效能。通过长期对其进行衡量，可深入了解软件交付效能的变化情况。无论技术栈、部署流程复杂度或终端用户如何，这些要素均可用于衡量任意应用程序或服务。

将目光投向软件交付效能指标之外

虽然这五个指标提供了效能的重要快照，但它们终究是结果性指标。它们告诉您正在发生什么，但不能解释为什么。部署频率低可能是由技术债务、官僚化流程或团队倦怠导致的，而仅靠这些指标无法对这些原因加以区分。

为了将效能数据与驱动它的人为因素联系起来，我们进行了聚类分析。这种方法超越了孤立的数字，揭示了七种常见的团队类型，每种都讲述了效能、幸福感和环境之间相互作用的更深层故事。



识别共性规律

我们开展了聚类分析，以理解影响软件交付效能的人为因素与系统性因素，并识别其中的共性规律。在综合考量以下因素的基础上，我们的统计聚类方法揭示了七种团队类型：

团队效能

该因素衡量个体对其直接所在团队的效能表现与协作能力强度的主观感知。

产品效能

该因素衡量团队所构建产品或服务的成功程度与质量。其评价维度包括：是否帮助用户完成关键任务、是否保障信息安全以及延迟等性能指标。

软件交付吞吐量

该指标用于衡量软件交付流程的速度与效率。

软件交付不稳定性

该指标用于衡量软件交付流程的质量与可靠性。

个体效能

该因素反映个人对自身工作效能与成就感的自我评估。

有价值的工作

该指标衡量个体自我评估投入于其认为有价值且值得的工作所占用的时间比例。

摩擦阻力

该指标衡量阻力在多大程度上妨碍了个体的工作。较低的摩擦阻力通常被视为一种积极结果。

职业倦怠


该指标衡量个体在工作中所体验到的疲惫感与消极态度。较低程度的职业倦怠通常被视为一种积极结果。

组织、团队与个人通常致力于提升团队效能、产品效能、软件交付吞吐量、个体效能以及有价值的工作比例，同时降低软件交付不稳定性、摩擦阻力与职业倦怠。

我们的分析揭示了七类截然不同的团队原型，范围从在健康且可持续环境中表现卓越的“和谐高成就者”，到受制于技术债务的“遗留瓶颈型”，再到陷入低效流程限制的“流程受限型”。

七类团队原型的效能水平

聚类1:基础性挑战型




聚类2:遗留瓶颈型




聚类3:流程受限型




聚类4:高影响力低节奏型




聚类5:稳健有序型



聚类6:务实执行者型



聚类7:和谐高成就者型



这些聚类的名称与描述均基于数据的解读得出。您的团队可能在效能水平上与某一聚类相似，但未必认为该聚类的名称或描述能够准确反映团队的真实特征。

图 2:七类团队原型的效能水平

聚类 1：基础性挑战型

这些团队被困在“生存模式”中，在流程、环境与成果等基础环节上存在显著缺口，因而面临重大挑战。

受访者占比：10% 的调查参与者属于聚类 1。

效能指标：与团队产出、产品交付及价值创造相关的关键效能指标持续处于较低水平。

团队幸福感：数据显示，职业倦怠报告水平偏高，且存在显著的摩擦阻力。

系统稳定性：软件及运行环境的稳定性面临显著挑战。

聚类1:基础性挑战型



图3：聚类 1:基础性挑战型

聚类 2：遗留瓶颈型

该类团队始终处于被动反应状态，不稳定的系统主导了他们的工作，并持续削弱团队士气。

受访者占比：11% 的调查参与者属于聚类 2。

效能指标：产品效能相关的关键指标较低。尽管团队能够定期交付更新，但持续存在的质量问题削弱了其实现的价值。

团队幸福感：数据显示其工作环境要求苛刻。团队成员普遍反映摩擦阻力较大，且职业倦怠水平偏高。

系统稳定性：软件及其运行环境的稳定性问题频繁且严重，导致大量计划外的被动性工作。




图4：聚类2:遗留瓶颈型

聚类 3：流程受限型

这些团队仿佛在“跑步机”上运转。尽管其系统相对稳定，但低效的流程消耗了大量精力，最终导致职业倦怠程度高企，而实际影响力却偏低。

受访者占比：17% 的调查参与者属于聚类 3。

效能指标：关键效能指标显示团队效能较低，创造的客户或业务价值有限。

团队幸福感：数据显示职业倦怠与摩擦阻力均处于高水平。这表明当前的工作流程和过程正在给团队形成一个充满挑战且不可持续的工作环境。

系统稳定性：团队的软件与运行环境稳定且可靠。这说明技术层面的不稳定性并非造成效能和幸福感问题的主要原因。



图5：聚类3:流程受限型

聚类 4：高影响力低节奏型

这些团队能够产出高影响力的工作，体现在突出的产品效能与较高的个体效能。然而，其交付模式节奏较低，表现为软件交付吞吐量不足且不稳定性较高。

受访者占比：7% 的调查参与者属于聚类 4。

效能指标：团队持续保持顶尖的生产力水平，效能与产品效能指标均表现突出。

团队幸福感：数据显示其摩擦阻力较低，表明团队流程高效且具有良好的协作性。

系统稳定性：运行环境呈现高度不稳定性，这种波动性对服务可靠性与长期可持续性构成了重大风险。




图6：聚类4:高影响力低节奏型

聚类 5：稳健有序型

这些团队堪称软件领域的“稳健工匠”，以谨慎且可持续的节奏交付高质量、有价值的工作成果。

受访者占比：15% 的调查参与者属于聚类 5。

团队幸福感：数据显示职业倦怠与摩擦阻力水平较低，表明团队环境健康且具备可持续性。

效能指标：产品质量与价值创造相关的关键效能指标持续表现良好。然而，团队的软件交付吞吐量处于较低分位，反映出其工作节奏更为谨慎与稳健。

系统稳定性：团队的软件与运行环境具有高度的稳定性与可靠性。

聚类 6：务实执行者型

这些团队始终能够以令人瞩目的速度与稳定性交付工作成果，尽管其工作环境尚未达到最佳投入状态。

受访者占比：20% 的调查参与者属于聚类 6。

团队幸福感：该类团队与绝对顶尖团队的差异主要体现在幸福感指标上。数据显示职业倦怠与摩擦阻力处于平均水平，说明其工作环境功能性良好且具备可持续性，但可能缺乏较强的参与驱动力。

效能指标：团队在软件交付相关的关键指标上表现强劲，吞吐量高于平均水平且不稳定性低。团队能够保持稳定的节奏，持续产出有价值的成果，并可靠地满足预期。

系统稳定性：团队的软件与运行环境稳定且可靠，为其高效能表现提供了坚实的基础。

聚类 7：和谐高成就者型

这正是卓越的典范，一个良性循环应该如此：稳定、低摩擦的环境赋能团队以可持续的方式交付高质量成果，并避免职业倦怠。

受访者占比：20% 的调查参与者属于聚类 7。

团队幸福感：其工作环境特点是职业倦怠与摩擦阻力报告水平较低。

效能指标：团队在多个方面的指标均表现积极，包括团队幸福感、产品成果以及软件交付。

系统稳定性：团队运行在稳定的技术基础之上，这为其工作速度与质量提供了双重支撑。

聚类5:稳健有序型




图7：聚类5:稳健有序型

聚类6:务实执行者型



图8：聚类6:务实执行者型

聚类7:和谐高成就者型




图9：聚类7:和谐高成就者型

软件交付效能水平




图 10 为 DORA 研究的核心论点提供了有力证据：所谓“速度与稳定性的权衡”其实是一个神话。最佳表现者（聚类 6 与 7）能够在这两个维度上同时取得卓越成绩。

相反，在频谱的另一端，团队面临明显困境。例如，遭遇基础性挑战的团队（聚类 1）。

而高影响力低节奏团队（聚类 4）则表明，速度若缺乏稳定性，将是一种危险且不可持续的做法。

卓越是可以实现的。聚类 6 与 7 占整个样本的近 40%。它们的存在为可能性提供了实证基准，也成为组织努力追求的标杆。尽管达到这一状态无疑十分艰难，但这些团队有力证明：高速且高质量的软件交付并非理论上的理想，而是切实可观的现实。

如何进行比较？


你或许会好奇，你的团队与今年研究中的其他参与者相比处于什么位置。需要牢记的一点是，这些度量是基于应用或服务层面进行收集的。此举有助于推动跨职能团队共同承担改进责任。

此外，最有价值、最具洞察力的软件交付效能比较，应针对同一应用或服务在不同时期的表现来进行。其目标在于持续学习与改进，而非一味追求达到最高的软件交付效能水平。

图 11 至图 15 展示了 2025 年 DORA 调查中受访者回答分布的洞见。


变更前置时间分布

调查问题：
您的变更前置时间是多少？
（即：从代码提交到代码成功运行在生产环境中所需的时间）



部署频率

调查问题：
贵组织多长时间将代码部署到生产环境或发布给终端用户一次？



部署失败恢复时间分布

调查问题:

在一次变更发布到生产环境或交付给用户后，如果导致了服务效能下降（例如，引发服务受损或服务中断），并因此需要补救措施（如热修复、回滚、向前修复或打补丁），通常需要多长时间才能恢复服务？



图 13: 2025 年 DORA 调查中部署失败恢复时间回答的分布

变更失败率分布

调查问题:

大约有多少比例的生产环境变更或对用户发布新版本会导致服务降级（例如，引发服务受损或服务中断），并因此需要采取补救措施（如热修复、回滚、向前修复或打补丁），如果有的话？




图 14: 2025 年 DORA 调查中变更失败率回答的分布

返工率分布

调查问题:

在过去六个月中，大约有多少比例的部署并非计划内，而是为了解决应用程序中的用户可见性缺陷而进行的？



图 15: 2025 年 DORA 调查中返工率回答的分布



将软件交付效能付诸实践

软件交付效能指标为整个交付流程提供了宏观视角。随着时间推移，这些指标的变化能够揭示整体状况是在改善还是恶化。为改变这些指标所需的干预措施可能会因具体应用而异，但也可能出现一些共性模式，例如冗长的评审与审批周期。

让我们通过一个假设性的案例来说明。在一次常规的回顾会议中，某团队讨论了他们的软件交付效能。他们注意到，所负责应用的变更前置时间正在开始增加。

他们可能是通过查看仪表盘注意到这一点，但同样有可能只是通过日常观察发现的。对于这些指标而言，并不总是需要精确的数值，团队通常能够感知到其随时间的变化趋势。

团队希望扭转这一趋势。但要做到这一点，就需要理解背后的潜在原因。这时，补充数据可能会有所帮助。团队可以查看其开发系统中的数据——例如代码仓库或分析工具——并发现代码审查似乎正在耗费更长时间。

团队一致认为这是需要改进的领域，并讨论了潜在的干预措施，包括：将代码审查重新设定为日常工作的优先事项，以及努力将变更拆分得更小，以便于审查。在确定了这些具体步骤后，他们同意在一个月后重新审视变更审批时间及所有软件交付指标，以评估改进进展。

无论你的团队被归类为“流程受限型”还是“稳健有序型”，目标都是一致的：培养持续改进的心态，使团队不断迈向更为和谐且高成就的状态。



人工智能的采纳与使用

Kevin M. Storer, 博士.

用户体验研究员, Google Cloud

Derek DeBellis

量化用户体验研究员, Google Cloud

随着我们持续探索软件开发行业中人工智能采纳的趋势，人工智能在软件开发中的应用已显著扩展。在这一快速演进的领域中，我们致力于提供基于实证的指导，帮助软件开发社区更好地应对这些变化。今年的《人工智能辅助软件开发现状调查》报告，呈现了迄今为止我们对人工智能辅助开发所进行的最深入分析结果。



研究发现


总体而言，我们关于软件开发人员采纳与使用人工智能的研究结果表明：人工智能已在各种任务中被广泛采纳并高度依赖。这为个人生产力和代码质量带来了显著提升。

采纳情况

今年有 90% 的调查受访者报告在工作中使用人工智能，比去年的同类指标上升了 14.1%。这一显著的高使用率表明，人工智能在软件开发中的应用如今已成为常态。

人工智能使用情况

在工作中使用人工智能的受访者比例



误差线显示 89% 的可信区间
图 16: 人工智能使用情况

“我认为在过去一年左右的时间里，人们已经意识到生成式人工智能的发展已达到一个真正能够在许多场景中发挥作用的阶段。而如今，这几乎成了一种共识：每个人的应用都能在某种程度上从生成式人工智能中获益。

因此我认为，推动新功能的启用以降低特定成本、缩短某些创造过程耗时的动力非常强劲。没有人想被甩在后面……我确信，随着时间推移，生成式人工智能将越来越多地融入到一切当中；而如果你没有以某种方式使用生成式人工智能，那么你将很难跟上时代步伐。”

使用体验

我们的受访者在使用人工智能工具方面报告了不同的经验区间，其中位数为 16 个月，平均值为 16.22 个月。作为参考，ChatGPT 发布于 2022 年 11 月，即在本次调查启动前约 31 个月。在我们的数据中，既包含了早期采纳者，也包含了后期采纳者，并且观察到在 2023 年底至 2024 年中期之间出现了一波采纳高峰。

使用时长

在我们的样本中，用户在最近一个工作日中与人工智能交互所花费的时间也存在差异。调查结果显示，受访者在最近一个工作日中与人工智能交互的中位数为 2 小时，约占标准八小时工作日的四分之一。

人工智能用户的月度采用情况

每月新增用户数量（含关键行业事件）



图 17：用户的人工智能月度采用情况

最近一个工作日的人工智能使用时长

用户与人工智能日均交互时间的分布




图 18：最近一个工作日的人工智能使用时长


反射式使用

尽管在我们的样本中，人工智能的使用几乎已无处不在，但反射式使用——即在面对问题时将人工智能作为默认手段——尚未普及。在人工智能的用户中，仅有 7% 的人报告称在遇到问题或需要完成任务时“总是”使用人工智能，而有 39% 的人仅表示“有时”会寻求人工智能的帮助。

不过，仍有高达 60% 的人工智能用户表示，在遇到问题或任务时“约有一半时间或更多”会使用人工智能，这表明人工智能已成为软件开发过程中的常见组成部分。

反射式人工智能的使用

用户在遇到问题或任务时求助人工智能的频率：



误差线显示 89% 的可信区间
图 19：反射式人工智能的使用

Sabre

在过去的 18 个月中，Sabre 通过使用分析与满意度调查，积极跟踪了生成式人工智能助手的采纳情况。采纳率已在不同任期与经验水平的开发者群体中攀升至 74%，并且在核心开发任务中的人工智能使用出现了显著增长。

这种使用率的提升与更高的用户满意度呈正相关。高达 86% 的用户报告称其生产力有所提高。满意度和节省时间的持续上升趋势表明，随着用户对生成式人工智能工具的熟练程度不断加深，其带来的收益也在不断增长。

我们的分析还发现，对于最新的生成式人工智能功能（如智能体模式），用户的采纳速度较为缓慢，目前仅有 25% 的用户在使用。对此，Sabre 正在强化培训项目，并推动同伴之间的知识分享，以提升用户参与度，并确保团队能够熟练掌握人工智能工具。

Jacek Ostrowski, 平台工程副总裁, Sabre


依赖性

除了使用频率高之外，我们还发现开发专业人员在工作中对人工智能工具存在高度依赖。

在我们的样本中，仅有 5% 的人工智能用户表示在工作中“完全不依赖”人工智能，而有 65% 的用户表示对人工智能的依赖程度为“中等”（37%）、“较高”（20%）或“极高”（8%）。

工作中对人工智能的总体依赖性

人工智能用户依赖程度的分布：



误差线显示 89% 的可信区间
图 20：工作中对人工智能的总体依赖性

任务


与我们的《2024 年 DORA 报告》2 一致，今年受访者使用人工智能工具的首要用途是编写新代码。在会编写代码的受访者中，有 71% 使用人工智能来辅助完成这一任务。

在工作职责涉及相关任务的受访者中，绝大多数也使用人工智能来进行文献综述（68%）、修改现有代码（66%）、校对（66%）以及创建或编辑图像（66%）。

在工作职责涉及相关任务的受访者中，较少见的人工智能使用场景包括：需求分析（49%）、内部沟通（48%）以及日程管理（25%）。

按任务划分的人工智能依赖性

在执行任务的人员中使用人工智能的比例



误差线显示 89% 的可信区间
括号内为执行该任务的所有受访者比例。“其他”类别已被排除。
图 21：按任务划分的人工智能依赖性

定制化如何提升开发者的投入感

Edward Fraser

加州大学伯克利分校信息学院研究生

我们的研究内容

随着人工智能助手在开发工作中日益普及，加州大学伯克利分校的一支研究生团队对学生开发者在实践中如何使用人工智能驱动的开发环境（IDE）展开了研究。研究团队通过眼动追踪数据和访谈，观察了具有 1 至 5 年经验的 Python 开发者如何完成两项简短任务：一项涉及使用陌生的库，另一项则要求解释一个晦涩的函数。

通过应用本研究的洞见，各经验层级的开发者都可能找到更契合自身需求的与人工智能编程助手协作的方式。

当人工智能成为阻碍

尽管人工智能编程助手旨在节省时间并减少工作量，但加州大学伯克利分校的一项研究发现，它们在某些任务中也可能带来摩擦。

例如，学生开发者在处理诸如编写样板代码、安装依赖包等机械性任务时乐于使用人工智能，但在需要更深入理解的情境下（如解释复杂代码），这些学生开发者大多忽略了人工智能的建议。

眼动追踪数据显示，在解释性任务中，开发者对人工智能聊天的视觉关注度不足 1%，而在更具机械性的任务中，这一比例接近 19%。研究中的学生往往选择手动完成任务，以保持对过程的掌控和理解，甚至会忽视那些准确且能节省时间的建议。

定制化作为解决方案

为减少摩擦并更好地支持专注工作，开发者和团队可以对其人工智能工具进行定制化。如今，大多数集成开发环境（IDE）都提供了诸如切换内联建议、启用“仅按需”模式、或调整建议的风格与结构等功能。

在仓库层级配置文件与关联文档的辅助下，人工智能助手能够遵循既定规范。通过尝试这些设置，可以使人工智能的行为更好地契合不同任务的认知需求，从而帮助减少干扰并提升人工智能助手的实用性。

团队启示

为了最大化人工智能编程助手价值，开发者与团队应投入精力进行定制化。


本研究表明，人工智能在解释性任务中可能会因增加认知负荷而造成干扰，尤其是在开发者试图理解不熟悉代码时。

关键在于让人工智能的支持与任务性质及开发者的偏好保持一致。通过优化设置，可以将人工智能从摩擦源转变为提升效率、增强体验的有力工具。

交互界面

对话式人工智能聊天机器人是与人工智能交互的最常见方式，其次是嵌入在集成开发环境（IDE）中的人工智能。受访者报告称，他们较少通过自动化工具链以及其他开发工具与平台与人工智能交互，但这可能是因为这些人工智能工具对用户而言不够直观可见。

人们与人工智能交互的场景
使用各类交互界面的受访者比例：



误差线显示 89% 的可信区间。“其他”类别已被排除。
图 22：人们与人工智能交互的场景

人工智能使用模式

除了询问受访者与人工智能的交互场景与目的外，我们还调查了他们在以下几种“模式”中的交互频率：

- 1) 聊天模式：任何逐轮的文本交互；
- 2) 预测文本模式：例如通过 Tab 键补全的代码建议；
- 3) 协作模式：使用人工智能对代码库进行更广泛的修改；

4) 智能体模式：允许人工智能在相对无人监督的情况下进行操作和修改。

与受访者最常使用的聊天机器人和 IDE 内交互相对应，文本聊天与预测文本是最常见的交互模式。而智能体模式的使用最少，多达 61% 的受访者报告称“从不”以智能体模式与人工智能工具交互。

这一使用模式很可能反映了不同人工智能模式的成熟度差异：智能提醒人工智能的采纳率较低，与其出现时间较晚且尚未像聊天与预测文本功能那样成熟相一致。

人工智能交互模式的使用频率
各交互模式的回答比例：





图 23：人工智能交互模式的使用频率

个体生产力

今年超过 80% 的调查受访者表示，他们感知到人工智能提升了自身的生产力。有超过 40% 的人认为生产力提升仅为“轻微”，不到 10% 的受访者认为人工智能对其生产力产生了任何下降影响。

人工智能对个体生产力的感知影响

受访者对人工智能影响其生产力的评价



误差线显示 89% 的可信区间


图 24：人工智能对个体生产力的感知影响

代码质量

除了感知到人工智能对生产力的积极影响之外，大多数受访者（59%）也观察到人工智能对其代码质量产生了正面作用。其中 31% 的人认为这种提升仅为“轻微”，另有 30% 的人未观察到正面或负面影响。然而，仅有 10% 的受访者认为人工智能的使用对其代码质量带来了负面影响。

人工智能对代码质量的感知影响

受访者对人工智能影响其代码质量的评价



误差线显示 89% 的可信区间

图 25：人工智能对代码质量的感知影响



我觉得在某些方面，人工智能有时写的代码比我自己写得更好，主要原因是我感觉它经过了非常充分的训练。我之前提到过：代码是高度二元的——要么能运行，要么不能。而人工智能写出来的代码通常足以满足我的需求。而且它常常会遵循一些我可能不小心忘记了，或者懒得回头去重构的代码规范。所以我觉得它能更连贯地生成内容。”

信任

与《2024 年 DORA 报告》² 类似，今年的研究结果揭示了用户对人工智能生成结果的信任度的复杂图景。多数受访者（70%）对其质量表现出一定程度的信心，其中近四分之一（24%）表示具有“极高”或“较高”的信任。与此同时，仍有 30% 的受访者态度较为保留，其中 23% 表示“略有信任”，7% 表示对人工智能生成结果的质量“完全不信任”。


这些数据突显了一个关键洞见：高水平的人工智能采纳与显著的感知收益，可以与谨慎而细致的信任态度并存。我们的研究结果表明，绝对信任并不是人工智能生成输出具备实用性的前提。

这一模式与既有的行为习惯高度契合；在访谈中，开发者将其比作他们对其他广泛使用资源所保持的健康怀疑态度，例如在使用 Stack Overflow 上的解决方案时，信息会被采纳，但并不会被无条件信任。

人工智能在软件开发中的可信度仍然是一个值得讨论和研究的重要议题。我们此前曾提出过 五种策略，以帮助提升开发者对人工智能的信任³。然而，我们的数据表明，开发者在实际工作中可能已经在主动考虑并应对人工智能的这一局限性。

对人工智能输出质量的信任度

受访者信任水平的分布：



误差线显示 89% 的可信区间

图 26：对人工智能生成输出质量的信任度

总结思考

综合来看，这些研究结果表明，人工智能在软件开发中的应用几乎已达到普遍化程度。人工智能被广泛用于各类开发任务，已成为受访者工作流程的一部分，并且在面对问题时经常被求助。

尽管受访者仍然对人工智能生成代码的可信度表示担忧，但他们普遍认可人工智能对个人生产力与代码质量所带来的积极影响。因此，尽管存在一些不完美之处，人工智能的使用似乎已迅速成为大多数从事软件开发的组织中的标准实践。

去年的研究发现，竞争压力是推动软件开发中采纳人工智能的重要驱动力²。许多受访者将这种心态表述为“错失恐惧症”或“担心被同侪开发者与竞争对手公司甩在后面”。

然而，社会压力是否是采纳新技术的合理动因，仍值得商榷。尽管我们的数据表明人工智能采纳带来了许多积极成果，但我们同样记录到了一些显著的弊端。

因此，我们提醒不要将人工智能普及的发现解读为：所有组织都应不顾自身需求而迅速采纳人工智能。更为合理的解读是：这些发现向所有参与软件开发的人——无论是个人贡献者、团队管理者，还是高层领导者——发出了一个强烈信号：**必须深入思考人工智能是否、在哪里以及如何能够并且应该应用于他们的工作中。**

采取保守还是宽松的方式才是正确路径，将取决于具体的情境。然而，人工智能的广泛采纳已经表明，组织已无法再忽视其应用所带来的影响。

我们理解，关于人工智能在多大程度上应被整合进软件开发的决策是复杂且充满挑战的，而最优的决策应基于数据。因此，在本报告关于 DORA 全新的人工智能能力模型一章中，我们探讨了组织中的文化能力与技术能力如何影响其人工智能采纳的结果，并为那些选择将人工智能融入流程的组织提供可供借鉴的思路，帮助其实现成功落地。

1. Introducing ChatGPT | OpenAI. <https://openai.com/index/chatgpt>
2. Accelerate State of DevOps 2024. <https://dora.dev/dora-report-2024>
3. Fostering developers' trust in generative artificial intelligence. <https://dora.dev/research/ai/trust-in-ai>

探索 AI 与关键成果之间的关系

Derek DeBellis

定量用户体验研究员， Google Cloud





人工智能已成为软件开发的新常态

短短三年间，AI 的采纳和使用经历了惊人转变。在 2022 年，开发者使用 AI 可能还令人惊讶，但如今，90% 的技术专业人员在工作中使用 AI。在 AI 采纳与使用章节显示，AI 的采纳几乎已成普遍现象，这一趋势远超我们的数据。

2025 年 Stack Overflow 开发者调查发现，84% 的开发者正在使用或计划使用 AI 工具进行开发，比前一年的 76% 有显著增长。¹

日常使用也很普遍，47% 的受访者每天使用 AI 工具。Atlassian 的 2025 年 DevEx 状态调查进一步印证了这一趋势，报告称几乎所有开发者（99%）现在都通过使用 AI 工具节省时间。²

个人的热潮在企业战略中也得到了呼应。LinkedIn 企业传播部 2025 年的一份报告显示，88% 的企业领导者表示，加速 AI 采纳是优先事项。麦肯锡的一项调查发现，78% 的受访者表示，他们的组织至少在一个业务职能中定期使用人工智能。⁴

这一优先事项也反映在支出上：斯坦福 2025 年 HAI 人工智能指数报告称，2024 年全球企业在 AI 上的总投资达到 2523 亿美元，比前一年增长 26%。⁵

或许最能说明这一最新现实的是企业招聘所需的技能：美国提及生成式人工智能技能的职位发布量仅在 2023 年就增长了 323%。⁶



人工智能采纳带来了什么影响

鉴于这股采纳热潮，组织必须弄清楚是否也带来了相应的收益。广泛采纳并不自动等于广泛价值。我们需要认识到，采纳过程可能是混乱的，既可能受炒作和“错失恐惧症”（FOMO）的驱动，并非源于深思熟虑的战略。

采纳还可能受到组织系统的限制和约束，正如我们在 2024 年 DORA 报告中得出的结论：AI 虽然带来了许多令人期待的结果，但也增加了软件交付的不稳定性，并降低了软件交付的吞吐量。

同一份 2024 年 DORA 研究发现，每当 AI 采纳率提高 25%，软件交付吞吐量会下降约 1.5%，而软件交付不稳定性则增加约 7.2%。

我们的研究并非唯一指出这些复杂性的研究。例如，Model Evaluation & Threat Research (METR) 的一项最新研究表明，感知与现实之间存在显著错位：即使开发者因 AI 工具开发效率降低了 19%，他们仍认为这些工具让自己效率提高了 20%。类似地，其他第三方研究也开始指出 AI 对认知和幸福感的潜在影响，进一步强调作为一个行业，我们仍处于理解人工智能应用真实影响的早期阶段。

然而，当开发者被要求根据 SPACE 框架的各个维度评估 AI 时，他们报告的结果大多是积极影响，负面影响很少。我们在 AI 采纳与使用章节中的大多数受访者也表示，AI 对他们的代码质量和生产力产生了积极影响。

这些相互矛盾的信号表明，我们需要开展更多基于证据的研究，以评估 AI 对产品开发的真实影响，尤其是在 AI 投资和采纳规模如此庞大的情况下。

我们认为，开发者社区和雇主应设定切合实际的期望，而获得对 AI 实际影响的清晰认识，是负责任地管理这些期望的第一步。

衡量人工智能采纳程度

为了理解 AI 采纳程度如何影响关键结果，我们需要具备衡量 AI 采纳程度情况的能力。

今年，我们设计了 AI 采纳的衡量方法，并遵循以下基本原则：


- 包容性(Inclusive)：衡量标准不应偏向任何特定角色（或系统性地导致除 AI 采纳之外的其他因素得分高或低）。例如，软件开发人员不应仅因为使用 AI 编码就自动获得更高分数。该指标需要捕捉对 AI 的普遍态度，而不依赖于个人的具体工作职能或其他无关因素。
- 数据驱动
(Data-informed)：与往年一样，我们让数据先行，即使我们有强烈的假设。此过程的一部分包括开展探索性因子分析，以减少先验假设的约束。
- 理论驱动
(Theory-driven)：我们对 AI 采纳的概念化和测量应与公认的 AI 使用普遍共识以及我们的定性研究保持一致。

我们认为，这一因子捕捉了三个概念上紧密相关的维度：

依赖维度 (Reliance)：在过去三个月中，你在工作中对 AI 的依赖程度。

信任 (态度维度 Trust)：在过去三个月中，你对 AI 生成输出质量的信任程度。

反射性使用维 (Reflexive use)：你在工作中遇到问题或任务时，使用 AI 的频率。



分析结果表明，这三个调查问题的回答高度一致，说明存在一个潜在的单一概念，使这三个变量协同变化。

我们认为，该因素涵盖了三个概念上相互关联的维度：其一为行为维度（即使用情况），其二为依赖维度（即人工智能融入个人工作流程的深度），其三为关键的态度维度（即信任程度）。这一划分既与相关文献研究结论一致，也与我们的定性研究结果相符。

我们认为，这一因子捕捉了三个概念上紧密相关的维度：这种关系很可能存在反馈循环：信任是使用的前提，而使用又是建立信任的机制。这种循环会形成一个强大的反馈回路：当用户开始信任系统并使用它时，使用频率的增加会进一步加深依赖和信任，从而形成一个采纳循环。确实，这种循环性使得将这些变量结合起来成为构建因子的理想选择，尤其考虑到我们的调查只是一个快照，而不是一个动态过程的视频。AI 的采纳是一个心理过程，涉及态度、意图和行为。

将这一衡量标准与结果联系起来

建立 AI 采纳度量标准后，我们可判断不同 AI 采纳水平是否导致结果差异；基础形式为：

当比较两个具有相同特质、环境和流程的人时，平均而言，AI 采纳率较高的人会报告 {数字} 更多或更少的 {结果}。²²

当然，几乎没有任何个人、团队或组织是“平均”的，但探索这些平均效应可以揭示出一些普遍模式。这些模式有助于为《DORA AI 能力模型》章节中的更细致分析提供背景，在该章节中我们探讨了 AI 采纳在哪些条件下最有益（或最不利）。

我们每年都会尝试选择和构建一些结果指标，以代表阅读报告的技术人员的目标。简而言之，我们希望用技术专业人员关心的方式来评估实践活动。我们每年都尝试筛选并构建能代表报告读者目标的结果指标。简而言之，我们希望以技术专业人士关注的核心要素为尺度，评估各类实践方法的价值。

以下是我们今年研究的结果指标：

组织效能

这是衡量组织整体成功的高层次指标，依据盈利能力、市场份额和客户满意度等特征。

团队效能

衡量个人所在团队的协作能力和有效性。

产品效能

衡量团队所构建产品或服务的成功与质量，包括帮助用户完成重要任务、保障信息安全以及性能指标（如延迟）。

软件交付吞吐量

表示软件交付过程的速度与效率。详见《理解你的软件交付效能》章节。

软件交付不稳定性

反映软件交付过程的质量与可靠性。详见《理解你的软件交付效能》章节。

代码质量

反映个人对其主要应用或服务所使用代码质量的评估。

个人效能

衡量个人对自己在工作中的有效性和成就感的自我评估。

有价值的工作

衡量个人认为自己花在有价值、值得做的工作上的时间比例。

摩擦阻力


衡量工作中受到阻碍的程度。摩擦越少通常被认为是积极结果。

职业倦怠

衡量与工作相关的疲惫感和消极态度。职业倦怠越少通常被认为是积极结果。

今年的研究成果

图 28 展示了 AI 采纳与这些结果之间的关系。²³



我们估计，在两个拥有相同特征、环境和流程的人之间，AI 采纳程度更高的那个人会报告以下情况：²⁴

- 更高水平的个人效能
- 更高水平的软件交付不稳定性
- 更高水平的组织效能
- 更高比例的时间用于有价值的工作
- 更高水平的代码质量
- 更高水平的产品效能
- 更高水平的软件交付吞吐

- 更高水平的团队效能
- 相似程度的职业倦怠
- 相似程度的工作摩擦

本章节接下来的部分将尝试通过假设这些结果背后的潜在原因，来解释这一模式。

为了构建这些假设，我们将参考已有文献、我们的定性研究、领域专家的观点，以及我们从 DORA 社区中获得的经验。更多细节请参见“方法论”章节。

自 2024 年以来保持稳定的积极关联

自去年报告以来，多个结果继续与 AI 采纳保持积极关联。我们来列举一下：

- 更高水平的个人效能
- 更高水平的代码质量
- 更高水平的团队效能
- 更高水平的组织效能

这些持续的积极关系已经变得越来越常见。我们在此将它们视为基准现象，而非头条新闻，因为它们与去年的结果一致，也符合许多技术从业者的实际体验。

这些积极影响背后可能存在无数机制，其中许多可能与具体的组织、团队、环境和情境密切相关。

AI 可以通过以下方式帮助个人：

- 处理模板代码和其他重复性结构
- 快速提供合理的选项
- 输出高度针对问题的解决方案
- 汇总和整合大量分散的信息
- 完成更高阶的任务，如设计、规划和分析

这些个人层面的提升可能会相互叠加——小的成功在多人和多个周期中不断积累——最终惠及整个团队和组织。

顽固的结果提醒我们，AI 是嵌套在一个更大的系统中的

一些结果持续呈现出与 AI 之间不太理想的关系模式：

- 与“工作摩擦”无明显关系
- 与“职业倦怠”无明显关系
- AI 与“软件交付不稳定性”的增加相关联

我们认为这些效应之所以“顽固”，更多是因为个体所处的系统、流程和文化环境所致。目前来看，AI 的应用主要集中在“键盘端”，这可以解释为什么代码质量和生产力有所提升，但摩擦、职业倦怠和不稳定性却没有改善。这些问题可能超出了个体的控制范围，更直接地与组织的结构和运作方式相关。

我们将这些结果视为“社会技术系统”（即流程与文化结合体）的属性和后果。尽管 AI 带来了诸多益处，但如果周边的系统和文化不发生改变，摩擦依然存在、职业倦怠依然平稳、交付不稳定性依然上升。

摩擦阻力

虽然自动化重复性任务的工具看起来是简化工作流程的明确途径，但我们的数据表明，职场中的“摩擦”问题远比完成机械性任务复杂得多。正如我们之前指出的，一些研究认为摩擦是源于个体之外的流程问题。

2019 年，微软识别出影响员工“拥有美好一天”的流程问题，包括：

- 基础设施问题，例如“不稳定且缓慢的系统和工具”

- 过时的文档
- 行政负担
- 时间压力
- 重复性任务

他们的结论之一是，管理者应“优先考虑并针对性地改进流程和工具”。

例如，即使 AI 能帮助提高编码效率，如果流程效率低下，尤其是在无法应对变更量增加和新的工作方式时，这种优势可能会被抵消。

举例来说，如果变更量增加，但没有相应的流程演进（如更完善的验证机制、角色定义或“黄金路径”），则可能导致验证和协调成本上升。

然而，我们并不认为摩擦完全是系统性问题。对个体而言，摩擦并不会消失，而是发生了转移：从手动操作转向决策与验证，例如提示词迭代、结果审查，以及评估那些看起来几乎正确的代码。这种转变可能导致总体摩擦水平并未明显下降，尽管输出更具影响力，且部分机械性任务已实现自动化。



“我们了解到，当人工智能增强有才华的工程师的技能时，它能发挥最大效用。通过自动化那些繁琐、重复性的任务，人工智能让我们的开发人员得以专注于战略性问题的解决和创新。”

职业倦怠

虽然我们可能会认为提高生产力的工具能够缓解职业倦怠，但我们的研究发现，职业倦怠对技术解决方案具有顽固的抵抗力。职业倦怠很可能受到员工所处工作文化的深刻影响。

多年来，我们在自己的数据中也观察到了这一点。职业倦怠与领导力、优先事项的稳定性以及“生机型文化”密切相关。2017 年的一项元分析发现了一些反复出现的倦怠前因，包括：

- 工作支持度低
- 奖励机制不足
- 缺乏工作公平性
- 工作不安全感

即使 AI 能够减少职业倦怠，其效果也可能被文化的强大影响所掩盖。

此外，我们的定性研究也出现了一些明确信号，与“工作强化”相关的文献一致，表明在某些组织中，AI 辅助开发工具所带来的“能力提升”反而引发了更高的工作产出预期。在这些情况下，即使 AI 提高了个人效能，工作需求与资源之间的平衡仍未改变。



“软件开发确实因为 AI 而发生了变化，我从今年开始就明显感受到了。去年其实并没有太强烈的感觉。但我认为，随着 MCP（模型上下文协议服务器）的创新，以及能够与模型一起编程，这确实在很多方面带来了变化，比如功能发布、功能开发的时间线，以及在一定时间内可以完成的工作。

现在，利益相关方期望产品能更快地完成更多工作。因此，项目的截止时间变得更紧，工作方式也确实发生了变化。这让我有些担忧，因为我觉得他们被领导层，尤其是产品领导层，设定了一个非常紧迫的交付期限。

软件交付不稳定性

如果说 DORA 十一年来给我们带来了什么启示，那就是：一个组织的技术实践和流程与软件交付效能密切相关。缺乏这些基础能力可能会完全抵消 AI 所带来的任何收益。

例如，一个已经采纳了 AI 的团队，如果没有建立强大的软件交付流水线，且高度依赖其他团队来完成交付，仍然可能会经历交付不稳定。而我们的数据表明，AI 的采纳不仅未能解决不稳定性问题，当前反而与交付不稳定性的增加相关联。

也许这些技术能力比以往任何时候都更加重要，甚至需要更严格地遵循其原则。然而，也可能仅靠这些还不够。或许证据指向一个更具颠覆性的结论：这些技术能力和衡量方式已不再足够。它们必须为 AI 时代进行演进、被替代，或得到补充。

有人可能会认为，为了获得 AI 辅助开发所带来的吞吐量提升，交付不稳定性是可以接受的代价。其逻辑是，AI 辅助交付的速度和数量可以削弱不稳定性的负面影响，比如通过快速修复 bug 和更新，从而将对终端用户的影响降到最小。

然而，当我们将视角从纯粹的软件交付指标扩展出去时，这种观点就站不住脚了。为了验证这一说法，我们检查了 AI 采纳是否能减弱交付不稳定性对那些历史上受其影响的后果的伤害。

我们没有发现任何缓解效应的证据。相反，交付不稳定性仍然对关键结果（如产品效能和员工职业倦怠）产生显著的负面影响，这最终可能抵消吞吐量提升所带来的任何收益。

去年模式的变化表明正在 适应性调整

我们观察到与 2024 年的发现相比出现了一些变化：AI 与“有价值工作时间”的关系从负面转为正面 AI 与“软件交付吞吐量”的关系从负面转为正面 AI 与“产品效能”的关系从中性转为正面。

这些变化表明人员、团队和工具已经完成适应性调整。人们又多了一年时间来学习如何使用 AI，组织和团队也有了一年时间进行重构，而 AI 公司则有了一年时间来开发更好的模型和使用体验。

我们可以从工具本身开始说起。在许多基准测试中，AI 工具正在变得更强大。过去，要在自己的数据上微调一个预训练模型是一项复杂任务，需要深厚的机器学习专业知识，但现在，许多平台已经创建了简化的工作流程。

云服务提供商也开发了强大的工具，使你可以将私有的、专有的数据源（如客户数据库、内部文档和代码库）连接到微调流程中，而无需将这些数据暴露在公共互联网或基础模型提供商面前。

与此同时，组织使用 AI 的方式也在不断演进，这可能为 AI 在代码审查、测试生成、调试、代码重构、文档编写和错误修复等关键任务中提供了额外能力和保护机制。

个人和团队也可能开始理解 AI 在何时、何地、如何最有用。例如，人们可能正在学习将枯燥、重复的任务交给 AI，从而将更多时间用于解决问题、设计和创造性工作。这可以解释为什么 AI 的采纳开始预测（与去年的发现相反）更高比例的“有价值工作时间”。

确实，如果 AI 能处理编码流程中的一些繁重工作（如脚手架搭建、模板代码、常规转换），开发人员可能会有更多时间专注于代码部署，从而提高软件交付吞吐量，并最终改善产品效能。

我们也可能正在观察组织系统正在适应，形成更有利于 AI 的环境，从而使个人和团队能够更好地利用 AI，并让其带来的益处扩展到团队、产品和整个组织。

我们在《DORA 人工智能能力模型》和《AI 之镜》章节中探讨了一些可能的系统约束，这些约束可能有助于解释上述现象。

合理的疑问是：为什么某些效应受到了适应性的影响，而另一些却没有（例如软件交付不稳定性）。调查数据并不能很好地回答这个问题。这很可能是由于人们关注的重点不同、某些约束的显著性不同，以及某些问题本身的挑战性不同。这些因素可能导致不同的学习曲线。

“如果它能帮到我，或者能在 30 分钟内完成一项本来需要我两个小时甚至更久的工作，那就很好，因为我现在有了这段时间，可以去做其他事情。我可以做些不同的事，或者干脆做更多的事。所以，它也在某种程度上帮助我更快地在职业上取得进展，对吧？因为你也在更快地学习新东西。”



结论

在不同层面上，AI 对大多数结果都产生了积极影响，但也存在一些显著的例外：它与“职业倦怠”和“摩擦”之间没有可衡量的关系，并且仍然与“软件交付稳定性”呈负面关联。

将 2025 年的一些发现与去年的数据进行比较，我们可以感受到大语言模型、工具和工作流程正在随着人们和组织系统的互动而不断演进。人们已经找到了使用 AI 的方法，将精力转向他们认为更有价值的工作；我们也开始看到 AI 的采纳正在推动更高的软件交付吞吐量和更好的产品性能。

值得注意的是，AI 并没有让技术人员的所有问题都变得更好。一些问题的顽固持续存在——包括交付不稳定性的上升、摩擦和职业倦怠的持平——这不仅是工具本身的局限，更是系统未能围绕 AI 进行适应的结果。

这些效应的持续存在，与其说是 AI 的失败，不如说是个体所处组织系统的负担——也可能是这些系统未能适应新范式的表现。

我们相信，AI 的价值不会仅仅通过技术本身被释放，而是要通过重新构想它所嵌入的工作系统来实现。我们在《DORA 人工智能能力模型》和《AI 之镜》章节中对此进行了进一步探讨。

A 对专业开发者的社会认知影响

Daniella Villalba, 博士.
用户体验研究员, Google Cloud

DORA 的核心关注点是那些从事软件开发的人。开发者所处的工作环境在他们的工作体验中扮演着关键角色。随着组织重新调整优先事项、领导者寻找新的创新方式,以及 AI 越来越多地融入工作流程, AI 将深刻改变这一环境。AI 有潜力改变开发者所从事的工作类型以及他们所解决的问题范畴。

历史表明,技术进步可以深刻改变人们的思维模式。比如在 Uber 出现之前,付钱给陌生人乘坐他们的私家车几乎是不可想象的。但如今,美国和加拿大约有 3100 万人每月至少使用一次该服务。

专业开发者正处于这场由 AI 驱动的变革的前沿,我们的目标是记录他们在这过程中所经历的变化。

我们选择研究六个社会认知概念,以探索开发者如何看待自己与工作的关系:

- 真实的自豪感 (Authentic pride)
- 工作的意义 (Meaning of work)
- 认知需求 (Need for cognition)
- 存在性连接 (Existential connection)
- 心理所有权 (Psychological ownership)
- 技能重排序 (Skill reprioritization)

人工智能采纳指数与关键成果的标准化效应预估

点表示后验均值; 线条表示89%置信区间




图29: 人工智能采纳指数与关键成果的标准化效应预估

真实的自豪感

自豪感是一种基本情绪。当我们将某项成就归因于自身可控的行为时，就会感到自豪。例如，一个人在跑完马拉松后感到自豪，因为他知道自己为此付出了大量训练。这种掌控感和成就感让我们对自己感到满意，尤其是在掌握技能或完成困难任务时。

那么，为什么要在 AI 的背景下衡量自豪感？因为存在两种相反的假设，每种都具有重要意义：

1. 人们可能会过度依赖 AI，将工作自动化，从而减少努力获得成就的空间；
2. 或者，AI 可能释放人们的时间，让他们专注于更有价值的工作，并因此感到自豪。

我们的研究支持第二种假设：更高的 AI 采纳程度与更高水平的真实自豪感相关联（见图 29）。数据还揭示了一个清晰的机制：AI 采纳程度越高，个体花在有价值工作上的时间越多，而那些认为自己工作有价值的人报告的自豪感也更高。

这些发现表明，开发者学会将重复性任务移交 AI 后可能获得潜在益处：他们能掌控最宝贵的资产——时间，进而自由投入真正重要的项目与创意。

工作的意义

“工作的意义”指的是人们希望自己的职业生涯能用于做一些真正重要的事情。

研究表明，从工作中获得意义感的人拥有更高的幸福感和工作满意度。

1. 我们希望探讨 AI 的采纳是否影响专业开发者对其工作的意义感知。我们提出了两个假设：AI 通过自动化繁重任务，提升开发者从事有价值工作的时间，从而增强他们的意义感；
2. AI 干扰了开发者参与核心任务的能力，从而削弱了他们的意义感。

结果显示：AI 的采纳对开发者是否认为工作有意义没有明显影响。这可能是因为我们还处于转型的早期阶段，尚未观察到明显变化。

认知需求

AI 的出现为人们提供了减轻认知负担的快捷方式。一些学术研究表明，学生开发者在想“关闭大脑”时会使用 AI。

虽然有些人非常享受思考和解决问题的过程，但 AI 的“即刻答案”可能会削弱这种乐趣。复杂问题现在可以瞬间解决，这可能让部分人对“动脑”失去兴趣。

然而，我们的研究发现：AI 的采纳并未改变开发者对参与认知活动的需求。

存在性连接

“存在性连接”是指在自己的内心世界与他人的世界之间建立联系的感觉。哲学家威廉·詹姆斯曾指出，这种认知鸿沟使我们难以真正理解他人的体验。这个概念体现了我们与他人建立深层次人际联系的能力，让我们在观点上不再感到孤独。

我们之所以研究开发者的“存在性连接”，是因为 AI 的兴起可能会改变人们在工作中的互动方式。AI 能提供即时、个性化的答案，这可能减少开发者向同事寻求帮助的需求。虽然这提高了效率，但也可能导致交流减少，协作解决问题的机会变少。

我们曾担心，更多依赖 AI、减少人与人之间的互动，可能会削弱职场关系，让人感到更加孤立。然而，我们的研究未发现 AI 采纳与开发者的“存在性连接”之间存在关联。

这可能意味着目前还处于技术变革的早期阶段，尚未显现出影响。也可能是 AI 替代某些人际互动的同时，也创造了新的连接机会，比如帮助我们共享并扩展更广泛的集体知识基础。

心理所有权

“心理所有权”是指即使某物并不真正属于你，你仍然会觉得它是“你的”。这种感觉可以针对有形物品，也可以针对无形概念，比如自己的想法。许多开发者对自己编写的代码有强烈的归属感，我们想了解 AI 辅助编程是否会削弱这种个人所有感。

我们的研究结果显示，有 78% 的概率表明：AI 的采纳不会降低开发者对其工作的个人所有感。换句话说，当开发者使用 AI 辅助编程时，他们并不认为代码“不是自己的”。

这支持了一个观点：当前的 AI 工具更像是高级助手，而不是共享成果的协作者。因为 AI 被视为一种工具，而非共同创作者，开发者已经将其心理上整合进工作流程，就像使用编译器或代码检查工具一样。

不过，也存在 21% 的可能性表明 AI 会降低个人所有感（见图 30）。当开发者独立编写代码时，他们清楚自己是创作者；而当 AI 介入编程过程时，可能会模糊“谁在写”的界限，从而降低他们的投入感和控制感——这两者是产生心理所有权的关键心理路径。

所有权归属感




图30：所有权归属感

技能重排序

随着开发者越来越多地与 AI 协作，关于这种合作如何改变不同技能的重要性排序的讨论也在不断增加。我们希望研究 AI 的采纳是否影响开发者对哪些技能在工作中更重要的看法。

我们假设：与 AI 相关的技能以及以人为中心的技能，可能会被认为比传统的编程技能更重要。

我们请参与者对以下八项技能按重要性进行排序。

1. 编写技术文档
2. 解决问题的能力
3. 提示工程（Prompt Engineering）
4. 编程语言语法记忆
5. 阅读和审查代码
6. 团队合作与协作
7. 理解团队的代码库
8. 编写代码

结果显示，AI 的采纳确实影响了“提示工程”的重要性认知。同时，AI 的采纳也提高了“编程语言语法记忆”的重要性认知。

这个发现非常有趣，值得进一步研究，因为人们原本可能认为，在 AI 时代，语法记忆会是最先被视为“过时”的技能之一。

最令人惊讶的是：AI 的采纳并未影响其他任何技能的重要性认知。

我们尚不能对这些数据得出明确结论，因为可能存在多种解释。这些结果可能表明开发者正处于适应 AI 驱动工作流程的阶段，或者他们仍然认为自身的专业技能在未来仍不可或缺。

总结与建议

综合来看，这些发现表明：AI 的采纳尚未显著改变开发者的工作体验。我们将继续积极监测这一领域的变化。

与此同时，我们建议组织给予开发者更多自由，让他们专注于自己认为有价值的工作。继续创造机会，让开发者学习如何有效利用 AI，从而将繁重任务交给 AI，腾出时间专注于更有意义的工作。

为了防止心理所有权的潜在下降，我们建议开发者将 AI 视为为他们服务的工具。即使这项技术变得越来越自主，也必须让开发者始终意识到：他们才是掌控方向的人。

1. 我们采纳了经过学界验证的真实自豪感测量量表。Tracy, Jessica L., Joey T. Cheng, Richard W. Robins, and Kali H. Trzesniewski. 《真实与傲慢的自豪感：自尊与自恋的情感核心》.《自我与同一性》，第 8 卷 2-3 期(2009):196-213 页.
2. Steger, Michael F., Bryan J. Dik, and Ryan D. Duffy. “《测量有意义的工作：工作意义量表(WAMI)》”.《职业评估杂志》2012, 20 卷, 第 3 期. 322 - 337 页.
3. Schmidt, Dusana Alshatti, et. al. 《高等教育中人工智能的融合：学术创新的认知、挑战与策略》，《计算机与教育开放期刊》，第 9 卷 (2025). <https://www.sciencedirect.com/science/article/pii/S2666557325000333>
4. Cacioppo, John T., and Richard E. Petty. 《认知需求》，《人格与社会心理学杂志》1982 年第 42 卷第 1 期, 116 - 131 页
5. Pinel, Elizabeth C., Anson E. Long, Erin Q. Murdoch, and Peter Helm. , 《心灵的囚徒：存在性孤独的识别与理解》，《人格与个体差异》105 卷 (2017 年) : 54-63 页
6. Peck, Joann, and Suzanne B. Shu. 《心理所有权与占有感》，载柯蒂斯·P. 豪特维特等编《消费者心理学 SAGE 手册》（塞奇出版社，2009 年），

1. 2025 Stack Overflow Developer Survey. <https://survey.stackoverflow.co/2025>
2. "Atlassian research: AI adoption is rising, but friction persists." <https://www.atlassian.com/blog/developer/developer-experience-report-2025>
3. "AI Adoption Starts at the Top: 3x more C-suites on LinkedIn are adding AI literacy skills compared to two years ago." <https://news.linkedin.com/2025/ai-adoption-starts-at-the-top-3x-more-c-suites-on-linkedin-are->
4. "The state of AI: How organizations are rewiring to capture value." <https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai>
5. The 2025 AI Index Report. <https://hai.stanford.edu/ai-index/2025-ai-index-report>, 247. Sourcing quid 2024.
6. Ibid, 228. Sourced from Lightcast data.
7. Accelerate State of DevOps 2024. <https://dora.dev/dora-report-2024>
8. "Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity." <https://metr.org/blog/2025-07-10-early-2025-ai-experienced-os-dev-study>
9. "ChatGPT May Be Eroding Critical Thinking Skills, According to a New MIT Study." <https://time.com/7295195/ai-chatgpt-google-learning-school>
10. Gerlich, Michael. "AI Tools in Society: Impacts on Cognitive Offloading and the Future of Critical Thinking." *Societies*, 2025, 15, no. 1. Article 6. <https://www.mdpi.com/2075-4698/15/1/6>
11. "The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers." https://www.microsoft.com/en-us/research/wp-content/uploads/2025/01/lee_2025_ai_critical_thinking_survey.pdf
12. Forsgren, Nicole, Margaret-Anne Storey and Chandra Maddila. "The SPACE of Developer Productivity: There's more to it than you think." <https://queue.acm.org/detail.cfm?id=3454124>
13. "The SPACE of AI: Real-World Lessons on AI's Impact on Developers." <https://arxiv.org/pdf/2508.00178>
14. Quantitative Developmental Systems Methodology Core, Penn State. "Intro - Basic Exploratory Factor Analysis." <https://quantdev.srri.psu.edu/tutorials/intro-basic-exploratory-factor-analysis>
15. Lee, John D., and Katrina A. See. "Trust in automation: Designing for appropriate reliance." *Human factors* 46, no. 1 (2004): 50-80.
16. Cody-Allen, Erin, and Rajiv Kishore. "An extension of the UTAUT model with e-quality, trust, and satisfaction constructs." In *Proceedings of the 2006 ACM SIGMIS CPR conference on computer personnel research: Forty four years of computer personnel research: achievements, challenges & the future*, pp. 82-89. 2006.
17. Reliance is often considered a behavioral manifestation of trust: "Trust in Automation: Integrating Empirical Evidence on Factors that Influence Trust".
18. J. J. Po-An Hsieh and Wei Wang, "Explaining Employees' Extended Use of Complex Information Systems," *European Journal of Information Systems* 16, no. 3 (2007): 216-27.
19. Adoption is dynamic, but given we have a snapshot, we're treating these highly co-determinant phenomena as unidimensional. If we had panel data, we could be more explicit about the cycle.
20. Last year, we spoke in terms of "effects". This year, however, we will speak in terms of comparisons. Although we try to do the work to create the conditions to speak causally, we don't want to give false assurances that we understand the underlying causal structure. Occasionally we will speak in causal terms, but ultimately, we're doing comparisons. This reasoning is summed up in *Regression and Other Stories*: "Strictly speaking, though, it is inappropriate to label these as 'effects' — at least, not without a lot of assumptions ... what is observed is an observational pattern ... These data allow between-people comparisons ... The safest interpretation of a regression is as a comparison ... regression is a mathematical tool for making predictions. Regression coefficients can sometimes be interpreted as effects, but they can always be interpreted as average comparisons." Vehtari, Aki, Andrew Gelman and Jennifer Hill, *Regression and Other Stories* (Cambridge University Press, 2020), 84-85.
21. Following the form suggested in *Regression and Other Stories*, 85.
22. Technically a standardized beta weight.
23. Technically, these are standardized beta weights, which equates to the estimated standard deviation difference in the outcome associated with a standard deviation increase in AI adoption.
24. Our dataset is limited, so they're not strictly identical, but they're identical in aspects we consider important to blocking biasing pathways.
25. Bauer, Jared. "Does GitHub Copilot Improve Code Quality? Here's What the Data Says." *The GitHub Blog*. November 18, 2024. Updated February 6, 2025. <https://github.blog/news-insights/research/does-github-copilot-improve-code-quality-heres-what-the-data-says/>
26. This was called "productivity" last year. The measure differs slightly and "individual effectiveness" is a more accurate label.
27. Meyer, André N., Earl T. Barr, Christian Bird, and Thomas Zimmermann. "Today was a good day: The daily life of software developers." *IEEE Transactions on Software Engineering*, 2019, 47, no. 5. (2019): 863—880.
28. Focus time effectiveness of computer assisted protected time for well-being and work engagement of information workers.
29. "Ironies of automation." <https://www.sciencedirect.com/science/article/abs/pii/S0005109883900468>
30. Arnold B. Bakker, Evangelia Demerouti, and Ana I. Sanz-Vergel, "Job Demands-Resources Theory: Ten Years Later," *Annual Review of Organizational Psychology and Organizational Behavior* 10 (2023): 25-53.
31. Accelerate State of DevOps 2024. <https://dora.dev/dora-report-2024>
32. Aronsson, Gunnar, Töres Theorell, Tom Grape, Anne Hammarström, Christer Hogstedt, Ina Marteinsdottir, Ingmar Skoog, Lil Träskman-Bendz, and Charlotte Hall. "A systematic review including meta-analysis of work environment and burnout symptoms." *BMC Public Health*, 2017, 17, no. 1. 264.
33. Work intensification: A systematic review of studies from 1989 to 2022.
34. "Technical Performance | The 2025 AI Index Report | Stanford HAI." <https://hai.stanford.edu/ai-index/2025-ai-index-report/technical-performance>
35. The 2025 AI index Report by Stanford HAI has a lot of benchmark examples from 2023 to 2024. Nature pushes against AI benchmarks: <https://www.nature.com/articles/d41586-025-02462-5>
36. "Technical Performance | The 2025 AI Index Report | Stanford HAI." <https://hai.stanford.edu/ai-index/2025-ai-index-report/technical-performance>
37. The Imarena Overview Leaderboard (<https://lmarena.ai/leaderboard>) shows newer models at the top.



DORA 人工智能能力模型

Kevin M. Storer, 博士.

用户体验研究员, Google Cloud

Derek DeBellis

定量用户体验研究员, Google Cloud

Nathen Harvey

DORA 负责人, Google Cloud

OEcon 翻译出品
保留所有权利, 禁止商用

DORA 长期以来不仅致力于描述软件交付的现状，更致力于帮助组织基于数据做出决策，以应对不断变化的开发工具、方法及技术环境。人工智能正深刻改变软件开发格局。虽然技术的飞速进步带来了诸多令人振奋的可能性，但也引发了关于软件开发应如何演进才能最好地适应当前形势的新思考。

因此，今年我们不仅关注‘谁在采纳 AI’及‘如何使用 AI’，更深入探究了在何种条件下，AI 辅助的开发者能获得最佳成效。

我们将这些发现整合为首个 DORA 人工智能能力模型。该首版模型中的七项 AI 能力被证实能放大 AI 技术采纳的效益。研究显示，这些能力涵盖组织的技术及文化层面，投资发展这些领域有助于释放 AI 工具的潜能。

与 DORA 核心模型相同我们将通过持续研究对 DORA 人工智能能力模型进行验证、修订和完善。我们热切期待与 DORA 社区分享未来的迭代成果。

人工智能能力

基于 78 次深度访谈、领域权威专家的专业意见及既往 DORA 研究，我们通过假设性推演构建了广泛的能力维度模型，旨在提升 AI 辅助开发团队的工作成效。

经过多轮论证与优先级评估，本年度调研最终选定 15 项候选能力作为初始评估指标。其中七项 AI 能力展现出与 AI 应用显著的协同效应——当团队将这些能力与 AI 技术采纳相结合时，人工智能在关键成果领域的影响效力显著增强。

这七大能力构成了我们新模型的核心

 明确且已共识的人工智能立场	 小批量工作
 健康的数据生态系统	 以用户为中心
 人工智能可访问的内部数据	 高质量的内部平台
 稳健的版本控制实践	



明确且已共识的人工智能立场


“所谓‘清晰且充分传达的 AI 政策立场’，是指开发者能够明确理解并知晓组织对其使用 AI 辅助开发工具的官方立场及许可范围。我们对清晰传达的 AI 政策立场的衡量标准是单一维度指标，包含四项独

立评估要素，用于衡量受访者对于以下方面的感知：

1. 在工作中使用 AI 的需求程度；
2. 所在组织支持开发者尝试 AI 技术的程度；
3. 明确获准使用 AI 工具的范围；
4. 所在组织 AI 政策与自身工作的相关程度。

由此可见，一个拥有清晰且已传达的人工智能立场的组织，会积极鼓励并期望其开发者运用 AI 技术，支持其开发者在工作中尝试使用人工智能技术，并明确规定哪些 AI 工具允许使用及其 AI 政策对员工的适用范围。


明确且已共识的人工智能立场能调节人工智能对个体效能的影响



明确且已共识的人工智能立场

图31：明确且已共识的人工智能立场调节人工智能对个体效能的影响

明确且已共识的人工智能立场决定人工智能对组织效能的影响



明确且已共识的人工智能立场

图32：明确且已共识的人工智能立场决定人工智能对组织效能的影响

明确且已共识的人工智能立场可调节人工智能对摩擦的影响




图33：明确且已共识的人工智能立场可调节人工智能对摩擦的影响

明确且已共识的人工智能立场可调节人工智能在近期工作日使用中对吞吐量的影响



图34：明确且已共识的人工智能立场可调节人工智能在近期工作日使用中对吞吐量的影响

我们以高度确定性发现：AI 技术采用的积极效益取决于组织是否具备明确且已共识的人工智能立场。当组织满足该条件时：

1. 人工智能对个体效能的积极影响将显著增强；
2. 人工智能对报告的组织效能的积极影响被放大；
3. 人工智能对摩擦的中性效应转变为有益效应，并显示可减少摩擦；

在确定性较低的情况下，我们还发现：当存在明确且共识到位的人工智能立场时：

1. 人工智能对软件交付吞吐量的积极影响会被放大。

在我们今年开展的深度访谈中，开发人员普遍且一致地表示，他们对所在组织在软件开发中使用人工智能的立场缺乏清晰认知与了解。

重要的是，这种认知缺失可能表现为：

- 1) 开发者行为过于保守，因担心超出组织可接受使用范围而未能充分利用人工智能；
- 2) 开发者行为过于放任，以超出组织可接受范围的方式不当使用人工智能。

这两种情况都不理想。

因此，我们曾分享过这些定性见解 并得出结论：当组织对人工智能在软件开发中的预期与可接受性确立明确的立场并有效传达时：

1. 有助于培养开发者对 AI 的信任度；
2. 在开发者对数据隐私存在无根据或源于误解的担忧时缓解其顾虑；
3. 推动 AI 辅助开发工具在整个组织范围内的规模化应用。

最新调研结果印证了我们的建议——即组织应着力明确其对人工智能辅助开发的立场，并将该立场传达给软件开发人员；同时，这些结果也证明了采取这一做法。

能为个人、团队及组织带来可衡量的积极效应。值得注意的是，该 AI 能力评估的是企业对软件开发中 AI 应用立场的清晰度与认知度——而非具体政策内容本身。这意味着各组织和团队可根据其行业特性、职能定位及数据基础设施等独特需求，自主决定适合的 AI 应用策略。

只要企业能清晰阐述其 AI 应用立场并充分传达给开发者团队，就能在软件开发流程的 AI 化转型中获得更显著的积极成效。

“为什么[我]没有早点尝试[AI]呢？部分原因可能是‘不知道 团队和管理层会如何看待此事’的心理负担……当时没人讨论这个话题。因此我并不担心‘会 因此惹上麻烦’”。

但另一方面也存在顾虑：‘我不太确定这种做法是否会受到鼓励，也不确定公司是否希望我们 继续使用 AI 。’我也不想偷偷摸摸地使用人工智能。我们公司确实制定了 AI 政策，但其核心在于规范可输入的信息范围以保护客户机密，诸如此类的事项。不过我认为如果获得明确鼓励，我可能会将其应用于更多日常性开发任务。





健康的数据生态系统

“健康的数据生态系统”指企业内数据系统的整体质量。在我们的分析框架中，数据生态系统健康度作为单一因子衡量，由三项独立指标构成，分别评估受访者对以下维度的感知：

- 1. 内部数据源的整体质量；
- 2. 内部数据源的可访问性；
- 3. 内部数据源的孤岛化或彼此割裂程度。


据此可理解为：拥有健康数据生态系统的企业，其内部数据应具备高质量、易获取且高度整合的特征。

我们高度确信：AI 技术采纳产生的积极效益取决于企业是否拥有健康的数据生态系统。当该条件满足时，AI 对组织效能表现的正面影响将显著增强。

人们常说，人工智能模型的性能取决于其训练数据的质量（即“数据质量决定模型优劣”）。

本研究表明，这一传统认知似乎同样适用于组织内部的局部层面。

当组织投入资源创建并维护高质量、可访问、统一的数据生态系统时，其所能带来的组织效能提升将超越单纯采纳 AI 技术所产生的效益。





人工智能可访问的内部数据

“AI 可访问的内部数据”指 AI 工具与组织内部数据源及系统实现连接的程度。该指标通过四个独立维度构成的单一因子进行测量，涵盖受访者以下方面的反馈：

1. 对工作中使用的 AI 工具可获取内部公司信息的感知度；
2. 对 AI 工具响应结果是否基于内部公司信息作为背景的感知度；
3. 向 AI 工具输入提示词时使用内部公司信息的频率；
4. 以及利用 AI 工具检索内部公司信息的频率。

因此，具备 AI 可访问内部数据的组织可理解为：员工观察到内部数据可被 AI 系统获取，并主动使用 AI 工具访问和处理这些数据。


我们高度确信地发现，AI 技术采纳的积极效益取决于组织是否拥有 AI 可访问的内部数据。当满足此条件时：

1. AI 对个体效能的积极影响将显著增强；
2. AI 对代码质量的积极影响亦将显著增强。

虽然基于通用知识库训练的 AI 工具有助于开发者提升效能并产出更高质量的代码，但研究表明：当 AI 能够访问内部数据源，使开发者能为 AI 工具提供企业特定上下文时，AI 在实现上述目标方面能产生更大的影响。

这也意味着，投入时间将 AI 工具与内部系统连接的组织，可能比依赖通用基础模型提供非专业化知识的组织获得更优的结果。

换言之，要最大化 AI 在个体效能和代码质量方面的效益，仅采购 AI 许可证远远不够，还需进行更深层次的投入。从某些角度看，这一发现并不意外——若 AI 无法访问企业内部数据，其实际作用究竟能真正发挥多大？



人工智能可访问的内部数据调节人工智能对代码质量的影响




图37：人工智能可访问的内部数据对人工智能代码质量影响的调节作用

“我认为当前多数客户尚未达到能有效运行任何人工智能系统的阶段...他们甚至未实现数据的规范化管理...数据分散在公司各处，缺乏统一存储系统或标准格式。”“若想应用人工智能，实际上需要大量数据工程工作——绝非少量——将数据重构为生成式人工智能系统可处理的形态。”“我感觉许多公司根本未达到能有效运用该技术的阶段。”



稳健的版本控制实践

健全的版本控制实践长期以来一直是高性能软件开发团队的基石。这些工具提供了系统化的方法，用于管理代码及其他数字资产随时间推移所产生的变更。

在生成式人工智能时代，代码生成的数量和速度急剧提升，这些实践的重要性愈发凸显。我们的研究表明，成熟的

版本控制习惯与AI技术采纳之间存在强大的协同作用，突显了这些实践对于最大化人工智能效益同时规避风险的关键意义。

我们高度确信，AI技术采纳的积极效益取决于受访者执行版本控制提交的频率。具体而言，在频繁提交的情况下，AI对个体效能的积极影响会显著增强。

此外，我们发现AI技术采纳的积极效益取决于受访者使用版本控制系统‘回滚’功能以撤销或恢复变更的频率。

具体而言，当回滚操作更频繁时，AI对团队效能表现的积极影响将得到放大。



成熟版本控制系统的核心价值在于其作为“心理安全屏障”的功能。该机制使开发团队能够自信地进行实验创新，因为他们深知若出现问题，可随时轻松恢复到稳定状态。最典型的例证便是对回滚功能的依赖性。快速且无繁琐操作地撤销变更不仅带来便利，更是提升开发速度与系统韧性的关键保障。

人工智能生成代码的速度或许能让开发人员感觉工作效率更高。

但是，正如我们在《探索人工智能与关键成果的关系》这一章节中所探讨的，使用人工智能使用亦伴随着更高程度的软件不稳定性。

我们提出了一个假设：造成这一现象的原因，部分可能在于审查大批量代码的难度更高。

因此，尽管依赖回滚机制并不能直接降低不稳定性，但我们推测其对 AI 辅助团队效能的积极影响，可能源于：在处理大批量代码时，以及面对这些代码可能引发的不稳定性时，能够快速撤销变更具有重要意义。





小批量工作模式

“「小批量工作模式」⁶ 作为 DORA 长期能力项，指团队将变更分解 为可快速测试评估的可管理单元的程度。

该能力通过单一维度衡量，包含三项指标：

1. 受访者主要应用/服务最近变更提交的代码行数近似值；
2. 单个发布或部署中通常包含的变更数量；
3. 开发者完成单项任务所分配工作所需时长。

在采纳小批量工作模式方面得分更高的团队，其每次变更提交的代码行数更少，每次发布的变更次数更少，且分配的工作能在更短时间。

我们高度确信：人工智能采纳的积极效益取决于团队是否采纳小批量工作模式——当团队采纳该模式时：

1. 人工智能对产品效能的积极影响会显著增强；
2. 人工智能对摩擦的中性效应转变为有益效应，并显示可减少摩擦反之我们也发现，在采纳小批量工作模式的团队中，人工智能采纳对个体效能的提升作用略有减弱。

尽管这些结果存在差异，但我们认为整体而言，它们表明小批量工作模式对 AI 辅助团队具有净正向影响。观察到的现象—— 在小批量工作中 AI 对个体效能提升的增幅有所降低——印证了我们的基本理论：人工智能主要通过帮助开发者快速生成大量代码，从而增强其对个体效能的感知。

对于优先采纳小批量工作模式的团队，个体效能提升幅度相对较小是符合逻辑的。

更重要的是，我们认为个体效能本身不应必然成为追求目标。个体效能实则是实现更优组织效能、团队效能、产品效能以及提升开发者幸福感的手段。

在此情境下，小批量工作模式既能提升报告的产品效能，又可降低人工智能辅助团队的感知摩擦。我们认为这些效益远超小批次工作对个体效能的潜在负面影响——此外，作为 DORA 核心模型长期验证的优势，小批次工作模式的其他益处亦不容忽视。⁷

批次规模对人工智能影响产品效能的调节作用




图40：批次规模对人工智能影响产品效能的调节作用

批次规模对人工智能影响个体效能的调节作用




图41：批次规模对人工智能影响个体效能的调节作用

批次规模对人工智能影响摩擦的调节作用




图42：批次规模对人工智能影响摩擦的调节作用



以用户为中心

以用户为中心的关注点”也是我们历年调查中持续采纳的衡量指标。所谓以用户为中心的关注点，指的是团队在思考其核心应用程序或服务时，对终端用户体验的重视程度。

受访者的用户中心化关注程度通过单一因子测量，该因子包含三项李克特七级量表指标（Likert scale），用于评估受访者对以下陈述的认同程度：

1. 为用户创造价值是他们的核心关注点；
2. 用户体验是其首要任务；
3. 聚焦用户是业务成功的关键。

由此可见，具备用户中心化关注的团队会优先考虑用户体验，并理解其与业务成功的关联性。

我们以高度确定性发现：人工智能采纳的效果取决于团队是否具备用户中心化的关注点。具体而言，当具备用户中心化的关注点团队采纳AI技术时，AI对团队效能表现的积极影响会显著增强。

重要的是，我们还发现：若缺乏用户为中心关注点，人工智能采纳将对团队效能产生负面效应。

综合来看，这些发现表明：投资培养以用户为中心的理念可为AI辅助团队的效能表现带来重要收益——若未能做到这一点则可能适得其反。缺乏用户导向的核心理念，AI采纳未必能帮助团队，甚至可能带来负面影响。

我们长期认为，以用户为中心的聚焦能帮助团队厘清目标并形成统一战略方向，此时用户体验将发挥北极星般的指引作用。这一原则对AI辅助开发团队尤为重要；当团队以用户为核心时，AI技术采纳能带来倍增效益；反之，若忽视用户需求，AI应用则会产生负面效应。

这些研究结果表明：鼓励采用AI技术的组织若能深度理解终端用户需求、目标及反馈，并将其融入产品路线图与战略规划，必将获得显著收益。同时它们也发出重要警示：

若缺乏以满足终端用户需求为核心的导向机制，AI采纳反而会损害团队效能表现。

“100%这就是我在此坚守五年的原因——我感受到自己在从事有意义的事业，帮助普通人。因此，即使只为一个人付出，对我而言也意义非凡。但在这里，我服务的是数百万用户……当遭遇情绪低谷时，只要想到所做之事皆为此目标，这个念头便能极大改善我的状态，并驱使我持续工作——仅凭开发这个小功能，今年就能帮助十万用户。”

以用户为中心的态度可调节人工智能对团队效能表现的影响




图43:用户中心化态度调节人工智能对团队效能的影响



“关键顿悟时刻在于认识到：临床医生需要的不是更多工具，而是减少信息干扰。我们最初的假设是：为临床医生提供更先进的功能才能创造价值。然而实际发现恰恰相反技术的简洁性与无感化才是真正的创新。相较于纯自动化系统，人机协同的混合模式在准确性、共情力和信任度层面均展现出显著优势。”





高质量的内部平台

理解高质量内部平台的价值一直是我们既往调研的重要组成部分。本。“平台”指的是一组可在多个应用程序或服务间共享的能力集合，其核心目的是让这些能力在整个组织内部实现广泛复用。

这些平台的质量通过单一评分进行量化该评分表明受访者认为其内部平台具备 12 项特征中的多少项。完整的高质量内部平台特征定义清单，请参阅附录。

我们高度确信，AI 采纳的效果取决于组织是否拥有高质量内部平台，具体而言，在具备

高质量内部平台的组织中，AI 对组织效能的积极影响会显著增强。

相反，我们发现人工智能对受访者所报告摩擦体验的中性效应反而产生了危害。这表明，在拥有优质内部平台的组织中，受访者反而感受到更多摩擦阻力。

尽管结果呈现矛盾性，但我们认为总体而言，这些发现证明了优质内部平台对人工智能辅助团队具有净积极影响。

虽然优质内部平台通过提供统一能力集提升个体效能——使开发团队能轻松在此基础上进行构建，但其设立的标准也可能限定开发工具的使用边界。例如通过定义仅限内部使用的 API（应用程序编程接口），这类 API 的安全控制措施会比外部 API 更严格。

由此，优质内部平台既能通过开放所需功能提升效能，亦能通过限制不良功能发挥作用。

由于目前针对人工智能辅助开发工具的使用，我们尚未形成一套标准化的最佳实践，因此我们提出假设：在该领域，优质内部平台产生的影响可能以后者为主——防止不当使用。这可以解释为何大量采用人工智能的团队会面临摩擦增加的现象，而这种摩擦对组织而言未必是负面结果。

基于上述原因，且考虑到其对组织效能的增益作用，我们认为对于需要在人工智能辅助环境下成功开展软件开发工作的组织而言，设计和维护高质量的内部开发平台，是一项至关重要的能力。

内部平台调节人工智能对组织效能的影响





图44：内部平台调节人工智能对组织效能的影响

DORA 人工智能能力模型

实践应用



本章研究结果表明，在软件开发中成功利用人工智能并非简单采纳新工具即可实现。相反，组织必须培育特定的技术文化环境才能获得最大收益。



基于 DORA 七项人工智能能力，以下是具体实践建议：

明确且已共识的人工智能立场

人工智能政策的模糊性会阻碍应用并滋生风险。制定并宣导明确的可使用工具及规范政策，以此建立开发者信任度。这种明确性为有效实验提供了必要的心理安全感，从而减少摩擦，并增强人工智能对个体效能和组织效能的积极影响。

健康的数据生态系统

人工智能对组织效能的裨益在健康的数据生态系统中将得到显著放大。加大对内部数据源的质量、可访问性及一致性的投入。当 AI 工具能够从高质量内部数据中学习时，其对组织的价值将同步提升。

人工智能可访问的内部数据

将 AI 工具与内部系统对接，突破通用辅助功能局限，实现个体效能与代码质量的双重飞跃。这意味着不仅要采购许可证，更需投入工程资源确保 AI 工具能安全访问内部文档、代码库及其他数据源。此举为工具注入了企业专属场景认知，使其效能最大化。

稳健的版本控制实践

AI 辅助编程虽能提升变更的体量与速度，但也可能引发更多不稳定性。版本控制系统是关键的安全网。应鼓励团队精通回滚与恢复功能的使用，因为在 AI 辅助环境中，这一做法与更优的团队效能表现密切相关。

小批量工作

尽管 AI 通过大量生成代码能提升个体效能感知，但我们的研究表明这并非最关键指标。应聚焦实际产出成果。推行小批量开发的规范，既能提升产品效能，又可减少 AI 辅助团队的协作摩擦。

以用户为中心

采纳人工智能技术后，个人效能可能获得大幅提升。但如果开发者不关注用户需求，他们的快速推进可能偏离正确方向。我们发现，采纳 AI 辅助开发工具可能对缺乏用户中心意识的团队产生负面影响。反之，将用户需求作为产品的北极星，能够引导 AI 辅助开发者瞄准正确目标，并对使用 AI 的团队效能表现产生极其显著的积极影响。

高质量的内部平台

高质量的内部平台是放大人工智能对组织效能表现积极影响的关键推动因素。这些平台提供必要的防护机制和共享能力，使人工智能效益得以在整个组织中安全高效地扩展。

1. 《DORA 研究计划》 <https://dora.dev/research>
2. 《培养开发者对生成式人工智能的信任度》 <https://dora.dev/research/ai/trust-in-ai>
3. 《超越人工智能输出准确性的关切》 <https://dora.dev/research/ai/concerns-beyond-accuracy-of-ai-output>
4. 《助力开发者采纳生成式人工智能：组织的四项实践策略》 <https://dora.dev/research/ai/adopt-gen-ai>
5. 《小批量工作模式》” <https://dora.dev/capabilities/working-in-small-batches>
6. 《DORA 研究计划》.” <https://dora.dev/research>

平台工程

Eric Maxwell

Google Cloud, Technology 部门负责人

Benjamin Good

Google Cloud, 平台工程负责人



在 2024 年报告中，我们首次深入探讨了企业内部平台工程对软件交付方面有关效能的影响。研究发现，平台工程对组织效能和生产力的提升具备积极影响。但是，得到上述积极的影响是有代价的：随之而来的是，软件交付的不稳定性在增加，吞吐量也在降低。

今年的研究不仅验证了平台工程的价值，更深入探究了一个成功的平台工程是如何进行运作以及如何创造价值。数据显示，平台工程绝非简单的工具堆砌，而是一种整体的全局性的体验，直接影响组织效能、员工幸福感以及组织利用变革性技术的能力。研究发现，用户将平台工程视为有机整体，其整体有效性比平台工程中任何单个功能的能力更重要。

本章将详细阐述定义平台工程状态的关键模式，从普遍采纳和团队结构到平台工程作为创新和风险管理战略基础的关键作用。

我们的重要发现

平台工程普遍被采纳：90%。

专职平台工程团队是目前主流的组织模式，占比高达 76%。这一现状使领导力的核心挑战从技术应用转向对多团队协作体系的有效治理。

一个优质的平台工程能够增强应用 AI 对组织效能的积极影响。因为当平台质量较高时，AI 对组织效能的促进作用会更为显著。

一个优质的平台工程如同力量倍增器，能够显著提升组织效能、工作效率与团队幸福感，实现多方共赢。

平台工程应被视为支撑卓越开发体验的有效载体。

平台工程的核心功能是作为风险管理引擎，在保障安全的同时提升开发速度并支持实验创新-即便这可能意味着软件交付稳定性会出现轻微但可预见的波动，但这正是为实现更高整体效能而作出的可控权衡。

平台工程的生态格局呈现三大特征： 无处不在的普及性、高度复杂的系统性， 以及由团队主导的驱动模式

当前，绝大多数企业已部署本地化的平台工程，这表明行业讨论的焦点已从“是否需要平台”转向“如何构建平台”。数据显示，高达 90%的企业已应用至少一个平台，其中 29%的企业正采纳多平台并行的运作模式。

如今，76%的企业已设立至少一个专职平台工程团队，

超过四分之一的受访者（29%）所在企业拥有多个平台工程团队。这种多平台与多团队并存的常态，与其说是工具冗余的体现，不如意味着企业正告别“一刀切”的模式，转而构建联盟式专业平台与团队，以适配不同的业务领域和技术栈。


管理层面临的挑战已从单纯“搭建平台”升级为“治理多元平台的复杂生态系统”。

与应用程序类似，平台建设同样需要引入 DORA 研发效能模型中的松散耦合团队能力——通过为各团队确立清晰的权责边界与协作接口，确保平台生态持续优化开发者体验，而非制造新的组织壁垒。

整体体验才是决定性因素

我们邀请受访者根据平台各项功能的实现效果进行评分。例如：“该平台能有效协助我构建和运行安全的应用程序及服务。”

调研发现存在明显的体验差距：平台在“提升系统可靠性与安全性”等核心技术功能方面获得较高评价，但在“反馈响应机制”和“任务自动化水平”等用户体验维度的表现稍显不足。



开发者对平台的整体印象——无论是将其视为得力助手还是矛盾来源——都会显著影响其对每个具体功能的评分。各功能项得分的紧密聚集表明，受访者并非将平台视为零散部件的简单堆砌，而是将其作为一个有机整体来体验。	这种体验差距很可能折射出“技术先行”的平台建设模式。 数据表明，若不能妥善解决用户体验问题，平台便无法释放其全部价值。	将平台视为产品的思维模式——即把内部开发工具当作产品来运营，将开发者视为核心用户——能持续确保以用户为中心，这正是 2024 年报告的重要发现。
--	--	--

用户为中心是避免内部开发者平台建设常见陷阱的关键方法，例如：

“建好自然有人用”的误区： 某个团队仅凭主观猜测开发者的需求构建平台，未进行用户调研、访谈或需求验证。他们完全专注于技术实现，假设平台价值会不言自明。 - 失败根源： 此类平台最终沦为“鬼城”，因为它既未解决开发者的实际痛点，也无法融入其现有工作流程。 - 产品化解决方案 以开发者同理心和需求挖掘为起点。平台团队持续与用户互动，深入理解其核心挑战，确保构建的功能是用户真正需要且愿意使用的。	- 工单运维陷阱 平台团队像基础设施“自动售货机”般运作：既缺乏愿景规划也没有发展路线图，工作完全被动响应开发者源源不断的工单（例如“请配置数据库”“搭建 CI/CD 流水线”）。 - 失败根源 这种模式既形成流程瓶颈，又给平台团队和开发者带来重复劳动。团队疲于处理零散需求，永远无法腾出精力构建 连贯 的自助服务能力。 - 产品化解决方案 聚焦建设具有清晰路线图的自助化平台。通过提供自动化、可复用的标准化工具，赋能开发者自主配置资源，从根本上消除工单排队现象。	- 象牙塔式平台陷阱 平台团队以高高在上的姿态单方面规定平台架构与工具标准，通过刚性规范强制执行，缺乏协作机制与反馈闭环。他们扮演的是技术守门人而非开发者赋能者的角色。 - 失败根源 这种方式会让开发者产生被动感，往往催生影子 IT 或非正式解决方案来规避平台限制，最终违背平台建设初衷。 - 产品化解决方案 设立平台产品经理角色，主动收集反馈并将开发者视为客户。平台设计重在赋能而非限制，提供便捷易用的标准化路径（Paved Roads），鼓励自愿使用而非强制服从。
--	--	--

平台能力相关性矩阵

	帮助构建可靠的应用程序	帮助构建安全的应用程序	任务自动化程度较好	消除基础设施复杂性	可以预期的行为	对任务给出明确反馈	提供支持独立工作的工具集	团队积极落实用户反馈	易于使用	用户界面直观简洁
帮助遵循所需流程	0.46	0.51	0.51	0.52	0.47	0.56	0.40	0.39	0.45	0.41
帮助构建可靠的应用程序		0.58	0.60	0.52	0.54	0.60	0.54	0.45	0.49	0.48
帮助构建安全的应用程序			0.49	0.49	0.51	0.61	0.53	0.47	0.51	0.44
任务自动化程度较好				0.49	0.54	0.62	0.51	0.50	0.50	0.43
消除基础设施复杂性					0.51	0.62	0.49	0.41	0.50	0.50
可以预期的行为						0.63	0.54	0.54	0.57	0.47
对任务给出明确反馈							0.62	0.60	0.66	0.65
提供支持独立工作的工具集								0.47	0.58	0.51
团队积极落实用户反馈									0.51	0.45
易于使用										0.71

图47：平台能力相关性矩阵

在分析各项平台能力之间的关联时，所有能力都呈现出程度相近的相关性。但其中有两项能力表现尤为突出：

首先，与积极用户体验相关性最强的能力是为任务提供清晰反馈。当平台能在任务成功或失败时给出明确反馈，用户将获得自主操作、主动排障和推进后续步骤的能力，无需自行梳理信息或猜测解决方案。


其次，“界面简洁直观”的相关性相对较弱：虽然清晰的界面能提升主观印象，但这并不直接转化为平台的实际效能。

尽管任务反馈清晰度和界面简洁性与其他能力项高度关联，但这两项在用户评价中仍排名靠后。这表明，孤立地优化单一能力是一项存在缺陷的策略。

要提升平台的感知质量，团队必须将其视为完整的内部产品，着力优化开发者全链路体验。如果平台仅技术卓越却缺乏用户导向（参见 2024 年 DORA 报告），便不能被视为成功。

效能、幸福感与风险管理的乘数效应

卓越的平台工程如同力量倍增器，能直接转化为更高的效能与生产力。随之而来的稳定性波动，恰恰可能是健康高速演进系统的特征——只要这种波动不影响产品效能，就属于可控范围内的良性代价。



“总体思路是尽可能实践持续交付——只要代码入库主干分支就立即部署，加入基础测试环节用于问题拦截，但核心原则是快速部署。这种模式在多数情况下运行良好，因为即使部署过程中出现故障，系统仍设有多重保障机制防止服务中断。因此单次部署可能失败需要紧急修复，但整个系统始终保持稳定运行。”

卓越的平台工程如同力量倍增器，能直接转化为更高的效能与生产力。随之而来的稳定性波动，恰恰可能是健康高速演进系统的特征——只要这种波动不影响产品效能，就属于可控范围内的良性代价。

尽管稳定性有所波动，效能却持续提升——这体现了一种风险补偿效应：平台使故障恢复变得快速且低成本，团队因此被赋能进行更多实验，为了追求效率而接受更高比率的可控轻微故障。

小幅度的稳定性波动，应被视为平台驱动显著效能提升的可控权衡。相较于交付吞吐量的有限增长和交付稳定性的适度下降，产品效能的改进往往能创造更大价值。投资高质量平台如同掌握战略杠杆，能够带来广泛而深远的回报。

核心战略：

平台工程是释放 AI 潜能的关键

应用 AI 对组织效能的积极影响，根本上取决于内部平台的质量水平。当平台质量较低时，AI 应用对组织效能的促进作用微乎其微；而当平台质量较高时，其提升效应则变得显著而强劲。这一关键发现，值得所有 AI 领域投资者高度重视。

内部平台调节人工智能对组织性能的影响




图49：内部平台调节人工智能对组织性能表现的影响



“Wayfair 公司发现，最大收益不仅来自更快发现故障，更在于降低修复故障所需的工作量。将 AI 嵌入 CI/CD 流程后发现：当针对性、可解释的建议和自动修复方案能无缝集成到开发者日常工具中时，他们的使用参与度最高。”

一个高质量平台在放大 AI 对组织效能的影响时发挥双重作用：首先，它作为 AI 效益规模化扩张的分发与治理中枢层，将 AI 的价值从个体生产效率提升转化为组织级系统改进。若缺乏此基础，AI 应用将止步于零散的局部优化。

平台通过集中化管理上下文环境，抽象化 AI 规模化应用中的复杂环节，使 AI 效能得以充分释放。但值得注意的是，AI 技术正快速演进，需警惕对 AI 实践、工具和方法进行过度标准化，否则可能限制其积极影响及适应技术变化的能力。

其次，平台在非 AI 场景中作为风险缓冲器的作用，同样适用于 AI 领域。平台应被用于创建容错空间，允许个人在安全边界内学习与实验。这种实验性安全空间将促使平台及平台团队持续进化，更好地适配新模型、交互模式及应用开发范式。

此外，无论代码由人工编写还是 AI 生成，平台均会实施统一的自动化测试与部署流程，从本质上确保应用程序和服务的所有变更安全可控。

若仅投资 AI 技术却未同步建设高质量平台，组织层面将难以获得显著回报。要真正发挥 AI 的竞争优势，领导者必须将平台工程视为基础性战略赋能因素。

平台工程时代的三大战略要务

践行全局体验观

你无法通过改进某一个功能来修复一个糟糕的平台。

应将你的平台视为完整的产品，聚焦从反馈闭环到自动化流程的开发者全链路体验。

将平台工程打造为 AI 战略基石

平台工程是释放 AI 组织价值的战略前提。更是将 AI 投资转化为真实竞争优势的引擎。

以平台工程为尺度校准风险偏好

卓越的平台工程通过降低失败成本与实现快速回滚，重塑组织与风险的关系。

需清醒认知平台工程在提升研发速度与伴随的稳定性波动之间的可控权衡，明确平台工程并非消除局部风险，而是构建风险缓冲机制。

1. Accelerate State of DevOps 2024. <https://dora.dev/dora-report-2024>
2. “Loosely coupled teams.” <https://dora.dev/capabilities/loosely-coupled-teams>
3. Accelerate State of DevOps 2024. <https://dora.dev/dora-report-2024>

价值流管理 (VSM)

Rob Edwards

应用交付主管, Google Cloud



每个组织都面临着加快创新的压力。我们都在采纳 AI、自动化流程、构建平台，并以极快的速度发布功能。但我们真的变得更好了吗？或者，我们只是在创建不提供价值的功能方面变得更快，在耗尽我们的团队工作量的方面变得更快，在引入系统复杂性方面变得更快？今天最大的风险不是落后，而是将大量投资投入到混乱的活动中，而这些活动并没有起到作用。

十多年来，DORA 的研究始终以一个核心理念为指导：效能最卓越的组织并非仅仅采用新工具，而是成为价值交付体系的行家。这些组织具备一项经实践验证的能力——“持续优化自身的优化能力”。它们能够理解自身的工作流程，识别真正的制约因素，并有的放矢、聚焦重点地调配资源。

今年，我们已经证实，能否详细梳理并管理自身的价值流的能力是真正将混乱的活动与集中的改进区分开来的能力。在 2025 年的研究中，我们发现，那些致力于理解自身价值流的团队，会将更多的时间投入到有价值的工作中。

更重要的是，我们发现：价值流管理（VSM）是将人工智能投入转化为竞争优势的“力量倍增器”，它能确保这一强大的新技术用于解决真正关键的问题，而非仅仅制造更多混乱。

如何实现重点改进： 价值流管理的原则

价值流管理（VSM）是一套对“从创意产生到交付客户”的工作流进行可视化、分析与优化的实践方法。它并非一套复杂繁琐的流程，而是由四项原则构成的体系——这些原则旨在帮助组织获得必要的清晰度，从而将改进重点聚焦于最关键的领域。

有关如何进行价值流映射练习的详细分步指南，请参阅 DORA 价值流管理指南。¹



从混乱的思绪到共享的图谱

想要理解一个复杂的系统并非易事。对任何人来说，记住所有复杂的细节都会极大地消耗脑力，这也会阻碍对整体情况的理解。

当一个团队共同绘制出一个系统时，所有细节都会从每个人的脑海中提取出来，进入一个共享空间。突然间，系统的结构以及任何隐藏的模式都变得清晰可见。这种可见性让人们更容易就哪些部分有效、哪些部分无效进行真正有意义的讨论。从本质上讲，这正是价值流映射（VSM）的核心所在。

这种实践本身关乎规划整个软件交付生命周期，从最初的概念一直到交付给客户。

这张图涵盖了一切：产品探索、设计、开发、测试、部署和运维。创建这种共享的呈现方式可以让团队对 workflow 形成集体理解，从而更容易发现阻碍工作的真正瓶颈和效率低环节。

将整个系统从概念映射到客户交付是目标，但您不必一次性解决所有问题。关键是从你能产生最大影响的地方开始。

在深入研究之前，应先从宏观层面审视工作流程，找出主要制约因素——这样做是为了避免将精力用于优化流程中并非真正瓶颈的部分。例如，如果你的团队最大的挑战在于产品探索，那么这可能是一个更有效的起点。

尽管如此，仍有一个高效且经实践验证的起点，也是 DORA 多年来一直采用的起点——即“从代码提交到生产环境部署”这一范围。我们选择从该环节入手，是因为流程的这一部分最容易实现标准化，也最便于通过调整提升效率。

更重要的是，这一阶段通常是团队自主权最高的阶段，因此他们能够立即实施具有重要影响的改进措施。这与探索阶段的工作形成鲜明对比——在探索阶段，核心目标是围绕“有效性”进行优化。

成功完成这一核心流程能带来立竿见影的成果，进而积累推动变革的动力与可信度——而这些正是影响更广泛的产品探索与客户反馈体系所必需的条件。




图50：展示待办事项到生产环境流程的价值流图示例

专注于流动，而不仅仅是速度

一旦你绘制好了价值流图，真正的目标就是让工作流畅且可预测地进行。要做到这一点，就需要从关注局部效率转向优化整个系统。

你应该从衡量重要的事情开始。跟踪关键指标，如交付周期、处理时间以及增值与等待时间的比率。

这些数字为您提供了关于真实限制的数据，并提供了一个清晰的基线，因此您将知道您的改进是否真的有效。

这种系统层面的视角对于确定应用新解决方案或新技术的最佳切入点至关重要。例如，一个团队可能通过映射发现，代码审查是一个显著的瓶颈。有了这一见解，他们可以决定应用 AI 来改进代码审查流程，而不是用人工智能简单地生成更多代码——这只会加剧瓶颈问题。

真正的成功在于利用 AI 改进代码审查流程本身，清除系统中的实际障碍。这就是关注流程的意义所在：你要解决整个系统最大的问题，而不仅仅是加快单个步骤的速度。

营造持续改进的文化

价值流图（VSM）并非一次性的工作，而是一个持续改进的循环。定期回顾团队绘制的价值流图，并将其作为每次改进讨论的起点。

培养一种让团队有能力进行实验、学习和适应的文化是至关重要的。² 这意味着要制定明确的目标，但也要为团队提供自主权，让他们知道如何实现这些目标。

团队需要拥有开展试验、学习与调整的自主权，且无需担心因此受到惩罚。同时，鼓励团队将所学经验与组织内其他成员分享，也同样至关重要。

通过这种方式开展价值流管理（VSM），并记录每一次迭代改进的过程，你将构建一份能动态反映进展的历程档案。随着时间推移，你可以回顾这些记录，清晰梳理出每一项变革如何逐步提升团队为客户交付价值的能力——形成一套完整且有据可依的发展脉络。

“此外，还存在这样一种复杂性，比如会思考‘这需要投入多少工作量？’‘最终要花费多长时间？’‘该如何估算这些呢？’这类问题。这类情况始终存在不确定性，而且（我们）会有种失控感：我们能否根据实际需求实时调整方案并完成工作？

还是说，每次我们想做些调整——比如修改一条防火墙规则——都得走一个两三周的流程？类似这样的情况还有很多。（现有）流程在很多方面都可能拖慢我们的工作进度。

我认为，尤其是那些资历较深的员工，他们在其他大公司工作过，对这种情况非常熟悉。”

以卓越的技术为基础进行构建

没有卓越的技术基础，就不可能实现快速、顺畅的流动，而这一基础通常是一个设计完善内部平台。通过为开发者提供测试和交付等功能的“康庄大道”，优质的内部平台能够简化复杂性，使高效能的工作模式具备可扩展性。

强大的技术基础和组织效能之间的关系将在平台工程一章中详细介绍

这在我们 2025 年的调查结果中 是如何体现的

多年来，DORA 一直倡导使用像价值流管理（VSM）这样的实践来创建快速的工作流。但是这个建议仍然有效吗，特别是在 AI 被广泛采纳的情况下？

今年，我们想验证我们长期以来关于价值流管理（VSM）益处的假设。我们的研究结果证实，采纳 VSM 原则的组织看到了显著的、可衡量的好处。

首先，我们的研究证实，价值流管理实践对效能具有直接且显著的影响。我们发现了以下强有力的证据：

- **VSM 驱动团队效能。**持续审查和改进其价值流的团队报告了显著更高的效能。
- **VSM 带来更有价值的工作。**这些团队将更多的时间花在对组织及其客户至关重要的工作上。
- **VSM 提高了产品效能。**最终，这种对价值流的关注转化为更好的产品结果，这可以说是最重要的结果。

这些数据传递出一个简洁且贴近实际工作场景的结论：当团队协作梳理并理解自身的价值流时，他们会将更多时间投入到真正重要的工作中。若团队对整个价值流形成了清晰且统一的认知，便能将精力聚焦于最关键的事务，进而将这种认知层面的清晰度转化为具有实际意义的影响。


这种认知层面的清晰度是解锁人工智能等新技术的关键。它让团队能够制定策略，而不只是用工具去解决问题。你不再只是优化某个小步骤，而是在消除系统最大瓶颈中的阻碍。

这一信念使我们为今年的研究制定了一个关键假设：

- **VSM 能将人工智能转化为组织优势：**我们假设 VSM 调节了 AI 采纳与组织效能之间的关系。拥有成熟 VSM 实践的团队可以将 AI 带来的生产力提升用于解决系统层面的问题，确保个人改进转化为更广泛的组织成功。如果没有 VSM，AI 可能会带来局部的效率提升，而这些提升会被下游瓶颈完全抵消，无法为整个组织创造真正的价值。



VSM缓和了人工智能对组织效能



结论

我们的分析证实了这一假设。虽然 AI 的采纳本身显示出适度的影响，但在具有强大 VSM 实践的组织中，这种影响被显著放大。

这证实了 VSM 是充分发挥 AI 投资价值的关键推动因素。通过确保团队层面与个体层面的生产力提升聚焦于系统层面最关键的制约因素，VSM 帮助将局部改进转化为有意义的组织影响。

本研究不仅是一项观察结论，更是一份行动挑战。要打破这种无序忙碌的循环，第一步看似简单却并非易事：问问你的团队——“我们能否在白板上画出软件交付的价值流？”

如果答案是否定的，或者如果图画揭示的问题多于答案，那么您就找到了行动的起点。这样一次对话，正是开启“持续改进”之路的开端。

1. “如何使用价值流映射来改善软件交付：价值流映射指南。” <https://dora.dev/guides/value-stream-management>
2. “如何改变你的组织。” <https://dora.dev/guides/how-to-transform>
3. ““工作在价值流中的可见性。” <https://dora.dev/capabilities/work-visibility-in-value-stream>
4. “《视觉管理》” <https://dora.dev/capabilities/visual-management>

AI 之镜： AI 如何反映和放大组织的 真正能力

Eirini Kalliamvakou, 博士.
首席执行官办公室研究顾问, GitHub



去年的 DORA 报告发现，使用人工智能（AI）的团队在软件交付中表现出更低的吞吐量与更高的不稳定性。这一超出预期的研究结果引发了激烈讨论 —— 一项旨在提升工作效率的技术，为何会与更缓慢、更不稳定的交付结果相关联？

今年，情况略有变化。AI 的采纳现在已经帮助吞吐量上升，但不稳定性仍然存在。这种 “既有进展又有阻碍” 的局面，促使我们进行更深入的研究 —— 不再局限于简单的 “是否使用 AI” 这类二元对比，转而探索真正决定 AI 影响的关键因素。

我们的研究发现指向了一个比工具与技能更核心的因素：人工智能所处的环境，才是决定其影响的关键。

超越工具来推动人工智能的影响

今年最令人兴奋的研究成果之一是 DORA AI 能力模型。人工智能的使用对吞吐量、代码质量、团队和组织效能等结果的影响，一直会因七项核心能力而得到增强：

- 1. 明确且已共识的人工智能立场
- 2. 健康的数据生态系统
- 3. AI 可访问的内部数据
- 4. 稳健的版本控制实践
- 5. 小批量工作
- 6. 以用户为中心
- 7. 高质量的内部平台

这些系统性条件，反映了一个组织如何构建工作体系、为团队提供支持，以及如何调整自身环境以适配现代化开发实践。这些能力可帮助判断人工智能（AI）工具的应用能否转化为具有实际意义的成果，因此它们被视为 “增强因素”。而这些能力均作用于团队层面与组织层面，这一特点也进一步印证了我们在看待人工智能在软件交付中的角色时，需要做出的一项关键认知转变。

我们的研究发现，人工智能（AI）对效能的影响，取决于其工作所处的系统环境。例如，一个与人工智能工具相集成的健康数据生态系统，能够创造有利条件，推动人工智能的价值从个体生产力提升，进一步拓展至组织层面的跨越式发展。若缺乏这些为人工智能使用者铺路、助力其成功的基础性工作，人工智能的价值可能会陷入停滞、进入平台期，或呈现分布不均的状态。

要利用这一洞见，我们应将关注焦点从 “个体如何使用人工智能（AI）”，转移到 “组织如何围绕人工智能设计配套系统” 上。

组织是系统，而非个人的总和

要理解如何将 AI 的影响力从个人生产力提升扩展到组织层面的收益，我们需要从系统的角度进行思考。组织不太像是个体和工具的集合，而更像是由相互依存的部分组成的网络。工作通过团队、流程、政策、基础设施和共同规范来流转。虽然个人能力在决定结果方面起着关键作用，但整体效能源于所有这些部分的互动方式。

这一理念是系统思维的核心——系统思维作为一种认知视角，深刻影响着高效能组织的发展方式。W. 爱德华兹·戴明是现代质量管理的创始人之一，他认为大多数效能问题不是源于人，而是源于系统。正如他的名言所说，“糟糕的系统每次都会击败优秀的人。”

在一个系统中，改善一个部分并不能保证总体上更好的结果。事实上，如果系统的其他部分不能适应，局部改进可能会受阻、稀释甚至逆转。

也是约束理论的核心观点。任何系统都存在一个限制因素——即制约因素——它决定了系统能够交付的价值总量。

若将精力集中在制约因素之外的其他方面，或许会让人感觉自己在高效工作，但这并不能切实改善价值流。

这一点对人工智能的应用具有启示意义。当开发人员使用 AI 工具更快地编写代码时，这些代码仍需经过测试与审核队列，随后进入集成与部署流。

除非为开发者的新工具和更快的速度更新相关工作流程，否则整体交付速度不太可能发生显著变化。该系统的设计无法承载这些成果，更不用说放大它们了。

我们此前已见过类似情形。在向云计算转型的过程中，那些仅迁移基础设施、却未重新思考架构与交付实践的企业，最终获得的回报十分有限。

然而，那些为云原生工作流重组其应用程序、团队和运营的组织能够释放真正的价值。敏捷和 DevOps 实践也是如此：只有在角色、反馈循环和团队边界发生深刻变化时，才能兑现其承诺的价值。

只有当围绕新技术和工具的系统随之发展时，这些新的、强大的技术和工具才能产生相应的变革性成果。

这就是为什么人工智能的应用需要被视为一项转型工作。如果组织希望加快速度、进行更多试验，并改变开发者的时间分配方式，就需要重新审视工作本身的流程。

下游系统（如集成、测试、部署和合规性）是否具备足够的灵活性与响应能力，以跟上 AI 的速度？决策结构是否跟上了工作节奏？团队是否获得了相应激励，从而主动进行任务委派？大规模验证 AI 输出，并以新的方式共享知识？

如果没有对工作流程、角色、治理机制和文化预期进行针对性调整，在整体未变的系统中，AI 工具很可能仍然是孤立的，这无疑是一种错失的机遇。要扩大人工智能的影响范围与效果，组织应投入资源重新设计自身系统。具体而言，这意味着要识别系统中的制约因素、优化工作流转效率，并创造有利条件，使局部效率的提升能够转化为组织层面的发展动力。

这种转变可能会是什么样？

转型有两种方式：增强和演进

当组织致力于挖掘人工智能的全部价值时，我们可以从两条互补的路径来思考转型。一条路径侧重于增强现有系统，以消除阻碍并支持人工智能工具带来的效能提升。另一条路径则设想人工智能如何为全新的工作方式打开大门。

增强：为承接 AI 带来的效能提升做好准备

当开发者开始使用 AI 工具并感受到工作效率提升，但团队在吞吐量或交付速度上却没有看到相应增长时，系统本身可能就是限制因素。

增强意味着识别并解决这些摩擦点，以便个人的加速能够向下游传导。

代码审查和验证：考虑人工智能可以在哪些环节加快现有步骤的推进速度并提升其清晰度。比如，由人工智能生成的首轮评审结果能快速发现问题，减少在常规反馈上花费的时间；通过结构化人工智能的输入内容，使其突出风险点或汇总代码差异，也能让人工评审更便捷、更高效。

持续集成和部署流水线：人工智能生成的代码流转速度很快——你的系统能否跟上这一速度？持续集成和部署流水线可能需要改进，以减少等待状态并实现更高频率的交付。借助人工智能实现的质量检查可分层嵌入流程，无需添加人工关卡，在不牺牲质量保障的前提下改善流程。

数据基础设施：人工智能能力模型指出了投入资源更新数据基础设施的价值。首先，当 AI 模型和工具与内部数据连接时，其在生产力与代码质量层面的价值会得到增强³。这里的内部数据包括代码仓库、工作跟踪工具、文档，甚至是决策日志和沟通工具。为人工智能工具补充这些高价值背景信息，能够提升其输出结果的质量。与背景信息的重要性相关联的是第二项研究发现：当数据生态系统处于健康状态（即数据可被人工智能获取、且具备准确性与完整性）时，人工智能对组织效能的价值贡献会更大⁴。

安全与隐私协议：随着人工智能如今参与到开发和运营 workflow 中，安全实践必须随之演进。这包括工具使用的安全性、更新相关政策，以及引入具备 AI 感知能力的监控系统，这些系统在不造成瓶颈的情况下维持信任。将这些流程的部分环节自动化有助于团队保持效率。

变革管理和文化调整：与所有组织转型一样，人工智能的采纳需要愿景、支持和沟通——这些都是变更型领导力的核心特质⁵。领导者应清晰阐述人工智能转型的长期目标（无论是创新突破、效率提升，还是质量优化），并通过培训赋能、共享实践规范及合理预期管理，为转型过程提供支撑。

文化同样发挥着重要作用。团队需要获得进行实验、犯错、提升熟练度以及分享所学知识的许可。对“验证 AI 输出”“委派 AI 任务”“优化提示词”“协调 AI 智能体”这类行为给予奖励，能清晰传递出在人工智能加速发展的环境中成功应有的样子这一正确信号。

演进：为人工智能所能实现的一切进行设计。

除了增强现有系统，人工智能还为设计全新工作流程提供了契机——这些工作流是与人工智能运行方式原生适配的全新方法。

AI-native 交付管道：人工智能能够持续分析代码，以发现漏洞、安全隐患及违反团队规范的问题。它可以提出测试建议，甚至动态生成测试用例。在具备合适数据与集成条件的情况下，AI 还可以在部署风险和性能退化发生之前对其进行预测。

AI-native 数据系统：人工智能可以通过组织、标记、清理和分析数据来帮助维护自身运行环境。这不仅能增强洞见生成的可靠性，并更快地迭代基于数据的决策。它还能揭示团队工作的模式，为运营改进提供新的调控手段。

AI-native 安全：人工智能可以通过更早地检测威胁、识别异常行为，甚至自动化部分事件响应过程，来提升安全团队的能力。对于通常面临资源不足问题的安全团队而言，人工智能的作用在于缓解其工作压力，同时缩短响应时间。

AI-native 协作模型：智能体工作流（agentic workflows）与协同集群（swarming）等新兴实践，正开始重塑人类与 AI 的协作方式。其中，智能体工作流将任务分配给具备自主能力的 AI 智能体；而协同集群则能让团队与 AI 围绕复杂问题动态协作、聚力解决。虽然还为时尚早，但这些模式暗示着新的、更具适应性的合作模式。

像持续人工智能（Continuous AI）⁶ 这样的新兴趋势说明了 AI 原生适配工作流如何长期持续下去。Continuous AI 将 AI 系统视为开发流水线的一个具有动态生命力的组成部分和团队流程的参与者。

Continuous AI 持续感知项目场景中发生的各类事件，在自主运行的同时保持协作属性，促进团队互动并与团队一起调整方向。实现这一模式的关键在于，需为人工智能系统或智能体持续更新相关的上下文信息，并不断从准确性、实用性与成本三个维度对其进行评估。

这一机制能确保人工智能与组织不断演进的架构、实践及优先事项保持一致，从而在环境发生变化时，保障其输出结果始终具备相关性与高质量。

在增强和演进中，二者的共同核心在于“针对性设计”。仅部署人工智能工具无法实现转型；而当 AI 部署与务实且具前瞻性的系统级变革相结合时，人工智能的采纳便能成为重塑软件构建、交付与安全保障方式的催化剂。



从哪里开始： 人工智能转型的实践步骤

一个组织越早将人工智能的应用视为一项转型工作，就越能掌控转型的推进过程。

尽管技术迭代速度很快，但真正的区别在于各组织如何有效快速地作出响应。在旧流程围绕新工具固化之前启动转型，意味着组织可以塑造其系统的未来，而不是被动继承它们。

一个顺理成章的首要步骤是审视当前实际的工作流转方式。在实践中，这意味着要建立对“想法从产生到客户交付的全过程”的共享可见性。这个过程，通常被称作价值流管理，可以帮助团队可视化交付的每个阶段，从编码、代码评审到测试、部署及生产环境运行。

如果做得好，梳理价值流可以揭示协调成本在何处累积、延迟和返工在何处频繁发生，以及系统在何处抵消或阻碍人工智能工具带来的效率提升。这有助于聚焦“约束理论”所指出的那些最能释放价值的关键因素。



要启动 workflow 映射，组织可组建小型跨职能工作组，成员包括参与日常软件交付运营的实践者，如工程师、产品经理、数据工程师、运维人员和安全人员。这些小组最适合从内部梳理系统，找出协作中的问题和瓶颈，并确定人工智能可以发挥变革性作用的领域。

这类工作若能获得管理层支持，其成效将最为显著。管理层的支持不仅是战略重要性的信号，还能确保工作获得必要资源，并为“从发现问题到采取行动”搭建清晰路径。。这些工作组的任务是提出战略性建议：系统应在哪些方面调整以适配 AI？AI 可在哪些环节优化流程或赋能角色？需培养哪些能力才能释放长期价值？

在某些情况下，引入外部协调者或顾问有助于指导上述工作推进、提供行业基准参考，并确保讨论始终聚焦于“能带来更广泛改进的系统性机遇”。

要让变革落地生根，认知与洞见必须源于组织系统内部人员。当实践者主导探索过程，且领导层承诺为实现目标提供支持时，推动实质性转型的必要条件便会逐步形成。

至关重要的是，开展这项工作必须运用系统思维。正如前面所讨论的，组织是复杂的系统，仅改进其中一个节点（比如加速代码生成）并不会提升整体效能，除非相邻的组成部分同步演进。DORA 人工智能能力模型有助于理解：

哪些组织层面的干预措施能够放大人工智能的效益。

例如，某工作组可能会发现：尽管人工智能工具能够提供有价值的建议，但其生成的响应往往会遗漏关键背景信息，例如团队约定、架构演进历史或过往事件记录等。

这对许多组织来说可能并不奇怪，因为这些信息通常隐藏在不同的系统和非正式的知识渠道中。

作为应对方案，工作组可能会建议：以结构化、安全的方式，将内部文档、决策记录及历史工单等信息对人工智能模型开放。他们还可能提议构建相应 workflow。

在开发或评审环节自动提供这一上下文，减少开发者用于搜索的时间，同时提升 AI 输出结果的质量。

或者，该工作组可能会探索人工智能的另一应用方向，如何利用 AI 来识别过时的文档、总结冗长的项目讨论，以及检测系统实际运行情况与文档所声称的内容之间的不一致之处。

这样做有助于将零散的知识转化为结构化的、可操作的资产。

除了流程变革，这些工作组还能凸显对新技能和新角色的需求。随着开发者将更多工作交由人工智能工具处理，验证、编排和工作流设计等任务变得愈发核心。

组织将需要定义这些角色的具体定位，如何支持他们，以及如何相应地调整激励措施。

这包括提供有针对性的培训——此类培训不应局限于工具层面，还应涵盖人工智能如何改变开发工作本质的内容。

这些变革不会自动发生，也不会一蹴而就。它们需要有明确的目标导向、清晰的责任归属，以及持续的支持。但值得注意的是，这些变革并非要求从一开始就做到尽善尽美。

当组织从小处着手、有目的地投入资源，并在各角色间建立共同的责任机制时，便能逐步积累变革动能。通过一步一个脚印、逐项构建能力，转型最终将落地生根。



“文化转型与工具建设同等重要。要取得成功，不仅需要引入自动化技术与衡量指标，还需围绕共同目标与责任归属，推动团队达成共识。”。

人工智能：镜子与倍增器

人工智能有潜力重塑软件的构建方式，但它本身并不能改变组织系统。它所做的，往往是非常迅速地反映出这些系统的实际运作方式。

在协同良好的组织中，人工智能能放大工作流的效率。而在架构松散的组织中，它会暴露痛点。那些拥有完善实践方法、灵活工作流程和共享背景信息的团队，往往能迅速看到成效。

而对于依赖脆弱流程和隐性知识开展工作的团队而言，可能会发现这类短板比以往任何时候都更为明显。

这就是为什么 AI 既是一面镜子，又是一个倍增器。它揭示了有效性的方面，加速了已经在进行的事情，但也凸显了需要改变的地方。

对于做好准备直面自身现状的组织而言，人工智能呈现的“映射结果”将成为一份行动指南。正如我们在过去其他变革中所看到的，那些愿意将 AI 采纳视为一个主动推动自身演进的组织，终将成为最大受益者——他们不仅能从 AI 工具中获益，更能从 AI 赋能的变革中收获价值。



1. 世贸爱德华戴明研究所 <https://deming.org>
2. 限制理论” https://en.wikipedia.org/wiki/Theory_of_constraints
3. .el
4. I 同上
5. “变革型领导” .” <https://dora.dev/capabilities/transformational-leadership>
6. “持续的 AI 1.” <https://githubnext.com/projects/continuous-ai>

人工智能：技能发展的挑战与机遇

Matt Beane, 博士.

加州大学圣巴巴拉分校副教授

斯坦福大学和麻省理工学院数字研究员

在技能发展方面，软件与其他职业相似。专业知识应该从高级员工流向初级员工，理想情况下，新的观点和技能应该涌现出来。

资深开发人员的职责远不止于审核代码提交请求（pull requests），他们还会指导初级开发人员如何从架构层面思考问题。结对编程并非仅仅是为了发现漏洞，更在于为了传递那些难以通过文档记录的隐性知识。在理想情况下，“三级梯队模式”——初级、中级、高级开发人员的层级结构——能帮助开发人员通过联合解决问题来获取技能，而非依赖正式培训。

我们需要研究人工智能部署对这个理所当然的过程的影响。我的职业生涯一直致力于研究智能自动化与技能之间的关系，研究覆盖 31 种以上的职业。结果表明，智能自动化的默认使用改变了传统的学徒模式，使新手参与对其发展至关重要的动手工作的机会减少。

专家能够自主完成工作，因此他们会直接使用智能自动化工具。少数资历较浅的人尽管存在这种参与障碍，还是设法学会了，但大多数人都举步维艰。自 2023 年以来，我只研究人工智能在复杂任务执行中的应用，最近主要研究其在软件工程中的应用。从初步研究结果来看，上述模式同样明显存在。

但也有一些有趣的例外，且我们仍需对此展开更深入的研究。就像过去的其他突破性技术一样。

从印刷机到个人电脑到互联网类似。人工智能的开发与部署正以史无前例的速度推进。而人类能力将如何适应这些变化，目前尚无定论。

然而，目前许多人关注的焦点仍是衡量与人工智能相关的生产力。我们会追踪 AI 的采纳率、生成的代码行数、合并的代码提交请求（pull requests）数量等指标，但却不会追踪那些能反映技能发展的指标，例如，随着时间推移，开发人员在代码语言运用或风格表达上的多样性。

最好的组织将协同优化员工的生产力和技能发展。事实上，在我的一些研究中，只有坚持同时发展技能，才能提高生产力。对这两项指标同时进行衡量与推动，才是实现可持续效能的关键路径。

人工智能是软件开发未来不可或缺的一部分，其中包括技能培养。例如，我们可借助 AI 分析开发人员与 AI 的交互过程，将其与版本控制交互数据相关联，进而关联到技能发展情况与关键工作成果。

这种分析方式在过去成本过高、难以实现，但如今用于数据标注的 API 成本正快速下降。借助 AI，我们能够获取所需的洞察，从而重构工作流程，并为开发人员提供指导，帮助他们保持学习优势——同时也助力他人实现同样的目标。

当前，AI 的默认使用模式虽能带来突破性的生产力提升，却对大多数开发人员的技能发展造成阻碍。为了保持我们的创新优势—无论是个人还是集体—我们需要使用 AI 本身来同时衡量技能发展和生产力。

度量框架

Sarah D' Angelo, 博士
用户体验研究员 , Google

Ambar Murillo
基础设施用户体验研究员
Google AI & Infrastructure

Sarah Inman , 博士
用户体验研究员 Google

Kevin M. Storer, 博士.
用户体验研究员, Google Cloud

选择适合组织目标的度量框架

对软件开发过程进行度量，有助于推动产生切实有效的变革。然而，这是一项复杂的任务，启动阶段往往令人却步，因为它涉及到理解您应该度量什么，并确定哪些内容是具备度量条件的。

最重要的一点是，您希望通过度量来推动组织中的变化。为此，我们建议您使用框架来指导您的度量策略。

度量框架将一个广泛的主题（例如，开发人员体验）分解为可以度量的不同视角（例如速度或满意度）。

当行业与学术界讨论软件开发各维度的度量方法时，常会引用各类框架作为参考：例如SPACE1、DevEx2、HEART、3和DORA的软件交付指标。选择一个框架来度量软件开发可能是一个困难和令人困惑的过程，但其实并非如此。

第一步是明确度量工作需服务于哪些目标、为哪些决策提供依据，因为不同的框架在总体目标上有所不同。

例如，软件开发中的常见框架其关注重点分别为度量开发人员体验、产品卓越度与组织效能。这些核心目标各自采用略有不同的视角，帮助理解软件开发过程（参见图 52）。

用于度量软件开发的典型框架类型



图52:用于度量软件开发的典型框架类型

要确定哪种框架最适合您的组织的目标，可将框架视为度量工作背后的“目的”。它们能帮助你明确为何要开展度量工作，并根据度量结果为你采取的行动提供指导。

框架为数据解读提供了视角，确保各项工作与组织目标保持一致。在选择框架时，可考虑以下问题：为何是现在？是否发生了某些变化，促使你产生度量的需求？如何根据洞察采取行动？通过度量，能否推动某些决策的制定或改进工作的实施？

现在，你要度量的“内容”是实际的指标，也就是构成核心框架的关键概念，例如交付速度指标或应用普及率指标。通常，你可以采纳两种不同的数据收集方法。如下的数据收集的“方式”，将帮助你获取所需指标。

自我报告数据

自我报告数据指直接从开发人员那里收集有关其体验的信息。具体可通过以下方法实现：

- **调查问卷：**通过设置问题，收集开发人员对工作各方面的看法、满意度水平及认知情况。
- **访谈与焦点小组：**通过一对一访谈和小组讨论，深入探究特定体验与主题相关的信息。

- **日志研究：**收集开发人员在实际场景中与工作活动、想法及体验相关的实时数据。

自我报告数据的优势在于，它能够捕捉那些难以通过自动化方式量化的主观体验与概念，例如满意度、幸福感或感知有效性。自我报告数据的另一项关键优势是，它通常不需要对开发人员的工具链进行大规模部署，也无需实现深度可观测性。

然而，自我报告数据在标准化程度、团队间可比性，以及面向大型组织的可扩展性方面确实存在挑战。其固有的主观性意味着，对数据的解读可能存在差异；同时，这类数据也更容易受到偏差影响（包括回忆偏差与社会期望偏见）。

基于日志的度量数据

基于日志的度量数据是从开发人员使用的工具与系统中自动收集而来的。这类数据可包含以下几种指标类型：

- **数量类指标：**用于统计特定产物的数量。例如，提交次数（代码提交）或用户数量。
- **时间类指标：**用于记录开展特定活动所消耗的时间。例如，编码耗时或代码评审耗时。
- **频率类指标：**用于度量特定时间窗口内的事件发生率。例如，月度部署次数，或每位开发人员的每周拉取请求（PR）数量。

基于日志的度量数据，其主要优势在于能够大规模提供持续度量的标准化数据。这类数据可清晰呈现各项活动与产出的详细情况。

然而，这类数据的获取需要对开发人员的工具链具备足够的可观测性，这意味着必须配备必要的集成组件与数据收集机制——而这一点可能会抬高其应用门槛。

此外，认为基于日志的度量指标具有客观性，是一种常见的误解。实际情况是，数据采集的实施方式存在差异，过程中的误差可能导致数据不准确，且对数据的解读也会受到偏差影响。

框架会为你提供希望度量的相关概念，但最终落地实施何种度量方式，取决于你的资源配置情况以及可获取的数据类型。例如：你是否具备对工具链的可观测性，以支持基于日志的度量方法？或者，你是否拥有研究团队，以开展自我报告数据的收集工作？

需要明确的是，并非所有组织都拥有同等的资源配置，也并非都具备能力，能按照某一特定框架建议的方式实施度量。认识到这一点至关重要。

即便存在组织层面的局限，框架依然能发挥指导作用——它可作为一种视角，帮助你更好地理解复杂行为，但无法完整捕捉全部行为细节。框架的设计初衷是帮助你更接近事实本质，而非让你实现“万物可度量”。因此，不应期望通过框架能度量所有事物。

在思考框架和指标之间的关系时，不妨将指标视为食材，而框架则是用这些食材制作的食谱。一些核心食材可以通过不同的方式重新组合，形成不同的食谱（即框架），而另一些食材则是某一特定食谱所独有的。

每顿饭的味道都不一样，但一些基本的食材是共享的，在许多情况下，你不需要拥有所有的食材来做一顿美味的饭。

尽管不同框架存在差异，其设计初衷是为了达成不同目标，但部分底层度量指标是存在重叠的。

下方图表展示了构成各类框架的部分度量指标，以及这些指标通常如何重叠。例如，生产力指标（如代码提交数或拉取请求数）可能会被这三类框架共同纳入度量范围。

一个组织可能会运用这些度量指标，实现以下目标：衡量新团队结构的影响（对应组织效能维度）、评估开发工具的效用（对应产品卓越性维度），以及了解开发人员的工作负荷（对应开发人员体验维度）。

相比之下，部分度量指标的专业性更强。例如，开发人员幸福感，通常是开发人员体验框架的关键组成部分，但通常不是组织效能或产品卓越框架中的主要度量指标。

选择使用单一框架，有助于让你采取的行动更具针对性，这是一个很好的开始方式。不过，你并非只能局限于使用某一个框架。

随着度量目标与度量能力的变化，运用多个框架有助于生成互补性的分析结果⁵，进而实现“整体大于部分之和”的效果。

关键在于，你需将度量作为一种手段——通过它让自己与所在组织对既定目标负责，同时确保你有能力根据度量结果采取行动。

适用于不同框架的指标示例




图53: 适用于不同框架的度量指标示例

在人工智能时代应用度量框架

你可能会疑惑：在开发流程中引入人工智能，是否会彻底改变现有一切？以往的框架是否依然适用，还是需要全新的框架？当技术出现颠覆性变革时，人们往往会觉得有必要彻底调整现有的度量数据收集策略。但我们建议，应审慎思考究竟哪些方面真正需要改变——尤其是在考量人工智能带来的影响时。

调整您的目标以更好地了解 AI 如何影响开发人员体验可能只需要更新几个指标，整体上仍可保留一致的度量标准。无需摒弃整个框架，你可将现有度量指标作为基准，借助它来明确技术范式转变对开发人员体验的改变方向与程度。例如，您可能需要添加有关 AI 建议的采纳率、模型质量或信任度的指标，同时保留现有的开发人员体验指标，例如感知生产力和审查代码所花费的时间。

随着人工智能领域涌现出更多重大进展，承担开发任务的主体（即“谁来做”）以及开发任务的具体内容（即“做什么”）都将发生变化。因此，度量工作可能需要相应调整——比如纳入不同的用户画像、捕捉不断变化的工作流程，但度量开发人员体验的核心目标，很可能并未改变。

此处的关键在于：若你的总体目标保持不变，就无需更换框架；你可以通过拓展度量范围，来适配技术层面的变化。

即便你的目标确实发生了变化，也未必需要从零开始搭建度量体系。由于指标可以为不同的框架服务，你往往能够迅速做出反应，重新整合这些指标以适配新框架或新增框架的需求。例如，了解人工智能驱动的开发工具对所生成代码的影响，可能是组织以前从未遇到过的新目标。实现这一度量目标颇具挑战性——尤其因为我们要度量的对象本身正处于动态变化之中。

各组织当前面临的一个普遍问题，AI 对代码质量的影响。正如我们所见，AI 正被用于提升开发效率，但人们也尤为担忧：我们是否在为追求速度而牺牲质量。短期内，开发效率的这类提升看似具有积极意义；然而，若代码质量偏低，这种短期效率提升可能会对长期开发效率产生负面影响。

为了应对这些问题，你的目标可能是在推动 AI 驱动工具的落地应用过程中，确保组织的代码质量始终保持在较高水平。这一目标涉及到前文所讨论的各类框架的各个方面，并且可能包含你已经在收集的度量指标（例如代码质量、工具采用率或感知到的开发效率）。

因此，您可以在引入新指标的同时继续使用现有指标。例如，将 DORA 的软件交付指标与 HEART 等产品卓越框架相结合。可以有效地了解开发人员对新型 AI 驱动工具的使用体验，也能掌握其对软件交付产生的影响。

软件开发生命周期的度量工作，是一项复杂且持续推进的过程。尽管目前已有多种框架与度量方法可供选择，但核心在于你需要具备根据度量结果采取行动的能力。而要确保能基于度量采取有效行动关键方面是：让度量工作与组织目标保持一致，并为您的度量工作争取到管理层的支持。

对你选择的框架和度量方法有意识，可以帮助你获得长期的成功。本着采用框架来实现特定目标的原则，您可以考虑如何根据 PDCA 框架，针对度量信息采取行动：

- **计划 (Plan)：**明确目标，选定适配的框架，并获取管理层支持；
- **执行 (Do)：**收集基准度量数据，尝试采取新的实践方式；
- **检查 (Check)：**再次开展度量，评估目标的推进进度；
- **调整 (Adjust)：**依据度量结论，优化后续推进方法。

我们的目的并非推荐某一种框架优于其他框架。

根据组织目标确定适配的框架，有助于明确你需要度量的内容与采取行动的方向。选择能与组织需求相契合的框架即可——若该框架能让你清晰理解，且能推动组织采取实际行动，那它就是当前阶段适合你的框架。

尽管各类框架提供了指导性结构，但许多底层度量指标却是共通的。这意味着，随着你的需求与目标不断发展或变化，当下所采用的度量指标，通常也能通过调整继续发挥作用。

1. “开发人员生产力的空间：比你想象的要多 <https://queue.acm.org/detail.cfm?>电话：+86-0512 - 8888888
2. “DevEx：什么实际上推动了生产力：以开发人员为中心的方法来衡量和提高生产力。<https://queue.acm.org/detail.cfm?>电话：+86-0551 - 88888888
3. “大规模测量用户体验：以用户为中心的 Web 应用程序的测试。
<https://research.google/pubs/measuring-the-user-experience-on-a-large-scale-user-centered-metrics-for-web-applications>
4. DORA 的软件交付指标：四个关键。<https://dora.dev/guides/dora-metrics-four-keys>
5. “DORA 与 H. E. A. R. T. 的结合，开启产品成功之路”
6. <https://cloud.google.com/transform/unlocking-product-success-by-combining-dora-and-heart>
7. “测量 AI 代码助理和代理。” <https://getdx.com/research/measuring-ai-code-assistants-and-agents>
8. “DORA 与 H. E. A. R. T. 的结合，开启产品成功之路。”

结语： 从洞察到行动

Nathen Harvey

DoRA 负责人， Google Cloud

十余年来，DORA 一直是软件开发领域值得信赖的合作伙伴，通过提供研究成果与 深度洞察，助力各团队实现能力提升。当前，随着人工智能、平台工程等新技术的逐步落地，行业正加速演进；但我们的使命始终未变：深入研究并分享那些能培育高效能团队的实践方法。

DORA 人工智能能力模型

今年，我们推出了首个 DORA 人工智能（AI）能力模型，这是我们研究工作的一项重要进展。在各组织应对人工智能落地的复杂挑战时，该模型提供了一个基于数据的框架，来指引其发展路径。模型明确了七大关键能力——这些能力经培育后，能显著放大人工智能为组织层面带来积极的影响和收益。

七大关键能力包括：

- 明确且已共识的人工智能立场
- 健康的数据生态系统
- 人工智能可访问的内部数据
- 稳健的版本控制实践

- 小批量工作
- 以用户为中心
- 高质量的内部平台

该模型是我们推出的首个迭代版本，我们将其视为与 DORA 社区及拥抱 AI 辅助软件开发的组织展开持续交流的起点。

我们期待了解您在应用这些洞见过程中的实践经验，并期望在未来的研究中，对该模型进行验证与完善。

以用户为中心

本年度研究揭示了一项关键洞察：当前我们仍处于 AI 辅助软件开发的早期阶段——这是一个技术与实践均快速演进的时期，此时过早推行标准化为时尚早。

研究结果表明，单纯部署 AI 工具并非实现转型的“万能解决方案”。事实上，AI 对团队效能表现的影响，高度依赖于一个关键因素：以用户为中心的理念。

我们的研究发现，当团队秉持以用户为中心的理念时，AI 对其效能表现的积极影响会显著增强；反之，若缺乏这一理念，采用 AI 技术反而可能对团队效能表现产生负面影响。

这一发现向所有组织传递了至关重要的启示：致力于培养对用户的深刻理解不仅有益，更是人工智能应用成功的先决条件。若未将用户置于战略核心位置，人工智能应用不仅难以提升团队效能，甚至可能阻碍其发展。

从研究到落地：邀您开启探索之旅

本年度报告中的研究结论具有一定复杂性，有时甚至可能呈现出看似矛盾的特征。这一现象恰恰反映了该领域处于动态变化中的真实状态。我们建议，您不必将这些研究结论视为僵化的固定方案，而应将其作为开展自身实践探索的假设依据。

以下是将报告研究成果付诸实践的几种方式：

- **在组织内部开展实践探索：**借助 DORA 的研究结论构建假设，并在团队中开展验证。这一过程能帮助您更深入地了解自身独特的运营场景，进而明确最具改进价值的关键领域。

- **开展内部调研：**可参考报告本年度调研问卷中的问题设计思路，设计更贴合团队工作与项目需求的精细化问卷。
- **关注整体体验优化：**需谨记，仅优化单一功能无法解决平台本身存在的缺陷。应将内部平台当作产品打造，聚焦从反馈闭环到自动化流程的全周期开发者体验。

- **分享实践所得经验：**在开展实践探索、积累洞察的过程中，可通过正式报告、非正式实践社区交流或日常沟通等方式，在组织内部传递相关经验。此举旨在培育持续学习的组织文化。

在人工智能持续演进过程中的最大风险并非落后于人，而是对混乱活动投入巨资却未能产生有实质价值的成效。选择能与组织产生共鸣并推动行动落实的框架与方法。

加入讨论

感谢您参与我们的研究。
我们诚邀您继续与我们同行。

请访问：

<https://dora.community>。

加入 DORA 社区，分享实践经验、汲取同行智慧、获取创新灵感。



致谢

DORA 研究展现出了一个充满热情、全球协作社区的巨大能量。我们衷心感谢数千名研究者、专家、实践者、管理者和变革推动者。他们慷慨分享自身的知识与经验，为本研究提供了重要支持。本报告的诞生，正是这一集体努力的直接成果。

我们同样要感谢作为读者的您。我们期望这些发现能助您及团队在组织内积极推动变革，实现持续改进。

研究合作伙伴

《2025 年 DORA 报告》由谷歌云（Google Cloud）与 IT Revolution 联合发布，以下机构为本次研究的合作方。

发布机构



研究合作伙伴




赞助机构

2025 年 DORA 报告获得以下赞助方的支持。如需了解这些赞助机构的更多信息，可访问 DORA 官方网站。¹

铂金赞助商



金牌赞助商



银牌赞助商



DORA 报告团队

Matt Beane, Ph.D.
James Brookbank
Kim Castillo
Sarah D'Angelo, Ph.D.
Derek DeBellis
Rob Edwards
Edward Fraser
Benjamin Good
Nathen Harvey
Sarah Inman, Ph.D.
Eirini Kalliamvakou, Ph.D.
Gene Kim
Eric Maxwell
Ambar Murillo
Allison Park
Daniel Rock, Ph.D.
Kevin M. Storer, Ph.D.
Daniella Villalba, Ph.D.
Steve Yegge
Jessie Young

编辑	Blanca Delgado	Jerome Simms
Seth Rosenblatt	Thomas De Meo	Dustin Smith
Accuracy Matters ²	Nicole Forsgren, Ph.D.	Dave Stanke
DORA 社区指导	Vivian Hu	Laura Tacho
Dhruv Agarwal	Jez Humble	Adrienne Braganza Tacke
Lisa Crispin	Michelle Irvine	Finn Toner
Steve Fenton	Ben Jose	Cedric Yao
Denali Lumma	Deepti Kamat	Members of the DORA community
Betsalel (Saul) Williamson	Amanda Lewis	
	Mike Long	调研设计合作伙伴
	Steve McGhee	Apparent ³ DORA branding
领域顾问/专家	Rebecca Murphey	Human After All: ⁴ DORA report design
Ameer Abbas	Jacek Ostrowski	Prolific: ⁵ Research infrastructure support
Colette Alexander	Justin Reock	User Research International: Research infrastructure support
Christy Barrett	Willy Rouvre	
Sander Bogdan	Ryan J. Salva	
Kevin Borders	Harini Sampath	
Adam Brown	Dadisi Sanyika	
Michele Chubirka	Robin Savinar	
Andrew Davis	Sean Sedlock	

1. “DORA 2025 Sponsors.” <https://dora.dev/research/2025/sponsors>

2. “Accuracy Matters.” <https://accuracymatters.co.uk>

3. “We Are Apparent.” <https://apparent.com.au>

4. “Human After All: Clarity through creativity.” <https://www.humanafterall.studio>

5. “Prolific | Easily collect high-quality data from real people.” <https://www.prolific.com>

6. “User Research for Product Development | User Research International.” <https://www.uriux.com>

作者



Derek DeBellis

Derek DeBellis 自 2022 年起主导 DORA 研究项目，现与 Kevin M. Storer 共同牵头该项目，合作十分顺利。

他的核心驱动力源于一个问题：如何助力人们愉快且高效地协同工作？这一思考推动着他在 DORA 的工作，也驱动着他独立研究权力动态、学习架构及信念传播机制。

未进行数据分析时，Derek 常在科罗拉多落基山脉越野跑（常扭伤脚踝）、阅读卡夫卡与博尔赫斯著作，或录制音乐。



Kevin M. Storer

Kevin M. Storer 领导谷歌云 DORA 团队的人种学研究工作。

其研究重点在于理解组织如何最优调整软件开发实践，以应对生成式 AI（尤其在编程领域）的最新进展。



Nathen Harvey

Nathen Harvey 负责领导谷歌云 DORA 团队，运用研究成果帮助企业提升软件交付的速度、稳定性与效率。

他专注于提升开发者体验，致力于发展 DORA 社区等技术社区，为学习与协作创造机遇。



Matt Beane, Ph. D.

Matt Beane 是加州大学圣塔芭芭拉分校技术管理副教授、斯坦福大学与麻省理工学院数字研究员，同时担任 SkillBench 公司首席执行官及联合创始人。该公司致力于通过生成式 AI 应用提升企业生产力与技能水平。

自 2011 年起，他持续研究智能技术的部署和应用。他著有《The Skill Code: How to Save Human Ability in an Age of Intelligent Machines》（HarperCollins 出版社，2024 年）。



Rob Edwards

Rob Edwards 担任谷歌云软件交付与开发者体验负责人。他与客户紧密合作助力工程团队更顺畅、更可靠地构建与交付软件产品。

他秉持这样的信念：最佳的技术解决方案一定是从人们为共同目标协作努力，将技术转化为商业成功的过程演化而来的。



Edward Fraser

Edward Fraserr 是加州大学伯克利分校（UC Berkeley）信息学院的研究生，其研究方向聚焦于如何通过人机交互与新兴技术，打造更具直观性、赋能性的体验。

凭借在设计与产品管理领域的专业经验，他近期的研究工作涵盖多个领域：包括针对开发者使用 AI 编码辅助工具的眼动追踪研究、面向企业级 AI 工具的用户体验（UX）研究，以及为被监禁学习者设计教育平台的相关工作。

作者



Benjamin Good

Benjamin Good 现任谷歌云解决方案架构师。他致力于通过云技术与自动化优化软件交付实践。

作为解决方案架构师，他通过提供架构指导、发布技术指南及开源贡献，助力谷歌云客户解决各类难题。加入谷歌之前，本曾在丹佛/博尔德地区多家企业主导云运营，期间成功构建多个平台体系。



Eirini Kalliamvakou

Dr.Eirini Kalliamvakou 现担任 GitHub 首席执行官的研究顾问，此前为首席研究员。她专注于研究开发者的需求、动机及行为模式。

其研究成果为 GitHub 的评估体系、创新战略及品牌叙事提供核心洞见，关于 AI 工具与开发者体验（DevEx）的研究正重塑行业实践与社区生态。



Gene Kim

Gene Kim 是屡获殊荣的研究者兼作家。自 1999 年以来，他持续研究高效能技术组织的运作机制。

他的著作销量已超百万册——作为《华尔街日报》畅销书作者，其作品包括《独角兽项目》，并合著了《凤凰项目》《DevOps 实践指南》以及两部荣获新乡卓越奖的《加速》与《打造制胜组织》。

2025 年，他荣获美国质量协会（ASQ）颁发的菲利普·克劳士比奖章。其最新著作《氛围编程》与史蒂夫·耶格合著（预计 2025 年 10 月出版）。



Eric Maxwell

Eric Maxwell 的职业生涯始于软件工程一线，对自动化的热忱与对同行的深切共情始终驱动着他。这段奠基性经历成为他如今领导谷歌 10x 技术咨询实践的核心基石。

埃里克为全球顶尖企业提供咨询，指导其通过技术、流程及文化的战略升级实现组织转型，从而加速价值交付。他将其专业洞见贡献于著名的 DORA 研究团队。在加入谷歌前，埃里克就职于 Chef Software 公司，期间他精进了基础设施自动化技能并持续创造卓越成果。



Sarah D'Angelo, Ph. D.

Sarah D'Angelo 是谷歌核心实验室团队的资深用户体验研究员。



Sarah Inman

Sarah Inman 任谷歌 Chrome 团队高级用户体验研究员。



Ambar Murillo

Ambar Murillo 是谷歌人工智能与基础设施团队的用户体验研究专员。



Daniella Villalba, Ph. D.

Daniella Villalbais 是谷歌云的高级用户体验研究员。她的研究聚焦于理解开发者群体。

个人与企业 统计概况

DORA 研究项目十余年来始终致力于探索高效能技术驱动型组织的核心能力、实践方法与度量标准。在此期间，我们收集了约 4.5 万名专业人士的反馈，这些受访者来自不同规模、不同行业的各类组。

今年，全球近 5,000 名不同行业的从业者分享了他们的经验，帮助我们深化理解人工智能如何变革软件开发，以及组织在此新范式下持续发展的必要条件。

本章将详细阐述受访者的背景信息，包括身份特征、地域分布及其在软件开发中的职能角色。

谨向所有分享洞见的参与者致以诚挚谢意！

受访者的个人特征

本年度共有 4,867 名受访者参与调研，覆盖多类人群、地区和行业领域。

个人特征

年龄

我们采用开放式问答形式采集受访者年龄数据。

受访样本的年龄中位数为 41 岁。

受访者年龄分布




图54：受访者年龄分布

性别

调研数据显示：62.8%受访者自述为男性，19.2%为女性，1.1%为非二元性别，0.5%选择自我描述性别，2.1%拒绝回答此问题。

受访者性别分布





图55：受访者性别分布

残障情况

我们依据“联合国华盛顿小组残疾功能状况量表”所提供的指导，从六个维度识别残障状况。2 今年是我们了解残障情况的第六年。

自报残障状况分布




图表 56: 自报残障情况分布

职业角色

我们在调查中设置了大量职业角色选项，以涵盖参与软件开发过程的多种角色形式。

这些数据中最具代表性的角色是全栈开发者、工程经理和后端开发工程师。

受访者角色分布




图表 57: 受访者角色分布

从业经验

我们请受访者上报其担任当前或类似职位的累计工作年限。

受访者担任当前职位的工作年限的中位数为六年。

受访者从业经验分布




图表58：受访者从业经验分布

团队经验

我们要求受访者报告其在当前团队的工作年限。

受访者在当前团队的任职时间的中位数为三年。

受访者团队任职时间分布




图表59：受访者团队任职时长分布

工作地点分布

我们询问受访者最近五个工作日大约有多少比例时间现场办公。

尽管存在更广泛的返岗工作潮，依然有 800 名受访者在最近五个工作日完全远程办公。最近五个工作日的现场办公时长中位数为 50%，这表明混合办公模式最为盛行。


现场办公时长分布



编程语言

我们请受访者选择工作中最常用的编程语言（最多三项），有近半数的受访者在工作中使用 Python，约三分之一的受访者分别使用 JavaScript 和 SQL

编程语言使用情况




图表 61：编程语言使用情况

企业统计数据

行业

我们要求受访者从 12 个类别中选择其组织所处的主要行业领域。


排除‘其他’选项后，受访者所处组织分布最多的三大行业领域为科技、金融服务以及零售业，消费品和电子商务领域，这与我们 2024 年企业统计数据的前 3 位相匹配。



图表62：受访者行业分布

规模

我们要求受访者从九个区间中选择其组织员工人数规模。受访者所在组织最常见的员工规模为：10,001 人 及 以 上（22.4%）、51 至 200 人（16.2%）以及 1,001 至 5,000 人（14.5%）。



图表63：组织规模分布

服务

AI 赋能的服务与应用程序

我们要求受访者确认在过去三个月内，所接触的应用程序或服务是否有效添加了 AI 驱动的体验功能。赞同与反对的受访者比例基本持平，超过四分之一受访者强烈不同意其应用程序在此期间添加了 AI 驱动的体验功能。

将人工智能主动整合至终端用户服务




图 64：人工智能在终端用户服务中的整合情况

应用程序关键性

我们要求受访者通过说明所负责的应用程序不可用将对组织实现目标和服务客户的能力产生何种程度的影响，来表明该应用程序对企业的关键性程度。超过半数的受访者认为，应用程序不可用将对企业造成‘极大程度’的影响。

主要服务中断的影响





图65：主要服务不可用的影响程度

服务使用年限

我们请受访者说明其负责的主要应用程序或服务已存在的大致年数。受访者负责的应用程序的使用年限的中位数为八年。

主要服务或应用程序使用年限分布




图表66：主要服务或应用程序使用年限分布

服务的用户

我们要求受访者说明其所负责的应用程序所面向的主要终端用户的特征。大多数受访者正在开发商业应用程序，面向内部和外部用户的应用开发数量大。

服务的主要终端用户特征



图表67：主要服务终端用户特征

国家

今年我们收到了来自100多个国家的受访者的反馈。受访者数量最多的国家是美国，其次是英国和印度。



国家

美国	日本	马来西亚	秘鲁	乌拉圭	马达加斯加
英国	新西兰	罗马尼亚	塞尔维亚	越南	摩洛哥
印度	瑞士	爱沙尼亚	斯洛伐克	安道尔	尼加拉瓜
德国	匈牙利	斯洛文尼亚	泰国	亚美尼亚	巴拿马
加拿大	比利时	印度尼西亚	乌克兰	巴哈马	巴拉圭
荷兰	丹麦	阿拉伯联合酋长国	阿富汗	巴林	摩尔多瓦共和国
澳大利亚	挪威	保加利亚	厄瓜多尔	白俄罗斯	索马里
法国	爱尔兰	克罗地亚	萨尔瓦多	玻利维亚	斯里兰卡
葡萄牙	智利	哥斯达黎加	约旦	布基纳法索	前南斯拉夫 马其顿共和国
波兰	菲律宾	尼日利亚	肯尼亚	刚果民主共和国	突尼斯
墨西哥	希腊	俄罗斯	立陶宛	埃塞俄比亚	乌干达
瑞典	以色列	土耳其	马耳他	格林纳达	也门
西班牙	新加坡	孟加拉国	韩国	香港（中国特别行政区）	赞比亚
不适用	芬兰	中国	阿尔及利亚	冰岛	
格鲁吉亚	奥地利	哥斯达黎加	塞浦路斯	伊朗	
意大利	捷克共和国	埃及	科特迪瓦	哈萨克斯坦	
南非	阿根廷	拉脱维亚	多米尼加共和国	黎巴嫩	
巴西	哥伦比亚	巴基斯坦	危地马拉	卢森堡	

颜色深度表示各国受访者数量，色调越深代表参与人数越多。

参与面谈的受访者个人特征

纳入我们面谈的唯一标准是参与者需以某种形式参与专业软件开发工作。我们的筛选问卷除确认工作性质、所在地及语言能力所需信息外，不收集参与者的个人资料。总计有 78 位符合标准的参与者接受了面谈。

关于工作职责的调研显示：70 位受访者表示亲自编写或修改源代码，37 位负责管理软件开发流程和/或开发基础设施，15 位参与开发产品与服务的采购决策，12 位负责制定及更新技术应用的组织政策，另有两位表示其工作仅通过一些其他方式与软件开发产生关联。

尽管上述职责表明受访者的岗位通常具有多重属性，我们仍请受访者从以下选项中选择最贴切的描述：“我是软件开发人员”、“我负责管理软件开发基础设施”、“我管理软件开发团队”、“我为组织制定软件开发相关政策”、“我决策软件开发相关产品与服务的采购”、“我的工作与软件开发完全无关”、“我的工作以未列明的方式涉及软件开发。”

67 位受访者自述主要身份为软件开发人员，7 位自述主要担任软件开发团队管理者，1 位表示主要负责软件开发基础设施运维，另有 3 位表示其工作仅通过一些其他方式与软件开发产生关联。

76 位受访者位于美国，1 位位于墨西哥，1 位位于特立尼达和多巴哥。考虑到访谈者的语言能力与日程安排限制，绝大多数参与者位于美国的情况并不令人意外。

1. 由于调查条件限制或数据缺失，并非所有受访者都参与每项分析。
2. “《联合国华盛顿小组残疾功能状况量表 (WG-SS)》” <https://www.washingtongroup-disability.com/question-sets/wg-short-set-on-functioning-wg-ss/>

方法论

A 方法论应该是如同食谱一般，使我们能够复制我们的工作，并确信我们的数据生成和分析的方式能否反馈有价值的信息。虽然限于篇幅我们无法深入探讨具体细节，但希望能为这样的思考提供一个良好的起点。

Derek DeBellis

定量用户体验研究员，Google Cloud

Kevin M. Storer, Ph.D.

用户体验研究员，Google Cloud

调研项目的设置

问题筛选

我们在决定是否将某个问题纳入调查时，会考量以下维度：

该问题是否……

- 能使我们将现有工作与之前的成果连接起来？
- 捕捉行业渴望达到的成果（例如，较高的团队效能）？
- 捕捉行业正在考虑投入资源的领域（例如，人工智能）？
- 捕捉我们坚信将帮助人们实现目标的地方（例如，高质量文档）？
- 帮助我们评估样本是否有代表性（例如，角色或性别）？
- 帮助我们阻止偏差路径（例如，编码语言或角色）？
- 对于绝大多数受访者来说，能够至少比较准确的回答问题？

我们通过文献研究、DORA 社区互动、认知访谈、并行定性研究、领域专家协作及团队研讨会，综合评估是否将问题纳入调查问卷。

调研体验

我们非常注重提升调研的可用性。通过开展认知访谈和可用性测试，确保调查符合以下规范要求：

- 完成调查所需的平均时间应该较短
- 问卷的可理解度应该较高
- 问题应当合理不费解，这在一些技术性质的概念上是个巨大的挑战

数据收集

本地化

来自世界各地的人们每年都会参与我们的调查。今年，为了使调查更易于被更广泛的受众所接受，我们将调查问卷进行了本地化，语言包括英语、西班牙语、法语、葡萄牙语、日语和简体中文。

收集调查反馈

我们使用多种渠道招募受访者。这些渠道可以分为两类：广泛调研渠道和受控渠道。

广泛调研渠道是指利用我们所能利用的所有社交手段，让人们知道我们想要他们参加一项调查。我们创建博客文章，使用电子邮件营销活动，在社交媒体上进行发布，并请社区中的其他人也这样做（也就是雪球抽样）。

我们使用受控渠道来补充广泛调研渠道。在这里，我们尝试招募被技术社区广泛认为是弱势群体的受访者，并尝试获得特定行业和组织类型的足够响应。

简而言之，这就是我们在招募过程中进行一定控制的地方，而广泛调研渠道则无法实现这种控制。受控渠道还能确保获得足够的响应，因为我们并不知道广泛调研渠道是否会得到执行类型分析所需的响应。

调研流程

今年我们有很多问题询问，但没有足够的时间来提问。我们的选择是……

- 制作一份极长的调查问卷
- 选择一部分领域进行重点关注
- 随机分配人员到不同的主题

我们不想放弃任何感兴趣的地方，因此我们选择随机将受访者分配到四个不同的主题中。这四个不同的主题之间有很多重叠，但每个主题均聚焦于不同的领域进行深入探讨。

以下是四种不同的路径：

- 人工智能
- 平台工程
- 社会认知层面
- 人工智能能力

访谈

去年我们引入了深度半结构化访谈，通过定性数据对年度调查进行补充，以此实现定量研究结果的三角验证、情境化阐释和精准解读。

今年我们刻意扩大了定性数据的研究作用，自 2024 年 7 月至 2025 年 7 月持续对软件开发专业人士进行访谈。

除利用这些洞见厘清调查结果外，我们还运用定性数据生成新假设并在调查中进行验证。

尤其是涉及人工智能辅助及人工智能驱动开发范式中的新兴实践。

本次访谈的提纲涵盖了软件开发中人工智能应用的基础主题，同时允许灵活地探讨参与者即时提出的关注点。单次访谈的设计时长为 90 分钟，均采纳远程方式进行。

通过问卷筛选和电话筛选，我们最终访谈了 78 名经核实的专业从事软件开发的参与者。所有访谈均以视频和音频形式记录。访谈内容均通过自动化软件进行转录。本报告最终出版物中引用的参与者陈述，在收录前均经过重新核对并手动转录。报告作者在参与者引文中增补或修改的文字以方括号([])标注，删除部分以省略号(...)标识。所有修订仅出于提升表述清晰度或保护匿名性的必要考量。

调查分析

去年我们引入了深度半结构化访谈，通过定性数据对年度调查进行补充，以此实现定量研究结果的三角验证、情境化阐释和精准解读。

今年我们刻意扩大了定性数据的研究作用，自 2024 年 7 月至 2025 年 7 月持续对软件开发专业人士进行访谈。

除利用这些洞见厘清调查结果外，我们还运用定性数据生成新假设并在调查中进行验证。

尤其是涉及人工智能辅助及人工智能驱动开发范式中的新兴实践。

本次访谈的提纲涵盖了软件开发中人工智能应用的基础主题，同时允许灵活地探讨参与者即时提出的关注点。单次访谈的设计时长为 90 分钟，均采纳远程方式进行。

通过问卷筛选和电话筛选，我们最终访谈了 78 名经核实的专业从事软件开发的参与者。所有访谈均以视频和音频形式记录。访谈内容均通过自动化软件进行转录。本报告最终出版物中引用的参与者陈述，在收录前均经过重新核对并手动转录。报告作者在参与者引文中增补或修改的文字以方括号([])标注，删除部分以省略号(...)标识。所有修订仅出于提升表述清晰度或保护匿名性的必要考量。

步骤一：定义因果理论（有向无环图）

所有统计模型均包含因果假设，我们的方法是将其呈现出来。相关性未必等同于因果性，但对于因果关系的理解将影响相关性分析结果。我们通过有向无环图 (DAG) 3 来呈现整个运作机制。

该 DAG 是我们基于前期研究、质性工作和领域专业知识构建的因果关系图谱。通过可视化假设，我们使其具备透明性和思辨性，此乃严谨科学的基石。⁴

本例中，我们使用高度简化的 DAG 假设 individual_experience、resources、5 及 stability 是同时影响 ai_adoption 与 individual_effectiveness 的共同成因。

```
# 加载必要库
library(dagitty)
library(ggdag)
library(lavaan)
library(tidyverse)
library(brms)
library(tidybayes)
library(ggplot2)
library(emmeans)
library(performance)
library(semPlot)


# 在简化版有向无环图中定义因果关系
simple_dag <- dagitty('dag {
  ai_adoption [暴露变量]
  individual_effectiveness [结果变量]
  individual_experience [调整变量]
  resources [调整变量]
  stability [调整变量]

  individual_experience -> ai_adoption; resources -> ai_adoption;
  stability -> ai_adoption

  ai_adoption -> individual_effectiveness

  individual_experience -> individual_effectiveness; resources ->
  individual_effectiveness; stability -> individual_effectiveness
}')

# 绘制DAG图可视化理论模型
ggdag(simple_dag, text = FALSE, use_labels = "name") + theme_dag_
blank()
```

这里输出的图表将我们的理论可视化呈现。我们关注的核心是 `ai_adoption` 对 `individual_effectiveness` 的影响，但要准确评估此影响，需理解更广泛的背景因素。该有向无环图 (DAG) 识别出了若干关键协变量，它们是：
`individual_experience` (与角色相关)
`resources` (履行角色所需资源)
`stability` (优先级的稳定度)
 后续我们将通过有向无环图明确标识这些变量。

基于因果理论生成模拟数据

本例将利用 DAG 定义的因果结构模拟一个数据集，包含虚构的数据。

通过已知的因果结构生成数据可获得完美的‘基准真实值’，这是非常有效的，因为它能帮助我们检验分析方法。

如果我们的分析方法无法从该洁净的完美数据中得出正确答案，那么其处理杂乱无章的真实数据的信任度必然存疑。

然而这也是一种简化处理。真实数据包含非线性关系、测量误差、未知因果结构及缺失值等复杂因素，本简化示例已将这些因素排除。

定义包含特定路径系数的模型以生成数据

```
model_specification <- "
```

```
# -- 测量模型 --
```

```
ai_adoption_factor =~ 0.8*use + 0.7*reliance + 0.6*trust
```

```
individual_effectiveness_factor =~ 0.8*effective +  
0.7*productivity + 0.7*impactful + 0.6*flow
```

```
# -- 结构模型（基于DAG的路径） --
```

```
ai_adoption_factor ~ 0.4*individual_experience + 0.3*resources +  
0.2*stability
```

```
individual_effectiveness_factor ~ 0.3*ai_adoption_factor +  
0.3*individual_experience + 0.2*resources + 0.15*stability"
```

```
set.seed(2025)
```

```
simulated_data <- simulateData(model_specification, sample.nobs =  
500)
```

```
#数据概览
```

```
summary(simulated_data)
```

```
glimpse(simulated_data)
```

步骤二：测量模型评估(CFA)

检验因果理论或结构理论前，必须通过验证性因子分析 (CFA) 确保测量工具的有效性 (Kline, 2015)。该步骤验证调查项目能否可靠的测量潜在构造。

我们通过以下标准评估模型：良好的全局拟合度、健壮局部因子载荷、且修正指数显示无显著模型压力点。

```
# 定义模型的纯测量部分
measurement_model <- "
ai_adoption_factor =~ use + reliance + trust
individual_effectiveness_factor =~ effective + productivity +
impactful + flow
"

# 将CFA模型拟合到模拟数据
cfa_fit <- cfa(measurement_model, data = simulated_data)

# 查看拟合指数、因子载荷和修正指数
summary(cfa_fit, fit.measures = TRUE, standardized = TRUE)
modificationindices(cfa_fit, sort = TRUE, minimum.value = 10)
```

这是该模型的部分输出结果。

```
> summary(cfa_fit, fit.measures = TRUE,
standardized = TRUE)

lavaan 0.6-19 ended normally after 34 iterations

估值方法          ML
优化算法      NLMINB
模型参数样本量    15

观测样本量      500

用户模型检验:

检验统计量      7.579
自由度          13
P值 (卡方检验)    0.870

M模型检验基线模型:
检验统计量      651.579
自由度          21
P值              0.000

用户模型与基线模型对比:

比较拟合指数 (CFI)    1.000
塔克-刘易斯指数 (TLI)  1.014
```

对数似然值与信息准则:

用户模型对数似然值 (H0) -5515.401
无约束模型对数似然值 (H1) -5511.612

赤池信息准则 (AIC) 11060.803
贝叶斯信息准则 (BIC) 11124.022
样本量调整贝叶斯信息准则 (SABIC) 11076.411

近似均方根误差:

RMSEA 0.000
90%置信区间下限 0.000
90%置信区间上限 0.023
零假设P值: RMSEA <= 0.050 0.999
P值 H_0 H_0: RMSEA >= 0.080 0.000

标准化均方根残差:

SRMR 0.017



如何解释验证性因子分析 (CFA) 的输出结果 lavaan⁷ 输出提供了丰富的诊断信息。以下将结合输出结果解读关键部分。

1. 卡方检验(χ^2)。这是完美拟合检验，其零假设为模型与数据完全匹配。

结果：检验统计量= 7.579，自由度 = 13，P 值 = 0.870

准则：期望获得不显著结果 ($p > .05$)。

解读：P 值极高(0.870)，意味着无法拒绝零假设。该检验表明，从统计学角度无法区分本模型结构与完美拟合的差异。⁸

警告：这是传统且正式的模型拟合统计检验。但对于 DORA 这类超大样本集，该检验过于敏感，即使模型表现优异也几乎总会显示‘拟合不佳’。因此，我们将其作为参考依据，但更侧重于以下实际指标。

2. 增值拟合指数(CFI 和 TLI)。这些指标将模型的拟合度与‘最差情况’基线模型(变量间无关联)进行对比。

计算结果：

CFI = 1.000, TLI = 1.014 判定标准：我们检验数值 > 0.90 (可接受)及 > 0.95 (优秀)。解读：数值达到或超过理论最大值 1.0，表明模型相对于基线模型具有完美拟合度。

(注：在拟合良好的模型中，TLI 有时可能超过 1.0。)

3. 绝对误差指数 (RMSEA 和 SRMR)。这些指标衡量‘拟合劣度’，即模型预测值与实际数据间的平均误差。

RMSEA 结果：

RMSEA= 0.000，90%置信区间为 [0.000, 0.023]

准则：我们检查点估计值 < 0.08 (可接受)和 < 0.06 (优秀)。

解释：

您的 RMSEA 值为零，整个置信区间远低于优秀拟合阈值，表明几乎不存在近似误差。

SRMR 结果：

SRMR = 0.017

准则：

我们检查是否满足值 < 0.08 。

解释：该值极低，表明观测相关性与预测相关性之间的标准化平均差异微乎其微。

4. 因子载荷与修正指数 (结果未显示)。使用标准化因子载荷检查各因子内部载荷是否显著且相似。⁹ 运用修正指数定位模型中存在局部应变的位置。

高修正指数表明这些区域可能存在设定错误。

本例中，所有拟合指数均一致表明该模型与数据的拟合度近乎完美。这正是我们在该特定场景中希望看到的结果。由于数据直接源自该模型的规格参数，完美的拟合度证实了我们的分析方法运行正确，且能还原已知结构。

但需注意：在真实的调查数据中出现如此完美的结果将极不寻常，甚至令人担忧。实际分析中的完美拟合可能意味着模型过于简化而无法匹配数据复杂度，或在某些情况下表明模型因反复调整导致「过度拟合」。

步骤三：模型结构检验与评估(SEM)

通过验证测量后，我们运用结构方程建模 (SEM) 对整个因果理论进行整体拟合检验。SEM 的核心目的是比较有向无环图 (DAG) 所隐含的协方差结构与实际数据观测到的协方差结构。

优质模型的标准在于理论预测与现实情况高度吻合。我们正在评估理论模型与观测数据的匹配程度。

```
#定义理论模型

# 通过指定路径系数定义模型以生成数据

structural_model <- "

# -- 测量模型 --

ai_adoption_factor =~ use + reliance + trust
individual_effectiveness_factor =~ effective +
productivity + impactful + flow

# -- 结构模型（基于DAG的路径） --

ai_adoption_factor ~ individual_experience +
resources + stability

individual_effectiveness_factor ~ ai_adoption_
factor + individual_experience + resources +
stability
"

# 对数据拟合完整SEM以估计路径系数

sem_fit <- sem(model_specification, data =
simulated_data)

# 执行完整的summary方法获取拟合指标、载荷及路径系数

sem_summary <- summary(sem_fit, standardized =
TRUE, rsquare = TRUE)

sem_summary
```

```
# 检查局部拟合的特定区域

residuals(sem_fit, type = "standardized")

modificationindices(sem_fit, sort. = TRUE,
minimum.value = 10)

# --- 生成最简的单色SEM路径图 ---

semPaths(sem_fit,

# --- 核心内容 ---

what = "std", # 重要提示：显示路径上的标准化系数

whatLabels = "est", # 显示估计值（即系数）

# --- Layout & Sizing ---

layout = "tree2", # 清晰的分层布局

rotation = 2, # 该设置旋转布局以获得更佳视图效果（
通常采纳自上而下方向）

sizeMan = 8, # 显变量（方框）尺寸（即方框尺寸）

sizeLat = 10, # 潜变量（圆形）尺寸（圆形尺寸）

edge.label.cex = 0.8, # 路径系数字体大小

nCharNodes = 0, # 确保完整显示变量名称

# --- 简约美学风格 ---

style = "ram", # 源自RAM规范的简洁绘制风格

residuals = FALSE, # 隐藏残差方差以减少杂乱

intercepts = FALSE, # 隐藏截距以简化模型

# --- 单色主题 ---

color = "white", # 所有形状的填充色

edge.color = "black", # 所有箭头的颜色

border.color = "black", # 形状边框颜色

border.width = 1.5, # 边框 厚度

label.color = "black" 箭头上文本的颜色)
```


结构方程模型评估方法

判断模型是否‘良好’需综合考察多项指标，这些指标可分为两类：

1. **整体拟合度：**基于全局视角⁹ 这些指标反映模型整体再现数据的匹配程度。

卡方检验(χ^2)：完美拟合检验，用于验证模型与数据完全匹配的零假设

CFI 与 TLI：比较拟合指数(CFI)和塔克-刘易斯指数(TLI)用于衡量当前模型相较于‘最差情况’基准模型的优化程度。我们通常要求其值 >0.90 （可接受）或 >0.95 （优秀）。

RMSEA：近似误差均方根(RMSEA)作为‘失拟度’指标，用于量化模型的平均误差水平。我们通常要求其值 <0.08 （可接受）或 <0.06 （优秀）。

2. **局部拟合度：**深度检测模型内部结构这些诊断方法有助于识别模型中存在的具体缺陷点。


因子载荷：在标准化输出中，我们要求各观测项在其对应潜因子上的载荷系数应具有统计显著性且数值较高（理想状态 >0.50 ）。该结果可验证测量模型的健壮性。

标准化残差：显示模型中每个独立关系的误差。

我们要求不存在过大残差值（例如绝对值均不超过2.58），否则就表明特定变量关系的理论预测存在偏差。

修正指数：这些‘如果……会怎样’式的统计量揭示了模型承受最大压力的环节。我们通过较大的值来诊断问题（例如某个测量项同时反映两个概念），但若无充分理论依据则避免据此盲目修改模型。

优质模型需具备可接受的全局拟合度、健壮的因子载荷量，且无显著局部应力迹象。正是这种包含多维证据的体系，赋予我们对模型结构的信心。



检验理论模型的预测效力

我们的有向无环图还生成了一组可验证的预测，称为‘隐含条件独立性’。这组预测聚焦于变量间不存在关联的具体情境，可将其视为检验理论模型的‘不在场证明’。若预测成立，该模型的可信度则相应提升。

当运行

``impliedConditionalIndependencies(simple_dag)`` 时，我们注意到：

```
ind_||_rsrc
ind_||_stbl
rsrc_||_stbl
```

这些论断是我们因果模型的核心预测，表明个人经验、可用资源及其团队的稳定性三者相互独立。换言之，了解团队的可用资源水平，并不能反映出关于个人在该团队中的经验或团队整体稳定性的任何信息。

我们首先通过检查原始模型中的协方差进行非正式验证。所有协方差值均接近 0，这提供了相当有力的证据。

我们还可尝试更正式的检验方法：将这些隐含条件纳入结构方程模型构建。

具体实现方式是将相关参数约束为 0。在先前模型中，我们允许这些参数自由取值；而当前模型则强制设为零值。

关键结果来自 `anova()` 函数执行的卡方差异检验。这提供了原始模型 (`sem_fit`) 与限制性模型 (`constrained_fit`) 之间的正式比较，在后者中强制将协方差设为零。关键在于：‘强制将这些关系设为零是否显著损害了模型的拟合度？’

请查看此输出的 "协方差" 部分

```
summary(sem_fit, standardized = TRUE)
```

正式检验隐含条件独立性 ---

获取隐含条件独立性

```
impliedConditionalIndependencies(simple_dag)
```

可直接检查协方差

```
sem_summary$pe %>% filter(op == "~~",
  lhs %in% c("individual_experience",
    "resources",
    "stability"))
```

1. 定义新的约束模型字符串

```
constrained_model_string <- "
```

-- 测量模型 --

```
ai_adoption_factor =~ use + reliance + trust
individual_effectiveness_factor =~ effective +
productivity + impactful + flow
```

-- 结构模型（基于DAG的路径） --

```
ai_adoption_factor ~ individual_experience +
resources + stability
```

```
individual_effectiveness_factor ~ ai_adoption_
factor + individual_experience + resources +
stability
```

--- 新增约束 ---

我们现根据DAG的隐含意义，明确强制协方差为零

```
individual_experience ~~ 0*resources
```

```
individual_experience ~~ 0*stability
```

```
resources ~~ 0*stability
```

```
"
```

2. 拟合约束模型

```
constrained_fit <- sem(constrained_model_string,
data = simulated_data)
```

3. 比较原始模型(`sem_fit`)与约束模型

非显著p值意味着数据支持这些约束条件

```
anova(sem_fit, constrained_fit)
```

	Df	AIC	BIC	Chisq	Chisq diff	RMSEA	Df diff	Pr(>Chisq)
sem_fit	28	10952	11040	21.454				
constrained_fit	31	15319	15420	24.980	3.5267	0.018739	3	0.3173

结果表明，将这三个协方差限制为零并未显著损害模型拟合。

卡方差异 (Chi-squared difference):

这是施加约束后模型拟合度下降的原始度量值

计算结果:

3.5267。单看这个数字很难解读其含义。

Df diff (自由度差异):

这表示添加的约束条件数量。

计算结果:

3. 结论正确，因为强制将三个协方差设为零。

Pr(>Chisq) (P 值):

这是最重要的数值。

它表示若约束条件在总体中实际成立，出现 3.5267 或更大卡方差异的概率。

计算结果:

0.3173.

简言之，研究推论成立，且约束模型是更简约的建模方案。

步骤四：通过贝叶斯模型进行估计比较

在对 DAG 结构建立信心后，我们转向核心问题。利用 DAG 确定正确的调整集，随后拟合贝叶斯模型。

虽然采纳因果框架，但我们将结果解读为原则性比较，承认观察数据的局限性 (Gelman et al., 2020)。

先验分布设置

在众多结果中测试预测因子的方法会引发多重比较问题。为此，我们在所有模型中为预测因子设置统一、持怀疑态度的贝叶斯先验分布。¹⁰这构成抵御随机性误导的原则性防护机制。通过设置怀疑先验 (student_t(3, 0, 0.5))，¹¹我们正式构建了‘真实效应可能较小’的信念，从而控制假阳性率。¹²

确定调整集

有向无环图 (DAG) 将明确模型中需要包含的变量，更重要的是，会指出不应包含的变量。若 DAG 构建正确，纳入这些变量应能阻隔偏执路径，避免影响 AI 采纳率 (暴露变量) 对个体效能 (结果变量) 效应的估计偏差。

识别调整集

```
adjustmentSets(simple_dag, exposure = "ai_
adoption", outcome = "individual_effectiveness")
```

准备数据

```
model_data <- simulated_data %>%
mutate(
  ai_adoption_score = rowMeans(select(., use,
reliance, trust)),
  individual_effectiveness_score =
rowMeans(select(., effective, productivity,
impactful, flow))
) %>%
mutate(across(c(ai_adoption_score, individual_
experience, resources, stability), scale))
```

定义先验分布

```
priors <- c(prior(student_t(3, 0, 0.5), class
= "b"), prior(student_t(3, 0, 2.5), class =
"Intercept"), prior(exponential(1), class =
"sigma"))
```

拟合模型

```
baseline_model <- brm(formula = individual_
effectiveness_score ~ individual_experience +
resources + stability, data = model_data, family
= gaussian(), prior = priors, chains = 4, iter
= 4000, warmup = 2000, seed = 2025, silent = 2,
refresh = 0)
```

```
full_model <- brm(formula = individual_
effectiveness_score ~ ai_adoption_score +
individual_experience + resources + stability,
data = model_data, family = gaussian(), prior =
priors, chains = 4, iter = 4000, warmup = 2000,
seed = 2025, silent = 2, refresh = 0)
```

使用留一法比较模型

```
# loo_compare <- loo(baseline_model, full_model)
# print(loo_compare)
```

包含89%可信区间的系数摘要

```
posterior_summary(full_model, probs = c(1-
.11/2,.11/2))
```

S型错误(近似p值)

```
1 - mean(as.matrix(full_model)[,"b_ai_adoption_
score"] > 0)
```

我们认为单一指标永远不足以全面理解模型。因此我们通过四个关键维度来评估证据，将数据中的不确定性转化为知识来源。

1. 预测准确度是否提升？（留一法结果）

是。留一法比较显示完整模型具有明显优势（elpd_diff = 10.7, se_diff = 5.2）。¹³

这是我们首项实证依据：

引入 AI 采纳率评分变量后构建的模型，预期能在新数据上获得更优的预测表现。这并非统计噪声，而是具有预测效用的关键变量。

2. 效应是否始终处于零值同侧？（S型错误检验）

是。检查 b_ai_adoption_score 的后验汇总：

Estimate Est.Error Q94.5 Q5.5

b_ai_adoption_score 0.199 0.041 0.265 0.134

AI 采纳率系数的 89%置信区间（Q5.5 至 Q94.5）为[0.13, 0.26]，整个区间显著高于零值。这表明发生 S 型（符号）错误的概率极低。我们可高度确信该相关性呈正向关系。

3. 我们是否认识到了效应规模？（M 型错误检验） 是。该模型清晰呈现了效应量级。最佳估计值为：AI 采用率每提升一个标准差，效能相应增加 0.20 个标准差。置信区间[0.13, 0.26]提供了该效应的合理范围估计。其影响不算庞大，但也不可忽视，且该估算具有合理的精确度。	4. 这与我们的理论是否一致？ 是。我们最初提到的有向无环图假设了从 AI 采纳率到个体效能存在直接正向的因果路径。所有收集的统计证据——从结构方程模型的结构验证，到留一法比较及最终的后验估计——均与这一理论主张相符。数据支持了我们最初提出的理论框架。	综合论证 通过整合这四个视角，我们跳出了‘某因素是否显著’的简单思维定式。所得的证据一致表明：AI 采纳率与效能提升之间的关系具有预测实用性、方向稳定性、量级适中和估算清晰的特点，且在理论层面站得住脚。该方法可避免‘被偶然超过统计显著性阈值的噪声模式所误导’¹⁴
--	--	--


步骤五：模型置信度诊断¹⁵

模型拟合并非终点。我们执行一系列严格的诊断检查以确保结果可靠。¹⁶ 包括检查 MC MC 收敛性（$\hat{R} < 1.01$，高 ESS 值），执行后验预测检验确保模型能复现观测数据，并通过残差分析验证模型假设（Gelman et al., 2013）。这个话题值得单独成章探讨。 此处，我们仅分享若干值得关注的重要诊断检查项。这些方法具有广泛适用性，从基础模型到高级模型皆可应用，因此值得深入了解。基本分类如下：	计算健康性： 首先确保模型算法正确运行并生成稳定的估计值。这是对模型计算引擎的技术性检验，用以确保结果可靠性（例如检验 $\hat{R}$ 统计量是否小于 1.01）。 预测一致性： 随后检验模型预测结果是否与我们最初使用的真实数据相吻合。我们使用该模型模拟数据，并检验其与真实观测数据的吻合度。一个无法还原历史数据的模型，对当前现象的解释力也无法令人信服。	统计有效性： 最后，我们验证模型的核心统计假设是否成立。这需要检查模型误差（残差），确保未违反线性关系等基本原则。
---	--	--

```
print("--- Convergence Diagnostics (R-hat, ESS) ---")
summary(full_model)
print("--- Visual Trace Plots ---")
plot(full_model, N = 4, ask = FALSE)
print("--- Posterior Predictive Check ---")
pp_check(full_model, ndraws = 100)
print("--- Residual Assumption Checks ---")
check_model(full_model)
```


后验预测检验

模型预测曲线应接近实际观测数据线




线性

参考线应保持水平平直




方差齐性

参考线应保持水平平直



强影响观测值

数据点应处于等高线内部




共线性

高共线性 (VIF) 可能放大参数不确定性



残差正态性

散点应沿线分布



步骤六：可视化估计效应


最终，我们将统计结果转化为直观的可视化效果。我们通过检视主要参数的完整后验分布来解读模型，绘制条件预测图（或估计边际均值）以理解比较的幅度，并在原始数据背景下观察回归线。

在最终结果中，我们报告 89% 置信区间——这一选择旨在揭示 p 值中心思维的任意性，并将重点置于后验分布的稳定高密度区域（McElreath, 2020）。

人工智能采用率对个人效能影响的三种视角


预测的个人效能

人工智能采用率低、均值及高水平的比较




人工智能采用率与效能间的关联

叠加在原始数据上的回归线及89%置信区间



人工智能采用率指数的后验分布

此图展示效应可能取值的完整范围



上图：结果量表的预测值 下图：标准化系数的后验分布

--- 步骤6: 可视化估计效应---

```
print("Generating visualizations...")
```

6a . 后验分布

```
plot_posterior <- full_model %>%  
  spread_draws(b_ai_adoption_score) %>%  
  ggplot(aes(x = b_ai_adoption_score)) +  
  stat_halfeye(fill = "#1565C0") +  
  geom_vline(xintercept = 0, linetype = "dashed") +  
  labs(  
    title = "Posterior Distribution for AI  
Adoption Score",  
    subtitle = "This shows the full range of  
plausible values for the effect.",  
    x = "Coefficient Estimate (Standardized)",  
    y = "Density"  
  ) +  
  theme_minimal()
```

6b. 比较图 (估计边际均值)

```
emm_results <- emmeans(full_model,  
  specs = ~ ai_adoption_  
score,  
  at = list(ai_adoption_  
score = c(-1, 0, 1)),  
  prob = 0.89) # 89%  
置信区间  
  
plot_comparison <- as.data.frame(emm_results) %>%  
  ggplot(aes(x = ai_adoption_score, y = emmean)) +  
  geom_point(size = 4, color = "#1565C0") +  
  geom_errorbar(aes(ymin = lower.HPD, ymax =  
upper.HPD), width = 0.1, linewidth = 1) +  
  labs(  
    title = "Predicted Individual Effectiveness",  
    subtitle = "Comparing low, average, and high  
levels of AI adoption.",  
    x = "AI Adoption Score (Standardized: -1,  
Avg, +1 SD)",  
    y = "Predicted Effectiveness Score"  
  ) +
```

```
theme_minimal() +  
  scale_x_continuous(breaks = c(-1, 0, 1), labels  
= c("Low", "Average", "High"))
```

--- 6c . 背景中的相关性 (带回归线的散点图)

创建参考网格: 沿预测变量范围生成点序列

```
plot_grid <- ref_grid(full_model,  
  at = list(ai_adoption_score  
= seq(min(model_data$ai_adoption_score),  
max(model_data$ai_adoption_score),  
length.out = 100)))  
  
# 获取网格中每个点的预测值 (估计边际均值)  
  
emm_plot_data <- emmeans(plot_grid, "ai_adoption_  
score", prob = 0.89) %>% as.data.frame()
```

使用平滑处理后的新数据绘制图表

```
plot_relationship <- ggplot(emm_plot_data, aes(x  
= ai_adoption_score, y = emmean)) +  
  geom_point(data = model_data, aes(y =  
individual_effectiveness_score), alpha = 0.2,  
color = "gray50") +  
  geom_line(color = "#1565C0", linewidth = 1.5) +  
  # 当前无需对aesthetic进行分组  
  geom_ribbon(aes(ymin = lower.HPD, ymax = upper.  
HPD), alpha = 0.2, fill = "#1565C0") +  
  labs(  
    title = "Relationship Between AI Adoption and  
Effectiveness",  
    subtitle = "Regression line and 89% credible  
interval overlaid on raw data.",  
    x = "AI Adoption Score (Standardized)",  
    y = "Individual Effectiveness Score"  
  ) +  
  theme_minimal()
```



```
#---打印修正后的图表 ---
```

```
print(plot_relationship)
```

```
#---将最终图表输出至屏幕 ---
```

```
print(plot_posterior)
```

```
print(plot_comparison)
```

```
print(plot_relationship)
```

```
#---使用patchwork组合三幅图表 ---
```

```
# '+'运算符实现图表并排显示
```

```
# '/'运算符实现纵向堆叠 combined_plot
```

```
combined_plot <- (plot_comparison + plot_
relationship) /
```

```
plot_posterior +
```

```
plot_annotation(
```

```
  title = "Three Views of the Effect of AI
Adoption on Individual Effectiveness",
```

```
  caption = "Top: Predictions on the outcome
scale. Bottom: Posterior distribution of the
standardized coefficient."
```

```
)
```

```
#---打印并保存最终组合图
```

```
print(combined_plot)
```

```
ggsave(
```

```
  combined_plot,
```

```
  filename = "combined_plot.svg",
```

```
  height = 6 * .75,
```

```
  width = 9 * .75,
```

```
  dpi = 600
```

```
)
```

```
print("--- Workflow Complete ---")
```



结论

该 workflow 从外显理论到严谨验证、估计与诊断，旨在呈现透明、可信且健壮的洞察结果。

我们希望通过分享此流程，以及“我们的研究模型及其理论”这一章节，使读者能够更有效地评价我们的工作。我们也期待此举能帮助复现我们的研究，以此鼓励人们去运用这些有趣的统计方法。



1. McElreath, Richard Statistical Rethinking: A Bayesian Course with Examples in R and Stan (Chapman and Hall/CRC, 2020).
2. Gelman, Andrew, Jennifer Hill, and Aki Vehtari. Regression and Other Stories of Analytical Methods for Social Research (Cambridge University Press, 2020).
3. The Our research model and its theory chapter provides an overview of this codified theory.
4. Pearl, Judea Causality (Cambridge University Press, 2009).
5. The Our research model and its theory chapter has a much more comprehensive overview.
6. Before we do a confirmatory factor analysis, we do an exploratory factor analysis to understand how the factors fall out before we constrain parameters with a theoretical model. This, in combination with other diagnostics, helps us better understand where our theory might have areas of poor fit.
7. Rosseel Y (2012). "lavaan: An R Package for Structural Equation Modeling." Journal of Statistical Software, 48(2), 1–36. <https://doi.org/10.18637/jss.v048.i02>
8. This is good news for the simpler model. It is essentially saying we don't lose a lot of information by not freely estimating certain parameters.
9. There are formal tests you could use to evaluate this.
10. Good modeling isn't just about fit; it's about finding the simplest model that fits well (Occam's razor). You could keep adding parameters to achieve this. The questions are which parameter is justifiable and how much can you trim without losing much understanding.
11. We also test for how robust the results are to various priors. In the end, we've decided we want to prevent false positives more than false negatives. We don't want people exploring certain areas based on us being tricked by noise.
12. There is a good discussion on the topic here: <https://discourse.mc-stan.org/t/why-studentt-3-0-1-for-prior/8102>
13. For interaction terms, we use an even more skeptical prior ($\text{normal}(0, 0.3)$), as these effects are expected to be smaller.
14. The model on top is the model that is making the best predictions. The elpd_diff should be greater than the se_diff . I start feeling especially confident when elpd_diff is greater than $2 \times \text{se_diff}$ (so, greater than 10.4 or 5.2×2).
15. The earlier you start evaluating these assumptions, the better.
16. Exploring the distributions and patterns in descriptive stats is a sometimes tedious, but crucial part that takes place at the start, before models are even being considered.

我们的研究模型及理论基础

“理论代表一种根本性决策要素，它使世界呈现截然不同的面貌——以全新的视角呈现。” 理论是一种根本性的原始决策，它决定了何为有效何为无效 ……

韩炳哲¹

Derek DeBellis

定量用户体验研究员, 谷歌云

本章阐述了支撑效能分析与评估的理论模型。该模型源于与 DORA 社区的讨论、负责在企业内推进变革的领域专家经验、文献研究及大量定性数据。此模型绝非简单的框图连线练习。其关键性在于：内含的理论性及不可避免的因果假设将指导整个分析过程。细微调整便可能会对分析结果产生重大影响。

相关不等于因果，但我们对因果关系的假设，却影响我们最终能看到怎样的相关性。

本模型对 DORA 框架具有两个独特之处。

首先，我们主要关注采纳 AI 技术带来的影响及其产生作用的条件（AI 能力要素）。这意味着模型的核心设计目标是让我们能够准确估算 AI 的采纳对那些我们认为对技术驱动型组织至关重要的结果变量所产生的影响。

通常模型会尝试预测多种能力与多重结果间的关联性。

其次²，本模型虽以结构方程模型（SEM）层级加以评估，但此举仅用于验证模型的合理性；然后我们再构建针对性的贝叶斯模型，以生成更聚焦、更精细的估计结果。

方法论章节对此做了详尽阐述。本章的基本结构如下：

本章基本论述脉络如下：


模型：对我们整体模型的介绍。

概念：对模型高层概念的说明。

理论：对各路径理论依据的概述。

本章与方法论章节共同呈现了支撑研究结果的理论与分析全貌，旨在将我们的假设和盘托出。我们希望这些阐述能为复制、借鉴和评估本研究提供充分的信息。

模型架构



在我们的因果模型中，各个概念（以方框表示）属于高层次类别。这些类别为了可视化效果做了简化，并不一定对应我们在分析中使用的具体度量指标。模型还包含一些情境性视角，用以帮助我们理解受访者的处境，包括环境特征、服务特征、流程与实践以及个体特征。

AI 采纳是我们通过验证性因子分析提取的一个潜在因子，由反思性使用、信任和依赖三项共同构成。至于结果变量，在执行摘要和“AI 影响”章节中有更详细的说明。

我们倾向于认为此处每个概念都不可或缺。要准确评估 AI 采纳带来的影响，必须厘清其所在的错综复杂的现实关系。

我们采用结构方程模型与有向无环图（DAG）来检验这一理论模型与观测数据的契合程度。一旦模型通过验证，便借助 DAG 对分析进行校正，以获得更精准的估计。

“方法论”章节会深入细节。在这里，我们将重点阐述支撑该模型的概念与理论。

概念体系

AI 采纳

AI 采纳衡量的是人工智能与个人工作流程及思维模式的融合深度。这一概念区分了单纯的工具使用和与技术建立的深度协作关系。我们通过三个核心指标来衡量人工智能采纳：

- 信任度
- 反射式使用
- 依赖程度

流程与实践

这一类别涵盖广泛的能力集合：既包含人工智能专属能力，也涉及团队层面流程与个人层面流程。所有这些能力都体现了工作方式与行为模式的典型特征。

相关构建要素包括：³

- 明确且已共识的人工智能立场
- 健康的数据生态系统
- 人工智能可访问的内部数据
- 稳健的版本控制实践
- 小批量工作
- 以用户为中心
- 高质量的内部平台

这些构成要素均是我们首版人工智能能力模型的重要组成部分，该模型的具体内容已在《人工智能能力模型》章节中详细论述。

个体特质

这一类别涵盖了个体的特定属性，包括其职位角色、年龄及在团队中的任职时长，同时还包括工作性质特征（例如在 AI 相关任务上投入的时间比例）。这些细节为理解个体的技术体验及其与技术平台的交互方式提供了关键背景信息。

这一概念通过以下观测指标进行探究与构建：

- AI 使用时长
- 团队任职年限
- 职位角色
- 年龄阶段
- 任务类型
- AI 专项任务

环境与组织特征

这些概念描述了工作的整体环境和背景，既包括企业规模与行业属性等稳定因素，也涵盖资源可用性和优先级稳定性等动态条件。这种环境背景构成了促进或制约技术应用与整体绩效的基础条件。

服务特征

服务特征定义了应用或服务的核心特征。了解服务的年限、关键性及是否融合人工智能技术，对理解性能度量指标及特定技术实践的相关性至关重要。

组织效能

这是基于盈利能力、市场份额和客户满意度等特征，对组织整体成果的高层级衡量指标。

团队效能

这一因子衡量的是个体所在直接团队的感知效能与协作强度。

产品效能

这一指标从帮助用户完成关键任务、保障信息安全以及减少延迟等性能特征出发，衡量团队所构建产品或服务成功度与质量水平。

软件交付效能

- **软件交付吞吐量：**
这体现了软件交付流程的速度与效率。详见《理解您的 软件交付效能》章节获取深度解析。
- **软件交付不稳定性：**
该指标用于度量软件交付流程的质量与可靠性。详见《理解您的软件交付效能》章节获取深度解析。

个体成果

- **代码质量：**该指标反映个体对 其所开发主要应用或服务底层代码质量的评估。
- **个体效能：**该因子衡量个体对 自身工作效率及工作成就感的自我评估。
- **有价值的工作：**该指标测量个 体自我评估中用于从事其认为有价值工作的时间占比。
- **摩擦阻力：**该指标衡量阻碍 个体工作的摩擦程度。

较低的摩擦值通常被视为积极成果。
- **职业倦怠：**该指标衡量 与工作相关的疲惫感及 消极情绪。我们认为职业倦怠是影响个体工作的关键阻碍因素。

理论基础

若研究结果是建筑结构，分析过程是施工建设，那么理论便是地基根基。本节将阐述这一理论基础，说明模型中那些关键路径为何能够让我们准确估计 AI 的影响。为保持清晰，此处仅聚焦模型的高层关系，并重点标出我们最需要论证的路径。

尽管我们的分析依赖于实例的细微关系，但在此我们仍聚焦于总体的理论关联。我们所强调的每一条分析链路都立足于已有文献、定性研究以及领域专业知识，并经由我们对十多年来持续进行的“高效能驱动力”的研究加以强化而得到。

服务特征 → 软件交付效能

要交付的系统服务其自身的特征决定了交付难度。例如，年代久远的服务往往背负着沉重的技术债，产生摩擦并拖慢交付 4.5。相反，服务是否处于核心地位和其重要程度会成为强大的催化剂，吸引组织的关注与资源投入。这种聚焦可能简化流程，并促使企业投资于自动化测试、SRE 等先进实践，从而同时提升交付速度与系统稳定性。

非核心服务往往得不到这类投入，导致被忽视并不断累积风险，最终形成对效能的拖累，直到事态严重时才显现出来。而融入 AI 的服务则带来 MLOps 的诸多挑战⁶，从根本上改变交付管道的稳定性与速度。

流程与实践 → (多重结果)

DORA 过去十年的研究表明，人员与团队的工作方式决定了他们交付软件、高效工作、协同合作以及最终打造卓越产品的能力。尽管今年探讨的具体实践可能有所不同，且当今开发领域已大量应用人工智能技术，但这一根本原则依然成立。

精心设计的流程

1. 将软件吞吐率与稳定性转化为可复现的成果⁷
2. 减少协调成本，使团队能将精力投入开发学习而非救火式工作和僵化的流程^{8,9}
3. 降低认知负荷，缓冲个体压力^{10,11}
4. 助力创意落地，同时保障安全性、软件交付效能与可靠性^{12,13}

团队效能 → 个体成果

高效运作的团队不仅交付产品；更赋能个体。¹⁴ 协作可靠、运行高效的团队能提升并放大个人成效。缺乏这些特质的团队会压制和限制个人发展，制造消耗精力的要求。^{15,16} 因此，高绩效团队既能提供优质工作的条件，又能为工作成果开辟实现影响力的途径。

环境特征 → 个体成果

工作环境对个体施加影响，既改变其工作方式，也塑造其工作体验。我们可通过工作需求-资源（JD-R）模型理解这些作用力，该模型将引发压力的因素（需求）与促成成功的要素（资源）区分开来。¹⁷ 例如，大型组织常产生诸如应对官僚体系、适应不断变化优先级等需求。¹⁸ 不同行业特有的需求可能改变职业倦怠的发生率和表现形式。¹⁹

结论

此外，某些行业可能面临因不确定性产生压力的外部因素。

^{20, 21} 不同组织在资源（例如工具）可用性和目标优先级稳定性方面也存在显著差异。资源匮乏会增加工作难度。另一方面，不稳定的优先级会形成移动靶效应，削弱开展雄心勃勃的长期项目的动力。²²

本章概述的理论是我们分析所依据的基础。

我们聚焦于模型中最关键的路径，而非对每个关联环节提供详尽论证。这是刻意为之的选择，旨在清晰透明地展现引导我们结论的核心假设。

通过提供此框架图，我们诚邀您严格评估研究发现、补充自身见解，并将这些因果推演应用于您面临的挑战。

本模型即我们的导航图；我们鼓励您使用它、提出质疑并协助我们完善它。

1. Han, Byung-Chul. *The Agony of Eros*, Vol. 1 (MIT Press, 2017), 47.
2. This approach was adopted in 2023.
3. We tested 15 constructs total in this space.
4. Forsgren, Nicole, Jez Humble, and Gene Kim. *Accelerate: The science of lean software and devops: Building and scaling high performing technology organizations* (IT Revolution, 2018).
5. Our 2022 and 2024 reports dive into this.
6. Sculley, David, Gary Holt, Daniel Golovin, Eugene Davydov, Todd Phillips, Dietmar Ebner, Vinay Chaudhary, Michael Young, Jean-Francois Crespo, and Dan Dennison. "Hidden technical debt in machine learning systems." *Advances in neural information processing systems*, 2015. 28.
7. We don't want to cite ourselves, but 10+ years of our research has underscored this point.
8. MacCormack, Alan, John Rusnak, and Carliss Y. Baldwin. "Exploring the Structure of Complex Software Designs: An Empirical Study of Open Source and Proprietary Code." *Management Science*, 2006, 52, no. 7. 1015–1030.
9. Hackman, J. Richard. *Leading Teams: Setting the Stage for Great Performances* (Harvard Business Press, 2002).
10. Bakker, Arnold B., and Evangelia Demerouti. "The job demands-resources model: State of the art." *Journal of Managerial Psychology*, 2007, 22, no. 3. 309–328.
11. Demerouti, Evangelia, Bakker, Arnold B., Nachreiner, Friedhelm, and Schaufeli, Wilmar B. (2001). "The job demands-resources model of burnout." *Journal of Applied Psychology*, 2001, 86, no. 3. 499–512.
12. Forsgren, Nicole, Jez Humble, and Gene Kim. *Accelerate: The science of lean software and devops: Building and scaling high performing technology organizations* (IT Revolution, 2018).
13. MacCormack, Alan, John Rusnak, and Carliss Y. Baldwin. "Exploring the Structure of Complex Software Designs: An Empirical Study of Open Source and Proprietary Code." *Management Science*, 2006, 52, no. 7. 1015–1030.
14. Hackman, J. Richard. *Leading Teams: Setting the Stage for Great Performances* (Harvard Business Press, 2002).
15. Demerouti, Evangelia, Bakker, Arnold B., Nachreiner, Friedhelm, and Schaufeli, Wilmar B. (2001). "The job demands-resources model of burnout." *Journal of Applied Psychology*, 2001, 86, no. (3). 499–512.
16. Bakker, Arnold B., and Evangelia Demerouti. "The job demands-resources model: State of the art." *Journal of Managerial Psychology*, 2007, 22, no. 3. 309–328.
17. Bakker, Arnold B., and Evangelia Demerouti. "The job demands-resources model: State of the art." *Journal of Managerial Psychology*, 2007, 22, no. 3. 309–328.
18. Aiken, Michael, and Jerald Hage. "Organizational alienation: A comparative analysis." *American Sociological Review*, 1966, 31, no. 4. 497–507. They suggest that a larger organization might create more formal rules.
19. Maslach, Christina, and Michael P. Leiter. "Understanding the burnout experience: recent research and its implications for psychiatry." *World Psychiatry*, 2016, 15, no. 2). 103–111.
20. When this survey was taken, many sectors in the United States were undergoing transformations, to put it euphemistically.
21. Hobfoll, Stevan E. "Conservation of resources: A new attempt at conceptualizing stress." *American Psychologist*, 1989, 44, no. 3. 513–524.
22. Crawford, Eean R., Jeffery A. LePine, and Bruce Louis Rich. "Linking job demands and resources to employee engagement and burnout: A theoretical and meta-analytic review." *Journal of Applied Psychology*, 2010, 95, no. 5. 834–848.

下一步

加入 DORA 社区，共同探讨、学习并协作提升技术驱动型团队与组织的影响力。

<https://dora.community>

探索能够营造学习氛围、实现快速流转与快速反馈的关键能力。

<https://dora.dev/capabilities>

推荐阅读：

Accelerate: The Science of Lean Software and DevOps: Building and Scaling High Performing Technology Organizations. 《加速：精益软件和 DevOps 的科学：如何构建和扩展高性能的技术组织》 IT Revolution.

<https://itrevolution.com/product/accelerate>

推荐阅读：

Team Topologies: Organizing Business and Technology Teams for Fast Flow. 《高效能团队模式》 IT Revolution.

<https://itrevolution.com/product/team-topologies/>

推荐阅读：

The Skill Code: How to Save Human Ability in an Age of Intelligent Machines 《技能密码》. HarperCollins.

推荐阅读：

Flow engineering: From Value Stream Mapping to Effective Action. IT Revolution 《流工程：从价值流程图到有效行动》.

<https://itrevolution.com/product/flow-engineering>

阅读 DORA 研究项目的出版物，包括往期 DORA 报告。

<https://dora.dev/publications>

查阅关于研究及报告的常见问题解答：

<https://dora.dev/faq>

阅读本报告并提交修改、更正与澄清说明。

<https://dora.dev/publications/errata>

确认此是否为 2025 年 DORA 报告的最新版本：

<https://dora.dev/vc/?v=2025.1>

附录

效果评估方法

组织效能：

这是衡量组织整体成功程度的高阶指标，基于盈利能力、市场份额和客户满意度等特征。

就下列各项效能指标而言，过去一年贵组织相对于目标达成情况如何？

- 客户数量增长
- 主要产品的相对市场份额
- 贵组织的整体效能表现
- 贵组织的整体盈利能力
- 组织及使命目标达成度
- 客户满意度
- 运营效率
- 所提供产品或服务的质量

团队效能：该指标衡量个体所在直接团队的可感知效能与协作能力。

您如何评价团队当前在以下领域的效能表现？

- 交付创新解决方案
- 适应变革能力
- 成员间有效协作
- 成员相互依赖度
- 高效协作

产品效能：该指标通过帮助用户完成重要任务、保障信息安全等特性，以及延迟等性能表现度量指标，衡量团队构建产品或服务的成功度与质量。

对于您负责的主要服务或应用程序，您如何评估其在以下领域的当前效能表现？

- 效能表现度量指标，例如延迟
- 功能实现符合预期
- 帮助用户达成关键目标

- 组织内向生产环境部署代码或向最终用户发布产品的频率如何？
- 团队的变更前置时间是多少（即从代码提交到成功在生产环境运行所需时间）？
- 当生产环境变更或用户版本发布导致服务降级（例如引发服务受损或中断）且需采取补救措施（如热修复、回滚、前向修复或补丁）时，通常需要多长时间恢复服务？
- 可用性与操作便捷性
- 保障用户信息安全
- 用户使用的可靠性与可用性

软件交付吞吐量：

这体现了软件交付流程的速度与效率。详见《理解您的软件交付效能》章节获取深度解析。

软件交付不稳定性:

该指标用于衡量软件交付流程的质量与可靠性。详见《理解您的软件交付效能》章节获取深度解析。

- 生产环境变更或用户版本发布中，约有多少百分比的变更会导致服务降级（例如引发服务受损或中断）且需采取补救措施（如热修复、回滚、前向修复或补丁）？
- 过去六个月中，约有多少百分比的部署属于非计划性但为解决应用程序用户端缺陷而执行的？

代码质量: 该指标反映个体对其所开发主要应用或服务底层代码质量的评估。

- 您如何评价所负责主要服务或应用程序的底层代码质量？

个体效能: 该指标反映个体对自身工作效率及工作成就感的自我评估。

- 过去三个月内，您在工作中执行任务与履行职责的有效性如何？

- 在过去三个月中，您对自身工作效率的感知如何？
- 在过去三个月中，您认为自己的工作产生了多大成效？
- 在过去三个月中，您达到高度专注或进入‘心流’工作状态的频率如何？

有价值的工作: 该指标测量个体自我评估中用于从事其认为有价值工作的时间占比。

- 在过去三个月中，您认为投入在有价值且值得的工作上的时间占比约为多少？

摩擦阻力: 指个体工作中受阻碍程度的衡量指标

- 在过去三个月中，工作摩擦对您造成的阻碍程度如何？

职业倦怠: 衡量与工作相关的疲惫感及消极情绪的指标在过去三个月中，您经历以下情况的频率如何？

- 对工作感到漠不关心或愤世嫉俗
- 因工作产生职业倦怠感
- 感觉工作效率低下
- 工作情绪对非工作生活造成负面影响

AI 采纳

AI 采纳采用虽非核心成果，但贯穿本报告的核心衡量指标以下是关于我们测量方法的补充说明。

AI 采纳: 该指标衡量个人将 AI 融入日常工作的程度及其对 AI 的态度。

在过去三个月中，当您遇到需解决的问题或需完成的工作任务时，使用 AI 的频率如何？

在过去三个月中，您在工作中对 AI 的依赖程度如何？

在过去三个月中，作为开发工作的一部分，您对 AI 生成代码输出质量的信任度如何？

平台工程

平台及平台团队的定义说明：

平台：指可跨多个应用程序或服务共享的能力集合。

公司可能拥有多个功能重叠的平台，我们将这些统称为‘平台’。

平台团队：指专门负责平台构建与运维的平台工程团队。不是必须设立专职平台工程团队的。

平台工程：指构建平台时应用的软件与系统工程实践。

稳健平台的核心特征列表：
您的平台在多大程度上具备以下特性？

该平台帮助我构建和运行可靠的应用程序与服务。

平台的用户界面 (UI) 简洁直观。

平台提供我独立工作所需的工具和信息。

该平台帮助我构建和运行安全的应用程序与服务。

平台的行为方式符合我的预期。

平台协助我遵循必要流程（例如代码审查、安全验收）。

平台提供我独立工作所需的工具和信息。

平台对我的任务结果给予清晰反馈。

我在平台上执行的任务自动化程度良好。

平台团队会对我提供的反馈采取行动。

该平台易于使用。

平台有效屏蔽了底层基础设施的复杂性。

审校



张乐

腾讯研发效能及 AI Coding 资深技术专家

目前负责服务数万人的智能化软件工程相关工具平台的设计与研发。前百度工程效率专家、前京东工程效率总监与首席架构师。长期在拥有数万人研发规模的一线互联网公司，负责研发效能提升、研发效能度量体系建设、敏捷与 DevOps 实践落地及工具平台研发工作。DevOps 运动国内早期布道者与推动者。《研发效能宣言》发起人及主要内容起草者。著作：《软件研发效能提升实践》、《软件研发效能权威指南》；译著：《独角兽项目：数字化转型时代的开发传奇》、《价值流动：数字化场景下软件研发效能与业务敏捷的关键》。知识星球“研发效能”主理人。



茹炳晨

腾讯 Tech Lead，腾讯研究院特约研究员，腾讯集团技术委员会委员，中国计算机学会 TF 研发效能 SIG 主席，腾讯云架构师技术同盟入会成长主席，中国通信标准化协会 TC608 云计算标准和开源推进委员会云上软件工程师工作组副组长，中国商业联合会互联网应用技术委员会智库专家，复旦大学 CodeWisdom 团队成员，“软件研发效能度量规范”团体标准核心编写专家，国内外各大技术峰会的联席主席、出品人和 Keynote 演讲嘉宾，公众号“茹炳晨聊软件开发”主理人，二十余本计算机专业图书的作者和译者。

译者



朱少民

QECon 发起人、CCF 杰出会员、《软件工程 3.0》作者
同济大学特聘教授、CCF 质量工程 SIG 主席，拥有个人公众号“软件工程 3.0 时代”。先后获得多项科技进步奖，出版了二十多部著作和 4 本译作，其代表作有：《软件工程 3.0》、《智能软件工程》、《全程软件测试》、《敏捷测试：以持续测试促进持续交付》、《软件测试方法和技术》、《软件质量保证与管理》等。经常作为大会联席主席、论坛主席或专场出品人、演讲嘉宾等出席国内技术大会，曾任 IEEE ICST 2019 工业论坛主席、多个 IEEE 国际学术会议程序委员、思科（中国）软件有限公司 QA 资深总监等。



李威

JFrog 解决方案架构师 DevOps 咨询师、教练。曾就职于烽火、京东等企业，十余年一线开发及运维经验，带领团队从零到一实践 DevOps 转型。现就职于 JFrog，善于在工程实践方面引导帮助客户落地 DevOps 理念。参与编写《软件研发效能权威指南》。



王永雷

2016 年加入 BlackDuck，BlackDuck 资深软件安全架构师，首席开源软件治理专家，为大中华区的企业客户提供企业级的软件安全和开源合规治理解决方案。参与编写《DevOps 原理和实践》，参与翻译《拥抱开源》，《开放式协作》。指南》。

译者



揭光发

腾讯云 架构师联盟社群管理
主席 腾讯 专家工程师
20 年研发与团队管理经验，前
腾讯云 TVP，现腾讯全栈技术
专家，公司级低代码项目负责
人，是 IEEE 低代码标准及大
湾区企业低代码标准的主撰
写人；大模型应用早期实践者
与布道师，是国内顶级行业/
技术峰会相关话题优秀讲师
及出品人。在低代码与 LLM 结
合场景有深度的实践，愿景是
“人人能编程”。带领团队深
度践行 LLM 对研发提效、探索
Vibe coding 在专业程序员与
准开发者群体的落地，个人代
码全栈 AI 含量几近 100%。



顾黄亮

畅销书《DevOps 权威指南》
《技术赋能数字化转型的基
石》作者，中国商联专家智库
入库专家、国家互联网数据中
心产业技术创新战略联盟
(NIISA) 智库专家委员会副主
任委员、江苏银行业和保险业
金融科技专家委员会候选专
家、中国信通院企业数字化转
型 IOMM 委员会特聘专家、中
国信通院可信云标准特聘专
家、低代码/无代码推进中心
特聘专家，腾讯云最具价值专
家 MVP，阿里云最有价值专家
MVP，《研发运营一体化
(DEVOPS) 能力成熟度模型》
和《企业 IT 运维发展白皮书》
核心作者，容器云技能大赛
课程出品人，多个技术峰会
演讲嘉宾，拥有丰富的企业级
DevOps 实战经验，专注企业
IT 数字化的转型和落地，致
力于企业智慧运维体系的打
造。



单琥晗

资深研发效能专家
在多家互联网头部公司负责研
发效能提升工作。主要包括：
华为，负责网络操作系统、终
端 EMUI 等千人级研发团队的
研发模式&工具的规划设计、落
地实施。
蚂蚁集团，负责研发数字化、
智能化建设（蚂蚁 研发洞察
体系）。
字节跳动，负责公司级研发效
能提升工作，主要包括：
效能度量体系的建设与推广
（字节 DevMind 体系）；效能
平台与最佳实践的建设与推
广；重点业务线效能洞察与提
升；AI X 研发提效实践的探索
与应用。

译者



吴骏龙

前 Wish 中国测试总监，历任阿里巴巴本地生活高级测试经理。

毕业于中国科学技术大学，获硕士学位。腾讯云最具价值专家 TVP。

极客时间《容量保障核心技术与实战》专栏作者，《软件研发效能提升之美》、《软件研发效能权威指南》、《现代软件测试技术之美》、《深入浅出全链路压测》等书籍作者。在软件质量体系、服务容量保障、服务稳定性建设、软件研发效能等领域深耕多年，善于通过创新手段解决质量、容量和效能难题，拥有多项国内外专利。多次受邀于业界各技术大会发表演讲，传播先进理念和方法论。



熊志勇

QECon 专家顾问

QECon 专家顾问，是 QETalk 访谈发起人，曾在京东和 360 担任研发效能和 DevOps 平台的产品专家。2023-2025 年在 360 集团致力于通过 LLM 技术打造研发效能数字人、智能指标查询及报表生成系统，服务集团内千人规模产研团队。此前在京东担任研发效能和 DevOps 平台产品专家，主导参与两款平台建设，支持万人规模产研团队协作。负责的京东零售持续集成和代码质量平台成功从 20 人小范围使用扩展至全公司通用效能工具。2011 年起作为测试技术社区 TestWo 核心成员参与“测试之旅”公益沙龙组织与测试白皮书编撰。2022 年起担任“云上软件工程社区”研发效能和平台工程领域技术专家，持续推动业最佳实践分享。



关注QECon公众号
持续获取AI质效前沿洞察

“State of AI-assisted Software
Development” 《AI 辅助软件开发之现状》 由 Google
LLC 发布，遵循 CC BY-NC-SA 4.0 许可协议。



2026全球软件质量&效能大会

2026 GLOBAL SOFTWARE QUALITY & EFFICIENCY CONFERENCE

2026年5月22-23日·深圳

2026年9月18-19日·上海

2026年10月30-31日·北京

AI赋能软件研发提质增效一线最佳实践

QECon全球软件质量&效能大会自办会以来,始终将质量、效能与每一位软件从业人员紧密连接在一起,追寻“提质增效”的最佳实践,坚持“一线技术与工程实践输出”。QECon2025内容亮点:聚焦大模型赋能软件工程细分场景技术落地话题,前瞻测试与提效领域的技术趋势。同时,延续对测试与效能基要能力的深度探讨,打造既立足前沿、又兼顾基础重要的技术交流平台,助力质效人智见未来。

适合参加岗位人群

研发总监、测试管理、测试开发岗位、QA、质量管理、研发管理、平台部门、CI/CD流水线部门、敏捷赋能团队、平台工程、pmo、工程效能团队、测试人员等。



详情查看官网



主会场+Aengt专场
回看

60%大模型赋能提质增效专场

LLM驱动的智能测试

质效领域Agent实践

AI驱动需求工程

LLM赋能下测试实践与流程再造

质效人如何掌握大模型核心能力

模型在研发提效中的深度实践

AIGC时代的代码质量

软件工程“暗”知识工程

AI时代的团队和组织管理

大模型时代质量工程

大模型驱动的DevOps工具链

大模型评测和Agent质量保障

.....

30%质量效能基要能力专场

自动化到智能化测试

多终端质量保障

测试左移&右移

专项测试

业务敏捷与价值流实践

全链路压测与稳定性保障

质效度量:从洞察到智能化

大厂专场

.....

10%深度闭门交流专场(2025组织过深受好评的主题)

3小时工作坊

DeepSeek技术及企业级应用实践

GenAI驱动的端到端研发需求测试范式跃迁

从“度量困境”到“智能破局”:智能洞察实践之路

.....

2小时闭门会

使用大模型实现质效提升必须跨过的几座大山

破解大模型软件测试难题

Vibe Coding对于软件质效提升的挑战与机遇

.....

研讨会话题类似

1. 单元测试用例生成有哪些坑?借助大模型会有多大实质性改进?
2. GenAI用于API测试用例生成有哪些成熟的实践?
3. 今天“推理模型+深度搜索”对程序语义的理解更加深刻,是否能解决测试断言(Test Oracle)问题?
4. 在复杂业务逻辑中,有哪些技术手段可以提升大模型对业务的理解,从而确保生成的测试用例具有足够的准确性和有效性?
5. 当测试人员可能会依赖自动化生成内容时,我们如何保证测试的质量?
6. 测试AI能力对业务RAG知识的依赖较多,实践中有哪些好的RAG知识库建设标准或规范?

.....



2026 智能时代软件工程技术大会

2026年6月26-27日 · 杭州

2026年11月20-21日 · 深圳

拥抱AI，走深向实 / 引领软件工程可持续发展

SECon+AgentX:智能时代软件工程技术大会：是一场面向AI时代 CTO、技术 VP、技术总监、架构师，研发管理者等技术领导者及研发从业者的高端技术盛会。

大会专注于软件开发技术的最新趋势，深度探讨大模型驱动的技术革新以及智能体在工程化落地过程中的关键技术突破与产品商业化验证的会议。重点打造覆盖全产业链的智能体技术实践平台和行业应用产品交流平台。

适合参加岗位人群

技术团队负责人、架构师、设计规划、工程总监、开发人员、前端开发、数据库专家、研发管理、AI模型应用开发岗、AI部署运维。



详情查看官网



AgentX专场回看

55%AI模型应用核心能力提升专场

AI Infra和加速推理

多模态与生成式AI应用

Data+AI的探索与实践

Agent开发框架应用与实践

金融场景Agent应用实践

模型应用主流架构模式

大模型高效训练与微调

RAG与上下文工程

Agent的具身化与交互

大模型行业创新应用

AI模型安全与数据治理

大模型行业创新应用

AI时代的数据架构

多智能体协作

.....

45%研发关键技术能力进阶专场

多云架构

数据治理

业务架构

出海与云原生

高可用架构

前端智能化践



产品力领航者大会

The Power of Products Leadership Conference

2026年4月24-25日·杭州

2026年8月·待定



详情查看官网

领航产品力，共启AI智能

在全球商业竞争范式由流量驱动向价值创造转型的关键阶段，产品力已演进为企业构筑长期竞争优势的核心战略要素，具备系统性产品矩阵的企业在消费下行周期中往往表现出显著抗风险能力，验证产品力驱动的商业韧性机制。PM大会以“重塑产品力基因——从用户心智到生态势能”为核心命题，解码产品力的底层逻辑与实践范式。

PM产品力领航者大会同时是专注于探讨和推动AGI时代下，产品人关键能力提升的重要盛会。旨在汇聚业界精英，共同探索在AIGC时代下如何提升产品能力，引领行业发展新趋势。会议聚焦以下主题方向：商业洞察、用户研究、技术创新、数据决策、跨界融合等，通过主题演讲和工作坊实践分享，集结产品大咖、沉淀人脉资源、提升自身职业价值、洞察行业发展趋势。

适合参加岗位人群

产品负责人、产品总监、产品经理或长期从事产品战略规划、产品策略、用户研究、用户体验等相关岗位、体验设计师、产品设计师、交互设计师、产品运营及用户增长人员、业务数据分析师、数据产品经理、产品市场推广及品牌建设人员等。

Day1: 十场行业主题峰会演讲, 35+前沿产品案例

AIGC时代产品

互联网产品

新零售

智慧出行

跨界大咖行

数字金融

产品出海

AI产品创新idear

.....

Day2: 10-12 场 3 小时深度工作坊

《从用户价值到商业价值》

《以拼多多为例，聊如何赢得竞争》

《AI 时代下的精益需求管理与实践》

《用户映射体系构建创新产品设计》

《规划AI产品的成长飞轮》

《解码潮流消费与增长思维重构》

《通过用户研究助力业务增长》

《数字化转型产品规划实战》

《策略产品经理实践工作坊》

《设计冲刺》

.....